

Lineární model s jedním numerickým prediktorem

Podkladové čtenářské materiály k přednášce

28. září 2026

Obsah

1 Úvod	2
2 Výsledky učení	2
3 Data a modelová otázka	2
3.1 Nejdřív jen květy jako data	4
4 Šířka korunního lístku	4
5 Délka korunního lístku	4
6 Rychlý a jednoduchý bodový graf	5
7 Graf pomocí {ggplot2}	6
7.1 Přes stejná data květů můžeme vést mnoho přímek	7
8 Jak popíšeme libovolnou přímku?	8
9 Intercept (a): posun přímky nahoru/dolů	9
10 Sklon (b): změna strmosti přímky	9
11 Od přímky k odhadnuté délce a residuu	10
11.1 Vybereme 4 květy napříč prostorem dat	10
11.2 Výpočet rezidua pro jeden květ	12
11.3 Výpočet rezidua pro všechny 4 květy	13
11.4 Jak kvantifikujeme „kvalitu“ přímky: SSE	14
11.5 Od našich dat k obecnému zápisu modelu	15
11.6 Sklon jako změna odhadnuté délky	17
12 Jak nejlepší přímku najdeme v R	17
12.1 Odhadnuté délky a graf modelu	18
13 Residua v R a jejich první grafická kontrola	21
13.1 Nejdříve známý graf: histogram residuí	22
13.2 Odhadnuté délky vs. residua	23
13.3 Základní graf v R	24
13.4 Graf pomocí {ggplot2}	25
14 Co musí být rozumné, aby lineární model odpovídal na naši otázku?	26
14.1 Čtyři otázky, čtyři různé stopy v grafu	27
14.2 Odezva a residua mohou mít jiný tvar	28
15 Co model nevidí: druhy kosatců	29
15.1 Nejprve obarvíme původní data	29
15.2 Potom obarvíme graf odhadnutých délek a residuí	30

16 Co budeme řešit v dalších lekcích	30
17 Shrnutí	31
Slovníček pojmů	31

1 Úvod

Představte si, že měříte korunní lístky kosatců. Dá se z jejich šířky odhadnout jejich délka?

Hlavní otázka této lekce

Mají širší korunní lístky kosatců také větší délku, a pokud ano, jak velká je tato změna?

Na tuhle otázku dnes navážeme. V minulé části jsme se naučili dívat na body v grafu a číst z nich jednoduchý trend. Teď tento trend rozšíříme do lineárního modelu, aby z bodů vznikl model, který umí vztah mezi šířkou a délkou korunního lístku shrnout jedním zápisem a jednou interpretací.

Cíl není „umět kliknout na funkci“, ale **převést biologickou otázku na modelový zápis a smysluplně interpretovat odhadnutý efekt**.

Pracovní otázka: Jak se mění odezva (délka korunního lístku) s rostoucím prediktorem (šířka korunního lístku)?

2 Výsledky učení

Po prostudování této lekce budete schopni:

- převést biologickou otázku na modelovou otázku s odezvou a prediktorem
- fitovat model $\text{lm}(y \sim x)$ a interpretovat směr i velikost efektu
- vysvětlit, co je residuum, a proč je důležité pro kontrolu modelu
- popsat základní diagnostický graf a rozpoznat v něm možné problémy

3 Data a modelová otázka

Pro první modelovou lekci používáme dataset `iris`, který obsahuje reálná měření 150 květů kosatců. Budeme vysvětlovat vztah mezi šířkou (`Petal.Width`) a délkou (`Petal.Length`) korunního lístku. Data sesbíral botanik Edgar Anderson a později je publikoval Ronald Fisher. Podrobnosti a odkazy na původní publikace uvádí [dokumentace datasetu v R](#).

Dataset rozlišuje tři druhy kosatců. V prvním modelu použijeme záměrně **jen jeden numerický prediktor** a **druh zatím do modelu nepřidáme**. Na konci se k tomuto rozhodnutí vrátíme při diagnostice.

Doplňující: proč dataset `iris`?

- měří biologicky srozumitelné veličiny ve stejných jednotkách

- obsahuje přirozenou variabilitu mezi květy
- hodnoty šířky začínají blízko nuly, takže intercept můžeme ukázat bez stlačení dat do malé části grafu
- umožňuje plynulý přechod od bodového grafu k lineárnímu modelu

Doplňující: příprava dat

Tento blok připravuje české názvy sloupců pro další výklad. Pro pochopení lineárního modelu jej můžete přeskočit; důležité je vědět, že každý řádek objektu `data_kosatce` představuje jeden květ.

```
# Načteme ukázkový dataset, který je součástí R
data(iris)

# Vybereme tři potřebné sloupce a dáme jim srozumitelné názvy
data_kosatce <-
  data.frame(
    sirka_listku = iris$Petal.Width,
    delka_listku = iris$Petal.Length,
    druh = iris$Species
  )

# Zkontrolujeme rozsah a typ hodnot v připravených datech
summary(data_kosatce)
```

sirka_listku	delka_listku	druh
Min. :0.100	Min. :1.000	setosa :50
1st Qu.:0.300	1st Qu.:1.600	versicolor:50
Median :1.300	Median :4.350	virginica :50
Mean :1.199	Mean :3.758	
3rd Qu.:1.800	3rd Qu.:5.100	
Max. :2.500	Max. :6.900	

Co konkrétně znamenají sloupce v `iris`:

- `Petal.Width`: šířka korunního lístku v centimetrech (prediktor)
- `Petal.Length`: délka korunního lístku v centimetrech (odezva)
- `Species`: druh kosatce, který zatím ponecháme mimo model

Na úrovni biologické otázky nás zajímá jednoduché tvrzení: mají širší korunní lístky také větší délku, pokud ano, jak velká je tato změna.

3.1 Nejdřív jen květy jako data

Než budeme mluvit o modelu, podívejme se na jednotlivé květy a na strukturu dat.

Z předchozích lekcí už víme dvě základní věci:

- obě proměnné jsou numerické, tedy měřené na číselné škále
- každou proměnnou můžeme nejdřív shrnout samostatně, než se podíváme na jejich vztah


Základní shrnutí jednotlivých proměnných si můžete otevřít jako krátké zopakování. Pro dnešní otázku ale bude nejdůležitější jejich vzájemný vztah.

Doplňující: zopakování každé proměnné samostatně

4 Šířka korunního lístku


```
# Zkontrolujeme polohu a rozptyl šířek korunních lístků  
summary(data_kosatce$sirka_listku)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.100	0.300	1.300	1.199	1.800	2.500



5 Délka korunního lístku

```
# Zkontrolujeme polohu a rozptyl délek korunních lístků  
summary(data_kosatce$delka_listku)
```



Než vybereme graf, zkusme si malý mentální úkol: když máme dvě numerické proměnné, jaký typ grafu dává největší smysl?

Odpověď: pro dvě měření použijeme bodový graf

Dobrá volba je bodový graf, protože chceme vidět jednotlivé květy a vztah mezi dvěma měřeními.

V našem případě je prediktorem **šířka korunního lístku** a podle ní vysvětlujeme rozdíly v **délce korunního lístku**.

Co z grafu sledujte zejména:

- **směr vztahu:** zda se s rostoucí šířkou obvykle zvětšuje i délka
- **neobvyklé květy:** jestli jsou v datech květy, které se chovají výrazně jinak než ostatní
- **rozptýlení kolem trendu:** jak velký je rozptyl hodnot kolem hlavního trendu

6 Rychlý a jednoduchý bodový graf


```
plot(
  # Každý květ vytvoří jeden bod se dvěma naměřenými souřadnicemi
  x = data_kosatce$sirka_listku,
  y = data_kosatce$delka_listku,
  # Popisky vysvětlují význam a jednotky obou os
  xlab = "Šířka korunního lístku (cm)",
```

```

ylab = "Délka korunního lístku (cm)",
main = "Bodový graf šířky a délky korunního lístku",
pch = 16,
col = "#8A8A8A",
cex = 1.4,
cex.axis = 1.5,
cex.lab = 1.5,
cex.main = 1.5
)

```

Bodový graf šířky a délky korunního lístku



7 Graf pomocí {ggplot2}

```


ggplot2::ggplot(
  # Data určují řádky; aes() přiřadí sloupce k osám
  data = data_kosatce,
  mapping = ggplot2::aes(x = sirka_listku, y = delka_listku)
) +
  # Jeden řádek dat se zobrazí jako jeden bod
  ggplot2::geom_point(size = 2, alpha = 0.8, color = "#8A8A8A") +
  # Popíšeme osy i celý graf
  ggplot2::labs(
    x = "Šířka korunního lístku (cm)",

```

```

y = "Délka korunního lístku (cm)",
title = "Bodový graf šířky a délky korunního lístku"
) +
ggplot2::theme_bw(base_size = 18)

```




7.1 Přes stejná data květů můžeme vést mnoho přímek

V celé lekci budeme držet tuto interpretační větu:

„Když porovnáme dva květy, model pro květ se širším korunním lístkem odhaduje v průměru delší korunní lístek. Velikost tohoto rozdílu popisuje sklon přímky.“

Pro stejná data existuje **více kandidátních přímek** a každá vede k **trochu jiné interpretaci**. Každá přímka má přitom jiné parametry (viz níže).



Než rozhodneme, která přímka vystihuje data nejlépe, potřebujeme umět libovolnou přímku jednoznačně popsat.

8 Jak popíšeme libovolnou přímku?

Každou přímku popíšeme dvěma parametry:


- **a**: intercept (anglicky *intercept*; česky také **průsečík**)
- **b**: sklon (anglicky *slope*; česky také **regresní koeficient**)

Intuitivně:


- **a posouvá přímku nahoru nebo dolů** (mění základní úroveň odhadnuté délky)
- **b mění strmost přímky**, tedy jak rychle roste odhadnutá délka s rostoucí šířkou

Nejčastější studentská chyba je zaměnit tyto role. Proto je v následujících grafech oddělujeme: nejprve měníme intercept při stejném sklonu, potom sklon při pevném interceptu.


9 Intercept (a): posun přímky nahoru/dolů



10 Sklon (b): změna strmosti přímky



Jak vypadají kombinace **a** a **b** dohromady, si ukážeme v obrázku.



Teď už umíme každou kandidátní přímku popsat. Jak ale poznáme, která z nich nejlépe vystihuje vztah mezi šířkou a délkou korunního lístku?

Kritérium pro výběr přímky musí využít residua

Potřebujeme kritérium, které využije vzdálenosti naměřených délek od přímky při dané šířce. Nejprve proto musíme pochopit odhadnuté délky a residua.

11 Od přímky k odhadnuté délce a residuu

11.1 Vybereme 4 květy napříč prostorem dat

Než porovnáme kandidátní přímky ve všech datech, ukážeme princip na čtyřech květech rozptřených napříč grafem.

Doplňující: výběr čtyř řádků

Tento technický krok pouze vybírá malý, přehledný příklad. Čísla řádků nejsou součástí statistické metody a pro pochopení dalšího výpočtu je nemusíte znát.

```
# Vybereme čtyři květy a ponecháme jen dvě modelované proměnné
data4 <-
  data_kosatce[
    c(1, 58, 71, 101),
    c("sirka_listku", "delka_listku")
  ]

# Zobrazíme malou tabulku, se kterou budeme počítat ručně
data4
```

	sirka_listku	delka_listku
1	0.2	1.4
58	1.0	3.3
71	1.8	4.8
101	2.5	6.0


Konkrétní kandidátní přímka

Jako konkrétní příklad použijeme přímku (**B**) s interceptem $a = 1.1$ a sklonem $b = 2.2$.

Reziduum je **svislá vzdálenost bodu od modelové přímky**. Pokud je **kladné**, model délku podhodnocuje; pokud **záporné**, délku nadhodnocuje.

Rezidua přitom **očekáváme i u užitečného modelu**. Jednotlivé organismy se v důsledku přirozené biologické variability liší, takže žádná jednoduchá přímka nepopíše každý květ přesně. **Samotná existence reziduí proto neznamena, že je model špatný.**

V grafu níže je to vidět přímo jako zlaté úsečky mezi šedými body a fialovou přímkou.



11.2 Výpočet rezidua pro jeden květ

Nejdřív pro jeden květ ručně (dosazení konkrétních hodnot):

Logický postup pro jeden konkrétní květ:

1. Vezmeme **šířku** vybraného korunního lístku.
2. Dosadíme ji do vztahu **odhadnutá délka = intercept + sklon × šířka**.
3. Vypočítáme odhadnutou délku tohoto korunního lístku podle zvolené přímky.

Nejprve vztah zapíšeme pouze názvy veličin z našich dat. Hodnoty prvního květu dosadíme až v dalším kroku. Jeho šířka 0.2 cm určuje **vodorovnou polohu prvního šedého bodu** v grafu výše. Intercept 1.1 a sklon 2.2 popisují **fialovou přímku**:

$$\begin{aligned} \text{odhadnutá délka prvního korunního lístku} &= \text{intercept} \\ &+ \text{sklon} \cdot \text{šířka prvního korunního lístku} . \end{aligned}$$

Teprve potom dosadíme hodnoty prvního květu:

$$\begin{aligned} \text{odhadnutá délka}_1 &= \text{intercept} + \text{sklon} \cdot \text{šířka}_1 \\ &= 1.1 + 2.2 \cdot 0.2 \\ &= 1.1 + 0.44 \\ &= 1.54 \text{ cm} \end{aligned}$$

Výsledek 1.54 cm je v grafu výše **výška fialové přímky** při šířce 0.2 cm — tedy **horní konec první zlaté úsečky**. Naměřená délka 1.4 cm je naopak **výška prvního šedého bodu**. Residuum proto nejprve zapíšeme pouze pomocí názvů veličin:

$$\begin{aligned} \text{residuum prvního korunního lístku} &= \text{naměřená délka prvního korunního lístku} \\ &- \text{odhadnutá délka prvního korunního lístku} . \end{aligned}$$

Teprve potom dosadíme hodnoty odečtené z bodu a přímky:

$$\begin{aligned}
 \text{residuum}_1 &= \text{naměřená délka}_1 - \text{odhadnutá délka}_1 \\
 &= 1.4 - 1.54 \\
 &= -0.14 \text{ cm}
 \end{aligned}$$

Hodnota -0.14 cm odpovídá **první zlaté úsečce**. Samotná úsečka má délku 0.14 cm; **záporné znaménko residua** říká, že šedý bod leží pod fialovou přímkou.

```

a0 <- 1.1
b0 <- 2.2

# Dosadíme šířku prvního květu do rovnice zvolené přímky
odhadnuta_delka_1 <-
  a0 + b0 * data4$sirka_listku[1]

odhadnuta_delka_1

```

```
[1] 1.54
```

11.3 Výpočet rezidua pro všechny 4 květy

Jakmile máme princip pro jeden květ, aplikujeme stejný výpočet na všechny čtyři květy. Tím získáme:

- odhadnuté délky jednotlivých květů
- rozdíl mezi naměřenou a odhadnutou délkou (residua)

```

odhadnuta_delka <-
  a0 + b0 * data4$sirka_listku

# Residuum je naměřená hodnota minus odhad přímky
residuum <-
  data4$delka_listku - odhadnuta_delka

tab_pred <-
  data.frame(
    bod = 1:4,
    sirka = data4$sirka_listku,
    namerena_delka = data4$delka_listku,
    odhadnuta_delka = round(odhadnuta_delka, 2),
    residuum = round(residuum, 2)
  )

# Zobrazíme měření, odhad i residuum vedle sebe
tab_pred

```

	bod	sirka	namerena_delka	odhadnuta_delka	residuum
1	1	0.2	1.4	1.54	-0.14
2	2	1.0	3.3	3.30	0.00
3	3	1.8	4.8	5.06	-0.26
4	4	2.5	6.0	6.60	-0.60

Čtení tabulky krok za krokem:

- sloupec **sirka**: šířka korunního lístku konkrétního květu
- sloupec **namerena_delka**: skutečně naměřená délka korunního lístku
- sloupec **odhadnuta_delka**: délka odhadnutá pomocí přímky B
- sloupec **residuum**: rozdíl mezi naměřenou a odhadnutou délkou

Teprve teď, když jsme stejný výpočet viděli pro všechny čtyři květy, zavedeme obecné symboly. Naměřenou hodnotu označíme y_i , šířku x_i , odhadnutou hodnotu $\hat{y}_i$, intercept a , sklon b a **residuum** (anglicky *residual*) e_i .

$$\hat{y}_i = a + b \cdot x_i$$

$$e_i = y_i - \hat{y}_i$$

V prvním vzorci je $\hat{y}_i$ odhadnutá délka jednoho lístku, x_i jeho naměřená šířka, a intercept a b sklon. Ve druhém vzorci je y_i skutečně naměřená délka a e_i rozdíl mezi měřením a odhadem.

11.4 Jak kvantifikujeme „kvalitu“ přímky: SSE

Součet čtverců residuí (anglicky *sum of squared errors* nebo *residual sum of squares*, zkratka **SSE**) říká, jak moc jsou body daleko od modelové přímky. **Čím menší SSE, tím lépe přímka vystihuje data.**

Proč čtverce? Protože:

- **odstraní znaménko** (kladná a záporná rezidua se neodečtou)
- **více penalizují velké chyby**
- **dávají jedno srovnatelné číslo** pro každou kandidátní přímku

Tabulka výše obsahuje všechny hodnoty potřebné pro ruční výpočet. Pro přehled ji zobrazíme ještě jednou:

Květ	Šířka	Naměřená délka	Odhadnutá délka	Residuum
1	0.2	1.4	1.54	-0.14
2	1.0	3.3	3.30	0.00
3	1.8	4.8	5.06	-0.26
4	2.5	6.0	6.60	-0.60

Ruční kalkulační zápis pro tuto přímku:

součet čtverců residuí = (residuum prvního květu)² + ... + (residuum posledního květu)².

Teprve potom dosadíme residua z tabulky:

$$SSE = (-0.14)^2 + (0)^2 + (-0.26)^2 + (-0.6)^2 = 0.02 + 0 + 0.07 + 0.36 = 0.45$$

Až potom obecně pro všechna pozorování:

$$SSE = \sum_{i=1}^n e_i^2$$

Zde e_i označuje residuum jednoho květu, e_i^2 jeho čtverec, n počet květů a znak $\sum$ znamená, že čtverce všech residuí sečteme.

Stejný výpočet nyní provedeme pro každou kandidátní přímku a pro všech 150 květů. Výsledkem je jediné srovnatelné číslo pro každou přímku:

Přímka	Intercept	Sklon	SSE
A	0.5	1.8	231.08
B	1.1	2.2	33.98
C	1.7	2.6	214.32

Otázka: Který model nejlépe odpovídá výzkumné otázce o vztahu šířky a délky korunního lístku?

Odpověď: nejlepší přímka má nejmenší SSE

Z nabízených přímek je nejlepší B, protože má nejmenší SSE. Lineární model ale není omezen na tyto tři možnosti: hledá takový intercept a sklon, které SSE minimalizují mezi všemi možnými přímkami.

11.5 Od našich dat k obecnému zápisu modelu

Pro první květ můžeme naměřenou délku rozdělit na délku odhadnutou přímkou a residuum:

$$\begin{aligned} \text{naměřená délka prvního korunního lístku} &= \text{odhadnutá délka prvního korunního lístku} \\ &+ \text{residuum prvního korunního lístku} . \end{aligned}$$

Teprve potom dosadíme hodnoty prvního květu:

$$\begin{aligned} \text{naměřená délka}_1 &= \text{odhadnutá délka}_1 + \text{residuum}_1 \\ &= 1.54 + (-0.14) \\ &= 1.4 \text{ cm} \end{aligned}$$

Stejný vztah nyní zapíšeme pomocí již zavedených obecných symbolů:

$$y_i = \hat{y}_i + e_i = a + b \cdot x_i + e_i$$

Interpretace v biologickém příběhu:

- y_i je naměřená délka jednoho korunního lístku a x_i jeho naměřená šířka
- $\hat{y}_i$ je délka odhadnutá přímkou pro tuto šířku
- **a** (intercept) je odhad délky korunního lístku při nulové šířce; nula leží těsně za rozsahem pozorovaných dat
- **b** (sklon) říká, o kolik se v průměru změní délka korunního lístku při zvýšení jeho šířky o 1 cm
- e_i je nevysvětlená část variability (residuum)

11.6 Sklon jako změna odhadnuté délky

Nejprve ukážeme sklon na zvolené přímce a až poté jeho obecný zápis. Pro výpočet musíme použít dva body ležící na stejné přímce, ne dvě libovolná pozorování z dat:

Bod na přímce	Šířka	Odhadnutá délka
1	0.2	1.54
2	2.5	6.60

Sklon zvolené přímky můžeme z těchto dvou bodů zapsat takto:

$$\text{sklon přímky} = \frac{\text{změna odhadnuté délky korunního lístku}}{\text{změna šířky korunního lístku}}.$$

Teprve potom dosadíme souřadnice dvou bodů na přímce:

$$\text{sklon přímky} = \frac{6.6 - 1.54}{2.5 - 0.2} = \frac{5.06}{2.3} = 2.2$$

Až potom obecně:

$$b = \frac{\Delta \hat{y}}{\Delta x}$$

12 Jak nejlepší přímku najdeme v R

Funkce `lm()` fituje lineární model. Nejprve si její zápis přečteme jako obecnou gramatiku:

```
# Obecný zápis nejprve pojmenuje role proměnných a dat
lm(
  formula = odezva ~ prediktor,
  data = data
)
```

V tomto zápisu jsou odezva, prediktor a `data` zástupné názvy. Znak `~` můžeme číst jako „odezvu vysvětlujeme pomocí prediktoru“.

Pro naši biologickou otázku dosadíme:

- odezva: `delka_listku`
- prediktor: `sirka_listku`
- data: `data_kosatce`

Teprve potom sestavíme konkrétní volání. Tady model jen fitujeme; grafy uděláme až v dalším kroku.

V této části oddělíme dvě operace:

- `lm()` odhadne parametry modelu z dat

- `coef(mod_listky)` vrátí dva parametry, které už znáte z kandidátních přímek

```
mod_listky <-
  lm(
    formula = delka_listku ~ sirka_listku,
    data = data_kosatce
  )

# Zobrazíme odhadnutý intercept a sklon
coef(mod_listky)
```

```
(Intercept) sirka_listku
1.083558      2.229940
```

Co vidíme za parametry (koeficienty) modelu:

- Intercept odpovídá parametru *a*
- odhad u *sirka_listku* odpovídá sklonu *b*

Odpověď na biologickou otázku

Odhadnutý sklon je 2.23. Při zvýšení šířky korunního lístku o 1 cm proto očekáváme v průměru zvýšení jeho délky o 2.23 cm.

Odhadnutý intercept je 1.08 cm. Popisuje odhadnutou délku při nulové šířce, která leží těsně mimo rozsah pozorovaných dat. V tomto biologickém příběhu je proto důležitější sklon.

Model tak odpovídá na **směr a velikost vztahu**. Ani dobře vypadající lineární vztah ale automaticky neznamená **kauzální vztah**: z modelu zatím čteme pouze **asociaci mezi proměnnými**.

12.1 Odhadnuté délky a graf modelu

Odhadnuté délky pro všechny květy vypočítáme pomocí `predict()`:

```
odhadnuta_delka <-
  predict(
    object = mod_listky,
    newdata = data_kosatce
  )

# Zkontrolujeme prvních šest odhadnutých délek
head(odhadnuta_delka)
```

1	2	3	4	5	6
1.529546	1.529546	1.529546	1.529546	1.529546	1.975534


Pak zobrazíme naměřené hodnoty a přímku odhadnutou modelem:

Tímto krokem uzavíráme logický kruh výzkumné otázky:

- ruční výpočet na 4 konkrétních květech
- stejný princip aplikovaný na celý dataset přes `predict()`
- vizuální kontrola, že přímka opravdu odpovídá číslům z modelu

```
data_model <-
  data.frame(
    # Původní naměřené hodnoty
    sirka_listku = data_kosatce$sirka_listku,
    delka_listku = data_kosatce$delka_listku,
    # Délky odhadnuté stejným modelem
    odhadnuta_delka = predict(
      object = mod_listky,
      newdata = data_kosatce
    )
  )

# Body jsou naměřené květy; čára spojuje odhady modelu
ggplot2::ggplot(
  data = data_model,
  mapping = ggplot2::aes(x = sirka_listku, y = delka_listku)
) +
  ggplot2::geom_point(size = 2, alpha = 0.75, color = "#8A8A8A") +
  ggplot2::geom_line(
    ggplot2::aes(y = odhadnuta_delka),
    color = "#5D2890",
    linewidth = 1
  ) +
  ggplot2::labs(
    x = "Šířka korunního lístku (cm)",
    y = "Délka korunního lístku (cm)"
  ) +
  ggplot2::theme_bw(base_size = 18)
```




Doplňující: kratší alternativa pomocí `geom_smooth()`

Balíček `{ggplot2}` umí lineární model odhadnout a nakreslit přímo pomocí `geom_smooth(method = "lm")`. Tuto zkratku používejte hlavně pro **první rychlou vizualizaci vztahu**. Vrstva sice model interně odhadne, ale nevytvoří snadno dostupný objekt modelu, ze kterého bychom mohli získat koeficienty, residua nebo další výsledky. Pro vlastní analýzu proto model fitujeme zvlášť pomocí `lm()` a uložíme jej do objektu. Argument `se = FALSE` zde vypíná zobrazení pásu nejistoty, ke kterému se vrátíme v další lekci.

```
ggplot2::ggplot(
  # Použijeme původní měření šířky a délky
  data = data_kosatce,
  mapping = ggplot2::aes(x = sirka_listku, y = delka_listku)
) +
  ggplot2::geom_point(
    size = 2,
    alpha = 0.75,
    color = "#8A8A8A"
  ) +
  ggplot2::geom_smooth(
    # Funkce odhadne lineární model a rovnou nakreslí jeho přímku
    method = "lm",
    se = FALSE,
    color = "#5D2890"
  ) +
  ggplot2::labs(
    x = "Šířka korunního lístku (cm)",
    y = "Délka korunního lístku (cm)"
  )
```

```
) +  
ggplot2::theme_bw(base_size = 18)
```



13 Residua v R a jejich první grafická kontrola

Residua jsou uložena přímo v objektu modelu. Získáme je funkcí `resid()` a uložíme do vektoru, se kterým můžeme dále pracovat:

```
vec_rezidua <-  
  # resid() vrátí residuum pro každý květ použitý při fitování  
  resid(mod_listky)  
  
# Zkontrolujeme prvních šest residuí  
head(vec_rezidua)
```


```
      1      2      3      4      5      6  
-0.12954613 -0.12954613 -0.22954613 -0.02954613 -0.12954613 -0.27553423
```

Kladné residuum znamená, že naměřená délka leží nad odhadem modelu. **Záporné residuum** znamená, že naměřená délka leží pod odhadem modelu.

13.1 Nejdříve známý graf: histogram residuí

Histogram už znáte z předchozích lekcí. Tentokrát na vodorovné ose nejsou původní délky lístků, ale rozdíly mezi naměřenou a odhadnutou délkou:

```
hist(  
  # Histogram ukazuje rozdělení residuí  
  x = vec_rezidua,  
  breaks = 12,  
  main = "Histogram residuí",  
  xlab = "Residuum (cm)",  
  ylab = "Četnost",  
  col = "#D9D9D9",  
  border = "white",  
  cex.axis = 1.4,  
  cex.lab = 1.4,  
  cex.main = 1.4  
)  
  
abline(  
  # Svislá čára označí nulové residuum  
  v = 0,  
  lty = 2,  
  col = "#5D2890"  
)
```



Prerušovaná čára označuje **nulové residuum**, tedy přesnou shodu naměřené a odhadnuté délky. Histogram ukazuje, **která residua jsou častá** a zda některé květy leží od odhadu neobvykle daleko. Neříká ale, **u kterých odhadnutých délek** tato residua vznikají.

13.2 Odhadnuté délky vs. residua

Proto ke každému květu spojíme odhadnutou délku z `fitted()` s jeho residuem z `resid()`:

```
vec_odhadnuta_delka <-  
  # fitted() vrátí odhadnutou délku každého květu  
  fitted(mod_listky)  
  
data_rezidua <-  
  data.frame(  
    odhadnuta_delka = vec_odhadnuta_delka,  
    reziduum = vec_rezidua  
  )  
  
# Zkontrolujeme, že každý odhad má odpovídající residuum  
head(data_rezidua)
```

```
  odhadnuta_delka  reziduum  
1      1.529546 -0.12954613
```


```
2      1.529546 -0.12954613
3      1.529546 -0.22954613
4      1.529546 -0.02954613
5      1.529546 -0.12954613
6      1.975534 -0.27553423
```

Stejný graf si ukážeme nejprve pomocí základních funkcí R a potom pomocí balíčku `{ggplot2}`.

13.3 Základní graf v R

```
plot(
  # Každý bod spojuje odhad modelu s residuem stejného květu
  x = data_rezidua$odhadnuta_delka,
  y = data_rezidua$residuum,
  xlab = "Odhadnutá délka (cm)",
  ylab = "Residuum (cm)",
  main = "Odhadnuté délky vs. residua",
  pch = 16,
  col = "#8A8A8A",
  cex = 1.3,
  cex.axis = 1.4,
  cex.lab = 1.4,
  cex.main = 1.4
)


abline(
  # V dobře padnoucím modelu hledáme body rozptýlené kolem nuly
  h = 0,
  lty = 2,
  col = "#5D2890"
)
```



13.4 Graf pomocí {ggplot2}

```
ggplot2::ggplot(
  # Stejná data jako v předchozím grafu v základním R
  data = data_rezidua,
  mapping = ggplot2::aes(x = odhadnuta_delka, y = reziduum)
) +
  ggplot2::geom_hline(
    # Referenční čára ukazuje nulové residuum
    yintercept = 0,
    linetype = 2,
    color = "#5D2890"
  ) +
  ggplot2::geom_point(
    size = 2,
    alpha = 0.8,
    color = "#8A8A8A"
  ) +
  ggplot2::labs(
    x = "Odhadnutá délka (cm)",
    y = "Residuum (cm)",
    title = "Odhadnuté délky vs. residua"
```

```
) +  
ggplot2::theme_bw(base_size = 18)
```



Jak tento graf číst:

- **každý bod** představuje jeden květ
- **vodorovná poloha** ukazuje délku odhadnutou modelem
- **svislá poloha** ukazuje rozdíl mezi naměřenou a odhadnutou délkou
- **bod na nulové čáře** má naměřenou délku přesně rovnou odhadu
- **bod nad nulou** model podhodnotil, **bod pod nulou** model nadhodnotil

Pro první kontrolu stačí jednoduchá otázka: *tvoří body kolem nuly neuspořádaný mrak, nebo v nich zůstává viditelný vzor?* **Viditelný vzor** znamená, že model v datech něco systematicky nezachytil.

14 Co musí být rozumné, aby lineární model odpovídal na naši otázku?


Lineární model je zjednodušený popis dat. Nemusí být dokonale pravdivý, ale jeho zjednodušení nesmí být v přímém rozporu s otázkou a daty. U jednoduchého modelu sledujeme čtyři odlišné oblasti:

1. **Tvar vztahu:** průměrná délka by se v pozorovaném rozsahu šířek měla měnit přibližně po přímce. Zřetelný oblouk v residuích by upozornil, že lineární tvar nestačí.

2. **Rozptýlení kolem přímky:** svislý rozptyl residuí by se neměl systematicky zvětšovat nebo zmenšovat. Trychtýřovitý tvar by znamenal, že model zachází se všemi částmi vztahu jako se stejně proměnlivými, přestože data tak nevypadají.
3. **Tvar residuí:** aby pozdější standardní chyby, intervaly a testy přiměřeně zachycovaly nejistotu, nesmí tvar residuí ukazovat silný rozpor s použitým modelem. Několik drobných odchylek od ideálního tvaru je v reálných datech běžných.
4. **Nezávislá informace:** zda jsou pozorování nezávislá, vyplývá především ze způsobu získání dat. Graf residuí sám nepozná, že několik měření pochází ze stejného jedince, lokality nebo časové řady.

14.1 Čtyři otázky, čtyři různé stopy v grafu

Následující schémata nejsou další čtyři datasety ani automatický test. Jsou to čtyři záměrně zjednodušené obrazy, které pomáhají pojmenovat, na jaký druh problému se díváme.




Obrázek 1: Schématické stopy v grafech residuí. Vodorovná čárkovaná čára označuje nulové residuum; spodní pravý panel jako jediný používá na vodorovné ose pořadí měření.

Vlevo nahoře nevidíme nápadný rozpor, ale ani tento obraz správnost modelu nedokazuje. Oblouk upozorňuje na tvar vztahu, trychtýř na měnící se rozptýlení. Dlouhé běhy nad a pod nulou se

ukážou teprve tehdy, když zachováme pořadí měření; nezávislost proto posuzujeme společně s informací o tom, jak data vznikla.

14.2 Odezva a residua mohou mít jiný tvar

U kosatců můžeme porovnat dvě skutečná rozdělení. Levý histogram popisuje naměřené délky korunních lístků. Pravý histogram popisuje odchylky těchto délek od hodnot odhadnutých přímkou.



Obrázek 2: Naměřená odezva a residua stejného modelu odpovídají na jiné otázky, a proto jejich rozdělení nemusí mít stejný tvar. Vodorovné osy panelů mají odlišný rozsah.

Histogram odezvy se ptá, jaké délky jsme naměřili. Histogram residuí se ptá, jak se skutečné délky liší od přímky při dané šířce. Ani jeden histogram sám neposoudí linearitu, měnící se rozptýlení nebo nezávislost; k tomu potřebujeme předchozí grafy a znalost uspořádání studie.

Diagnostika proto není zkouška, kterou model jednou provždy „udělá“ nebo „neudělá“. Spojuje grafy, znalost uspořádání studie a otázku, zda případný problém může změnit biologický závěr. V této lekci problémy pouze rozpoznáváme; jejich řešení přijdou postupně v dalších lekcích.

Doplňující: předpoklady se týkají residuí kolem modelu

Lineární model nevyžaduje, aby samotná šířka nebo délka korunních lístků měla dokonale normální rozdělení. Důležité je, jak se chovají odchylky délky od hodnot očekávaných při dané šířce. Proto diagnostikujeme residua kolem přímky, nikoli pouze histogram původní odezvy.

Ani residua nemusí vytvořit dokonalou zvonovitou křivku. U malého souboru lze tvar posoudit jen hrubě; u velkého souboru zase i nepatrná odchylka může vypadat „statisticky zjistitelně“. Smyslem kontroly je hledat odchylku natolik výraznou, že zpochybňuje použitý model nebo jeho nejistotu, nikoli získat mechanické razítko správnosti.

Doplňující: odlehlý, krajní a vlivný bod nejsou totéž

Odehlé pozorování má neobvykle velkou odchylku od toho, co jsme čekali. **Krajní bod** má neobvyklou hodnotu prediktoru, například mimo většinu pozorovaných šířek. **Vlivný bod** je takový, jehož přítomnost výrazně mění odhadnutý intercept nebo sklon.


Jeden květ může splňovat jednu, dvě nebo všechny tři vlastnosti. Žádná z nich sama neznámá chybu ani povolení řádek smazat. Nejdříve ověříme měření a biologický kontext, potom zkusíme citlivost závěru. Formální míru vlivu si ukážeme až u modelu s více prediktory.

15 Co model nevidí: druhy kosatců

Dosud jsme všechny květy zobrazovali stejně a druh kosatce jsme do modelu nezahrnuli. Nyní použijeme barvu pouze jako pomůcku, abychom zjistili, zda se jednotlivé druhy v datech chovají podobně.

15.1 Nejprve obarvíme původní data


Stejně barvy použijeme pro každý druh v obou následujících grafech:



Barvy ukazují, že **tři druhy netvoří jeden společný bodový mrak**. Jedna přímka vedená přes všechny květy proto shrnuje nejen vztah šířky a délky, ale také **rozdíly mezi druhy**.

15.2 Potom obarvíme graf odhadnutých délek a residuí

Ke každému residuu nyní doplníme druh stejného květu:



Po obarvení vidíme, že residua jednotlivých druhů **neleží kolem nuly úplně stejně**. Model některé druhy častěji **nadhodnocuje** a jiné častěji **podhodnocuje**. Informace o druhu tedy zůstala v části dat, kterou jednoduchý model nevysvětlil.

V této lekci stačí toto omezení rozpoznat a popsat. Druh jako další prediktor přidáme do modelu až v některé z navazujících lekcí.

16 Co budeme řešit v dalších lekcích

Jednoduchý lineární model je výborný začátek, ale ne univerzální řešení. V této lekci jsme odhalili jeden důvod k opatrnosti: v residuích zůstaly rozdíly mezi druhy kosatců.

V dalších lekcích se naučíme rozlišovat také jiné viditelné vzory:

- zakřivený průběh může ukazovat na nelinearitu
- postupné rozšiřování nebo zužování bodového mraku souvisí s pojmem heteroskedasticita
- jednotlivé body daleko od ostatních mohou být odlehlá pozorování
- barevně oddělené skupiny mohou upozornit na důležitý prediktor, který v modelu chybí

Tyto pojmy teď nemusíte umět diagnostikovat ani řešit. Později podle biologické otázky zvážíme další prediktor, transformaci, jiný tvar vztahu nebo jiný model.

Hlavní princip zůstává stejný: nejprve omezení modelu transparentně pojmenujeme a teprve potom volíme vhodné rozšíření.

V následující lekci ponecháme stejný modelový rámec a přidáme první inferenční vrstvu: výběrovou variabilitu a intervaly spolehlivosti jako vyjádření nejistoty odhadu. Testování hypotéz a p-hodnota přijdou až v pozdější lekci.

17 Shrnutí

- Lineární model zavádí hlavní rámec: biologická otázka → graf → model → interpretace → diagnostika.
- Koeficient sklonu popisuje, o kolik se v průměru změní délka korunního lístku při zvýšení jeho šířky o 1 cm.
- Rezidua nejsou „odpad“, ale klíčová informace o tom, co model nevysvětluje.
- Nejlepší přímka minimalizuje součet čtverců residuí; funkce `lm()` ji najde a vrátí její intercept a sklon.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice. Úplný průběžně aktualizovaný slovníček je dostupný také [online](#).

Interaktivní slovníček je dostupný online: <https://cuni-natur-biostatistics.github.io/slovník/>