

Lineární model s jedním numerickým prediktorem

Podkladové čtenářské materiály k přednášce

4. října 2026

Obsah

1 Úvod	2
2 Výsledky učení	2
3 Data a modelová otázka	2
3.1 Nejdřív jen květy jako data	4
4 Šířka korunního lístku	4
5 Délka korunního lístku	5
6 Rychlý a jednoduchý bodový graf	6
7 Graf pomocí {ggplot2}	6
7.1 Přes stejná data květů můžeme vést mnoho přímek	7
8 Jak popíšeme libovolnou přímku?	8
9 Intercept (a): posun přímky nahoru/dolů	9
10 Sklon (b): změna strmosti přímky	9
11 Od přímky k odhadnuté délce a residuu	10
11.1 Vybereme 4 květy napříč prostorem dat	10
11.2 Výpočet rezidua pro jeden květ	12
11.3 Výpočet rezidua pro všechny 4 květy	13
11.4 Jak kvantifikujeme „kvalitu“ přímky: SSE	14
11.5 Od našich dat k obecnému zápisu modelu	15
11.6 Sklon jako změna odhadnuté délky	17
12 Jak nejlepší přímku najdeme v R	17
12.1 Odhadnuté délky a graf modelu	18
13 Residua v R a jejich první grafická kontrola	21
13.1 Nejdříve známý graf: histogram residuí	22
13.2 Odhadnuté délky vs. residua	23
13.3 Základní graf v R	24
13.4 Graf pomocí {ggplot2}	25
14 Co musí být rozumné, aby lineární model odpovídal na naši otázku?	26
14.1 Čtyři otázky, čtyři různé stopy v grafu	27
14.2 Odezva a residua mohou mít jiný tvar	28
14.2.a Základní graf v R	29
14.2.b Graf pomocí {ggplot2}	30
14.2.c Základní graf v R	33

14.2.d Graf pomocí {ggplot2}	34
14.2.e Základní graf v R	36
14.2.f Graf pomocí {ggplot2}	37
15 Co model nevidí: druhy kosatců	40
15.1 Nejprve obarvíme původní data	40
15.2 Potom obarvíme graf odhadnutých délek a residuí	41
16 Co budeme řešit v dalších lekcích	42
17 Shrnutí	43
Slovníček pojmů	43

1 Úvod

Představte si, že měříte korunní lístky kosatců. Dá se z jejich šířky odhadnout jejich délka?

Hlavní otázka této lekce

Mají širší korunní lístky kosatců také větší délku, a pokud ano, jak velká je tato změna?

Na tuhle otázku dnes navážeme. V minulé části jsme se naučili dívat na body v grafu a číst z nich jednoduchý trend. Teď tento trend rozšíříme do lineárního modelu, aby z bodů vznikl model, který umí vztah mezi šířkou a délkou korunního lístku shrnout jedním zápisem a jednou interpretací.

Cíl není „umět kliknout na funkci“, ale **převést biologickou otázku na modelový zápis a smysluplně interpretovat odhadnutý efekt.**

Pracovní otázka: Jak se mění odezva (délka korunního lístku) s rostoucím prediktorem (šířka korunního lístku)?

2 Výsledky učení

Po prostudování této lekce budete schopni:

- převést biologickou otázku na modelovou otázku s odezvou a prediktorem
- fitovat model $\text{lm}(y \sim x)$ a interpretovat směr i velikost efektu
- vysvětlit, co je residuum, a proč je důležité pro kontrolu modelu
- popsat základní diagnostický graf a rozpoznat v něm možné problémy

3 Data a modelová otázka

Pro první modelovou lekci používáme dataset `iris`, který obsahuje reálná měření 150 květů kosatců. Budeme vysvětlovat vztah mezi šířkou (`Petal.Width`) a délkou (`Petal.Length`) korunního lístku. Data sesbíral botanik Edgar Anderson a později je publikoval Ronald Fisher. Podrobnosti a odkazy na původní publikace uvádí [dokumentace datasetu v R](#).

Dataset rozlišuje tři druhy kosatců. V prvním modelu použijeme záměrně **jen jeden numerický** prediktor a **druh zatím do modelu nepřidáme**. Na konci se k tomuto rozhodnutí vrátíme při diagnostice.

Doplňující: proč dataset iris?

- měří biologicky srozumitelné veličiny ve stejných jednotkách
- obsahuje přirozenou variabilitu mezi květy
- hodnoty šířky začínají blízko nuly, takže intercept můžeme ukázat bez stlačení dat do malé části grafu
- umožňuje plynulý přechod od bodového grafu k lineárnímu modelu

Doplňující: příprava dat

Tento blok připravuje české názvy sloupců pro další výklad. Pro pochopení lineárního modelu jej můžete přeskočit; důležité je vědět, že každý řádek objektu `data_kosatce` představuje jeden květ.

```
# Načteme ukázkový dataset, který je součástí R
data(iris)

# Vybereme tři potřebné sloupce a dáme jim srozumitelné názvy
data_kosatce <-
  data.frame(
    sirka_listku = iris$Petal.Width,
    delka_listku = iris$Petal.Length,
    druh = iris$Species
  )

# Zkontrolujeme rozsah a typ hodnot v připravených datech
summary(data_kosatce)
```

	sirka_listku	delka_listku	druh
Min.	:0.100	Min. :1.000	setosa :50
1st Qu.	:0.300	1st Qu.:1.600	versicolor:50
Median	:1.300	Median :4.350	virginica :50
Mean	:1.199	Mean :3.758	
3rd Qu.	:1.800	3rd Qu.:5.100	
Max.	:2.500	Max. :6.900	

Co konkrétně znamenají sloupce v `iris`:

- `Petal.Width`: šířka korunního lístku v centimetrech (prediktor)

- **Petal.Length**: délka korunního lístku v centimetrech (odezva)
- **Species**: druh kosatce, který zatím ponecháme mimo model

Na úrovni biologické otázky nás zajímá jednoduché tvrzení: mají širší korunní lístky také větší délku, a pokud ano, jak velká je tato změna.

3.1 Nejdřív jen květy jako data

Než budeme mluvit o modelu, podívejme se na jednotlivé květy a na strukturu dat.

Z předchozích lekcí už víme dvě základní věci:

- obě proměnné jsou numerické, tedy měřené na číselné škále
- každou proměnnou můžeme nejdřív shrnout samostatně, než se podíváme na jejich vztah


Základní shrnutí jednotlivých proměnných si můžete otevřít jako krátké zopakování. Pro dnešní otázku ale bude nejdůležitější jejich vzájemný vztah.

Doplňující: zopakování každé proměnné samostatně

4 Šířka korunního lístku

```
# Zkontrolujeme polohu a rozptyl šířek korunních lístků
summary(data_kosatce$sirka_listku)
```


Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.100	0.300	1.300	1.199	1.800	2.500



5 Délka korunního lístku

```
# Zkontrolujeme polohu a rozptyl délek korunních lístků  
summary(data_kosatce$delka_listku)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1.000	1.600	4.350	3.758	5.100	6.900



Než vybereme graf, zkusme si malý mentální úkol: když máme dvě numerické proměnné, jaký typ grafu dává největší smysl?

Odpověď: pro dvě měření použijeme bodový graf

Dobrá volba je bodový graf, protože chceme vidět jednotlivé květy a vztah mezi dvěma měřeními.

V našem případě je prediktorem **šířka korunního lístku** a podle ní vysvětlujeme rozdíly v **délce korunního lístku**.


Co z grafu sledujte zejména:

- **směr vztahu:** zda se s rostoucí šířkou obvykle zvětšuje i délka
- **neobvyklé květy:** jestli jsou v datech květy, které se chovají výrazně jinak než ostatní
- **rozptýlení kolem trendu:** jak velký je rozptyl hodnot kolem hlavního trendu

6 Rychlý a jednoduchý bodový graf

```
plot(  
  # Každý květ vytvoří jeden bod se dvěma naměřenými souřadnicemi  
  x = data_kosatce$sirka_listku,  
  y = data_kosatce$delka_listku,  
  # Popisky vysvětlují význam a jednotky obou os  
  xlab = "Šířka korunního lístku (cm)",  
  ylab = "Délka korunního lístku (cm)",  
  main = "Bodový graf šířky a délky korunního lístku",  
  pch = 16,  
  col = "#8A8A8A",  
  cex = 1.4,  
  cex.axis = 1.5,  
  cex.lab = 1.5,  
  cex.main = 1.5  
)
```

Bodový graf šířky a délky korunního lístku




7 Graf pomocí {ggplot2}

```
ggplot2::ggplot(  
  # Data určují řádky; aes() přiřadí sloupce k osám
```

```

data = data_kosatce,
mapping = ggplot2::aes(x = sirka_listku, y = delka_listku)
) +
# Jeden řádek dat se zobrazí jako jeden bod
ggplot2::geom_point(size = 2, alpha = 0.8, color = "#8A8A8A") +
# Popíšeme osy i celý graf
ggplot2::labs(
  x = "Šířka korunního lístku (cm)",
  y = "Délka korunního lístku (cm)",
  title = "Bodový graf šířky a délky korunního lístku"
) +
ggplot2::theme_bw(base_size = 18)

```




7.1 Přes stejná data květů můžeme vést mnoho přímek

V celé lekci budeme držet tuto interpretační větu:

„Když porovnáme dva květy, model pro květ se širším korunním lístkem odhaduje v průměru delší korunní lístek. Velikost tohoto rozdílu popisuje sklon přímky.“

Pro stejná data existuje **více kandidátních přímek** a každá vede k **trochu jiné interpretaci**. Každá přímka má přitom jiné parametry (viz níže).



Než rozhodneme, která přímka vystihuje data nejlépe, potřebujeme umět libovolnou přímku jednoznačně popsat.

8 Jak popíšeme libovolnou přímku?

Každou přímku popíšeme dvěma parametry:


- **a**: intercept (anglicky *intercept*; česky také **průsečík**)
- **b**: sklon (anglicky *slope*; česky také **regresní koeficient**)

Intuitivně:


- **a posouvá přímku nahoru nebo dolů** (mění základní úroveň odhadnuté délky)
- **b mění strmost přímky**, tedy jak rychle roste odhadnutá délka s rostoucí šířkou

Nejčastější studentská chyba je zaměnit tyto role. Proto je v následujících grafech oddělujeme: nejprve měníme intercept při stejném sklonu, potom sklon při pevném interceptu.


9 Intercept (a): posun přímky nahoru/dolů



10 Sklon (b): změna strmosti přímky



Jak vypadají kombinace **a** a **b** dohromady, si ukážeme v obrázku.



Teď už umíme každou kandidátní přímku popsat. Jak ale poznáme, která z nich nejlépe vystihuje vztah mezi šířkou a délkou korunního lístku?

Kritérium pro výběr přímky musí využít residua

Potřebujeme kritérium, které využije vzdálenosti naměřených délek od přímky při dané šířce. Nejprve proto musíme pochopit odhadnuté délky a residua.

11 Od přímky k odhadnuté délce a residuu

11.1 Vybereme 4 květy napříč prostorem dat

Než porovnáme kandidátní přímky ve všech datech, ukážeme princip na čtyřech květech rozptřených napříč grafem.

Doplňující: výběr čtyř řádků

Tento technický krok pouze vybírá malý, přehledný příklad. Číslo řádků nejsou součástí statistické metody a pro pochopení dalšího výpočtu je nemusíte znát.

```
# Vybereme čtyři květy a ponecháme jen dvě modelované proměnné
data4 <-
  data_kosatce[
    c(1, 58, 71, 101),
    c("sirka_listku", "delka_listku")
  ]

# Zobrazíme malou tabulku, se kterou budeme počítat ručně
data4
```

	sirka_listku	delka_listku
1	0.2	1.4
58	1.0	3.3
71	1.8	4.8
101	2.5	6.0


Konkrétní kandidátní přímka

Jako konkrétní příklad použijeme přímku (**B**) s interceptem $a = 1.1$ a sklonem $b = 2.2$.

Reziduum je **svislá vzdálenost bodu od modelové přímky**. Pokud je **kladné**, model délku podhodnocuje; pokud **záporné**, délku nadhodnocuje.

Rezidua přitom **očekáváme i u užitečného modelu**. Jednotlivé organismy se v důsledku přirozené biologické variability liší, takže žádná jednoduchá přímka nepopíše každý květ přesně. **Samotná existence reziduí proto neznamena, že je model špatný.**

V grafu níže je to vidět přímo jako zlaté úsečky mezi šedými body a fialovou přímkou.



11.2 Výpočet rezidua pro jeden květ

Nejdřív pro jeden květ ručně (dosazení konkrétních hodnot):

Logický postup pro jeden konkrétní květ:

1. Vezmeme **šířku** vybraného korunního lístku.
2. Dosadíme ji do vztahu **odhadnutá délka = intercept + sklon × šířka**.
3. Vypočítáme odhadnutou délku tohoto korunního lístku podle zvolené přímky.

Nejprve vztah zapíšeme pouze názvy veličin z našich dat. Hodnoty prvního květu dosadíme až v dalším kroku. Jeho šířka 0.2 cm určuje **vodorovnou polohu prvního šedého bodu** v grafu výše. Intercept 1.1 a sklon 2.2 popisují **fialovou přímku**:

$$\begin{aligned} \text{odhadnutá délka prvního korunního lístku} &= \text{intercept} \\ &+ \text{sklon} \cdot \text{šířka prvního korunního lístku} . \end{aligned}$$

Teprve potom dosadíme hodnoty prvního květu:

$$\begin{aligned} \text{odhadnutá délka}_1 &= \text{intercept} + \text{sklon} \cdot \text{šířka}_1 \\ &= 1.1 + 2.2 \cdot 0.2 \\ &= 1.1 + 0.44 \\ &= 1.54 \text{ cm} \end{aligned}$$

Výsledek 1.54 cm je v grafu výše **výška fialové přímky** při šířce 0.2 cm — tedy **horní konec první zlaté úsečky**. Naměřená délka 1.4 cm je naopak **výška prvního šedého bodu**. Residuum proto nejprve zapíšeme pouze pomocí názvů veličin:

$$\begin{aligned} \text{residuum prvního korunního lístku} &= \text{naměřená délka prvního korunního lístku} \\ &- \text{odhadnutá délka prvního korunního lístku} . \end{aligned}$$

Teprve potom dosadíme hodnoty odečtené z bodu a přímky:

$$\begin{aligned}
 \text{residuum}_1 &= \text{naměřená délka}_1 - \text{odhadnutá délka}_1 \\
 &= 1.4 - 1.54 \\
 &= -0.14 \text{ cm}
 \end{aligned}$$

Hodnota -0.14 cm odpovídá **první zlaté úsečce**. Samotná úsečka má délku 0.14 cm; **záporné znaménko residua** říká, že šedý bod leží pod fialovou přímkou.

```

a0 <- 1.1
b0 <- 2.2

# Dosadíme šířku prvního květu do rovnice zvolené přímky
odhadnuta_delka_1 <-
  a0 + b0 * data4$sirka_listku[1]

odhadnuta_delka_1

```

```
[1] 1.54
```

11.3 Výpočet rezidua pro všechny 4 květy

Jakmile máme princip pro jeden květ, aplikujeme stejný výpočet na všechny čtyři květy. Tím získáme:

- odhadnuté délky jednotlivých květů
- rozdíl mezi naměřenou a odhadnutou délkou (residua)

```

odhadnuta_delka <-
  a0 + b0 * data4$sirka_listku

# Residuum je naměřená hodnota minus odhad přímky
residuum <-
  data4$delka_listku - odhadnuta_delka

tab_pred <-
  data.frame(
    bod = 1:4,
    sirka = data4$sirka_listku,
    namerena_delka = data4$delka_listku,
    odhadnuta_delka = round(odhadnuta_delka, 2),
    residuum = round(residuum, 2)
  )

# Zobrazíme měření, odhad i residuum vedle sebe
tab_pred

```

	bod	sirka	namerena_delka	odhadnuta_delka	residuum
1	1	0.2	1.4	1.54	-0.14
2	2	1.0	3.3	3.30	0.00
3	3	1.8	4.8	5.06	-0.26
4	4	2.5	6.0	6.60	-0.60

Čtení tabulky krok za krokem:

- sloupec **sirka**: šířka korunního lístku konkrétního květu
- sloupec **namerena_delka**: skutečně naměřená délka korunního lístku
- sloupec **odhadnuta_delka**: délka odhadnutá pomocí přímky B
- sloupec **residuum**: rozdíl mezi naměřenou a odhadnutou délkou

Teprve teď, když jsme stejný výpočet viděli pro všechny čtyři květy, zavedeme obecné symboly. Naměřenou hodnotu označíme y_i , šířku x_i , odhadnutou hodnotu $\hat{y}_i$, intercept a , sklon b a **residuum** (anglicky *residual*) e_i .

$$\hat{y}_i = a + b \cdot x_i$$

$$e_i = y_i - \hat{y}_i$$

V prvním vzorci je $\hat{y}_i$ odhadnutá délka jednoho lístku, x_i jeho naměřená šířka, a intercept a b sklon. Ve druhém vzorci je y_i skutečně naměřená délka a e_i rozdíl mezi měřením a odhadem.

11.4 Jak kvantifikujeme „kvalitu“ přímky: SSE

Součet čtverců residuí (anglicky *sum of squared errors* nebo *residual sum of squares*, zkratka **SSE**) říká, jak moc jsou body daleko od modelové přímky. **Čím menší SSE, tím lépe přímka vystihuje data.**

Proč čtverce? Protože:

- **odstraní znaménko** (kladná a záporná rezidua se neodečtou)
- **více penalizují velké chyby**
- **dávají jedno srovnatelné číslo** pro každou kandidátní přímku

Tabulka výše obsahuje všechny hodnoty potřebné pro ruční výpočet. Pro přehled ji zobrazíme ještě jednou:

Květ	Šířka	Naměřená délka	Odhadnutá délka	Residuum
1	0.2	1.4	1.54	-0.14
2	1.0	3.3	3.30	0.00
3	1.8	4.8	5.06	-0.26
4	2.5	6.0	6.60	-0.60

Ruční kalkulační zápis pro tuto přímku:

součet čtverců residuí = (residuum prvního květu)² + ... + (residuum posledního květu)².

Teprve potom dosadíme residua z tabulky:

$$SSE = (-0.14)^2 + (0)^2 + (-0.26)^2 + (-0.6)^2 = 0.02 + 0 + 0.07 + 0.36 = 0.45$$

Až potom obecně pro všechna pozorování:

$$SSE = \sum_{i=1}^n e_i^2$$

Zde e_i označuje residuum jednoho květu, e_i^2 jeho čtverec, n počet květů a znak $\sum$ znamená, že čtverce všech residuí sečteme.

Stejný výpočet nyní provedeme pro každou kandidátní přímku a pro všech 150 květů. Výsledkem je jediné srovnatelné číslo pro každou přímku:

Přímka	Intercept	Sklon	SSE
A	0.5	1.8	231.08
B	1.1	2.2	33.98
C	1.7	2.6	214.32

Otázka: Který model nejlépe odpovídá výzkumné otázce o vztahu šířky a délky korunního lístku?

Odpověď: nejlepší přímka má nejmenší SSE

Z nabízených přímek je nejlepší B, protože má nejmenší SSE. Lineární model ale není omezen na tyto tři možnosti: hledá takový intercept a sklon, které SSE minimalizují mezi všemi možnými přímkami.

11.5 Od našich dat k obecnému zápisu modelu

Pro první květ můžeme naměřenou délku rozdělit na délku odhadnutou přímkou a residuum:

$$\begin{aligned} \text{naměřená délka prvního korunního lístku} &= \text{odhadnutá délka prvního korunního lístku} \\ &+ \text{residuum prvního korunního lístku} . \end{aligned}$$

Teprve potom dosadíme hodnoty prvního květu:

$$\begin{aligned} \text{naměřená délka}_1 &= \text{odhadnutá délka}_1 + \text{residuum}_1 \\ &= 1.54 + (-0.14) \\ &= 1.4 \text{ cm} \end{aligned}$$

Stejný vztah nyní zapíšeme pomocí již zavedených obecných symbolů:

$$y_i = \hat{y}_i + e_i = a + b \cdot x_i + e_i$$

Interpretace v biologickém příběhu:

- y_i je naměřená délka jednoho korunního lístku a x_i jeho naměřená šířka
- $\hat{y}_i$ je délka odhadnutá přímkou pro tuto šířku
- **a** (intercept) je odhad délky korunního lístku při nulové šířce; nula leží těsně za rozsahem pozorovaných dat
- **b** (sklon) říká, o kolik se v průměru změní délka korunního lístku při zvýšení jeho šířky o 1 cm
- e_i je nevysvětlená část variability (residuum)

11.6 Sklon jako změna odhadnuté délky

Nejprve ukážeme sklon na zvolené přímce a až poté jeho obecný zápis. Pro výpočet musíme použít dva body ležící na stejné přímce, ne dvě libovolná pozorování z dat:

Bod na přímce	Šířka	Odhadnutá délka
1	0.2	1.54
2	2.5	6.60

Sklon zvolené přímky můžeme z těchto dvou bodů zapsat takto:

$$\text{sklon přímky} = \frac{\text{změna odhadnuté délky korunního lístku}}{\text{změna šířky korunního lístku}}.$$

Teprve potom dosadíme souřadnice dvou bodů na přímce:

$$\text{sklon přímky} = \frac{6.6 - 1.54}{2.5 - 0.2} = \frac{5.06}{2.3} = 2.2$$

Až potom obecně:

$$b = \frac{\Delta \hat{y}}{\Delta x}$$

12 Jak nejlepší přímku najdeme v R

Funkce `lm()` fituje lineární model. Nejprve si její zápis přečteme jako obecnou gramatiku:

```
# Obecný zápis nejprve pojmenuje role proměnných a dat
lm(
  formula = odezva ~ prediktor,
  data = data
)
```

V tomto zápisu jsou odezva, prediktor a `data` zástupné názvy. Znak `~` můžeme číst jako „odezvu vysvětlujeme pomocí prediktoru“.

Pro naši biologickou otázku dosadíme:

- odezva: `delka_listku`
- prediktor: `sirka_listku`
- data: `data_kosatce`

Teprve potom sestavíme konkrétní volání. Tady model jen fitujeme; grafy uděláme až v dalším kroku.

V této části oddělíme dvě operace:

- `lm()` odhadne parametry modelu z dat

- `coef(mod_listky)` vrátí dva parametry, které už znáte z kandidátních přímek

```
mod_listky <-
  lm(
    formula = delka_listku ~ sirka_listku,
    data = data_kosatce
  )

# Zobrazíme odhadnutý intercept a sklon
coef(mod_listky)
```

```
(Intercept) sirka_listku
      1.083558      2.229940
```

Co vidíme za parametry (koeficienty) modelu:

- Intercept odpovídá parametru **a**
- odhad u `sirka_listku` odpovídá sklonu **b**

Odpověď na biologickou otázku

Odhadnutý sklon je 2.23. Při zvýšení šířky korunního lístku o 1 cm proto očekáváme v průměru zvýšení jeho délky o 2.23 cm.

Odhadnutý intercept je 1.08 cm. Popisuje odhadnutou délku při nulové šířce, která leží těsně mimo rozsah pozorovaných dat. V tomto biologickém příběhu je proto důležitější sklon.

Model tak odpovídá na **směr a velikost vztahu**. Ani dobře vypadající lineární vztah ale automaticky neznamená **kauzální vztah**: z modelu zatím čteme pouze **asociaci mezi proměnnými**.

12.1 Odhadnuté délky a graf modelu

Odhadnuté délky pro všechny květy vypočítáme pomocí `predict()`:

```
odhadnuta_delka <-
  predict(
    object = mod_listky,
    newdata = data_kosatce
  )

# Zkontrolujeme prvních šest odhadnutých délek
head(odhadnuta_delka)
```

1	2	3	4	5	6
1.529546	1.529546	1.529546	1.529546	1.529546	1.975534


Pak zobrazíme naměřené hodnoty a přímku odhadnutou modelem:

Tímto krokem uzavíráme logický kruh výzkumné otázky:

- ruční výpočet na 4 konkrétních květech
- stejný princip aplikovaný na celý dataset přes `predict()`
- vizuální kontrola, že přímka opravdu odpovídá číslům z modelu

```
data_model <-
  data.frame(
    # Původní naměřené hodnoty
    sirka_listku = data_kosatce$sirka_listku,
    delka_listku = data_kosatce$delka_listku,
    # Délky odhadnuté stejným modelem
    odhadnuta_delka = predict(
      object = mod_listky,
      newdata = data_kosatce
    )
  )

# Body jsou naměřené květy; čára spojuje odhady modelu
ggplot2::ggplot(
  data = data_model,
  mapping = ggplot2::aes(x = sirka_listku, y = delka_listku)
) +
  ggplot2::geom_point(size = 2, alpha = 0.75, color = "#8A8A8A") +
  ggplot2::geom_line(
    ggplot2::aes(y = odhadnuta_delka),
    color = "#5D2890",
    linewidth = 1
  ) +
  ggplot2::labs(
    x = "Šířka korunního lístku (cm)",
    y = "Délka korunního lístku (cm)"
  ) +
  ggplot2::theme_bw(base_size = 18)
```




Doplňující: kratší alternativa pomocí `geom_smooth()`

Balíček `{ggplot2}` umí lineární model odhadnout a nakreslit přímo pomocí `geom_smooth(method = "lm")`. Tuto zkratku používejte hlavně pro **první rychlou vizualizaci vztahu**. Vrstva sice model interně odhadne, ale nevytvoří snadno dostupný objekt modelu, ze kterého bychom mohli získat koeficienty, residua nebo další výsledky. Pro vlastní analýzu proto model fitujeme zvlášť pomocí `lm()` a uložíme jej do objektu. Argument `se = FALSE` zde vypíná zobrazení pásu nejistoty, ke kterému se vrátíme v další lekci.

```
ggplot2::ggplot(
  # Použijeme původní měření šířky a délky
  data = data_kosatce,
  mapping = ggplot2::aes(x = sirka_listku, y = delka_listku)
) +
  ggplot2::geom_point(
    size = 2,
    alpha = 0.75,
    color = "#8A8A8A"
  ) +
  ggplot2::geom_smooth(
    # Funkce odhadne lineární model a rovnou nakreslí jeho přímku
    method = "lm",
    se = FALSE,
    color = "#5D2890"
  ) +
  ggplot2::labs(
    x = "Šířka korunného lístku (cm)",
    y = "Délka korunného lístku (cm)"
  )
```

```
) +  
ggplot2::theme_bw(base_size = 18)
```



13 Residua v R a jejich první grafická kontrola

Residua jsou uložena přímo v objektu modelu. Získáme je funkcí `resid()` a uložíme do vektoru, se kterým můžeme dále pracovat:

```
vec_rezidua <-  
  # resid() vrátí residuum pro každý květ použitý při fitování  
  resid(mod_listky)  
  
# Zkontrolujeme prvních šest residuí  
head(vec_rezidua)
```


```
      1      2      3      4      5      6  
-0.12954613 -0.12954613 -0.22954613 -0.02954613 -0.12954613 -0.27553423
```

Kladné residuum znamená, že naměřená délka leží nad odhadem modelu. **Záporné residuum** znamená, že naměřená délka leží pod odhadem modelu.

13.1 Nejdříve známý graf: histogram residuí

Histogram už znáte z předchozích lekcí. Tentokrát na vodorovné ose nejsou původní délky lístků, ale rozdíly mezi naměřenou a odhadnutou délkou:

```
hist(  
  # Histogram ukazuje rozdělení residuí  
  x = vec_rezidua,  
  breaks = 12,  
  main = "Histogram residuí",  
  xlab = "Residuum (cm)",  
  ylab = "Četnost",  
  col = "#D9D9D9",  
  border = "white",  
  cex.axis = 1.4,  
  cex.lab = 1.4,  
  cex.main = 1.4  
)  
  
abline(  
  # Svislá čára označí nulové residuum  
  v = 0,  
  lty = 2,  
  col = "#5D2890"  
)
```



Prerušovaná čára označuje **nulové residuum**, tedy přesnou shodu naměřené a odhadnuté délky. Histogram ukazuje, **která residua jsou častá** a zda některé květy leží od odhadu neobvykle daleko. Neříká ale, **u kterých odhadnutých délek** tato residua vznikají.

13.2 Odhadnuté délky vs. residua

Proto ke každému květu spojíme odhadnutou délku z `fitted()` s jeho residuem z `resid()`:

```
vec_odhadnuta_delka <-  
  # fitted() vrátí odhadnutou délku každého květu  
  fitted(mod_listky)  
  
data_rezidua <-  
  data.frame(  
    odhadnuta_delka = vec_odhadnuta_delka,  
    reziduum = vec_rezidua  
  )  
  
# Zkontrolujeme, že každý odhad má odpovídající residuum  
head(data_rezidua)
```

```
  odhadnuta_delka  reziduum  
1      1.529546 -0.12954613
```


```
2      1.529546 -0.12954613
3      1.529546 -0.22954613
4      1.529546 -0.02954613
5      1.529546 -0.12954613
6      1.975534 -0.27553423
```

Stejný graf si ukážeme nejprve pomocí základních funkcí R a potom pomocí balíčku `{ggplot2}`.

13.3 Základní graf v R

```
plot(
  # Každý bod spojuje odhad modelu s residuem stejného květu
  x = data_rezidua$odhadnuta_delka,
  y = data_rezidua$residuum,
  xlab = "Odhadnutá délka (cm)",
  ylab = "Residuum (cm)",
  main = "Odhadnuté délky vs. residua",
  pch = 16,
  col = "#8A8A8A",
  cex = 1.3,
  cex.axis = 1.4,
  cex.lab = 1.4,
  cex.main = 1.4
)


abline(
  # V dobře padnoucím modelu hledáme body rozptýlené kolem nuly
  h = 0,
  lty = 2,
  col = "#5D2890"
)
```



13.4 Graf pomocí {ggplot2}

```
ggplot2::ggplot(
  # Stejná data jako v předchozím grafu v základním R
  data = data_rezidua,
  mapping = ggplot2::aes(x = odhadnuta_delka, y = reziduum)
) +
  ggplot2::geom_hline(
    # Referenční čára ukazuje nulové residuum
    yintercept = 0,
    linetype = 2,
    color = "#5D2890"
  ) +
  ggplot2::geom_point(
    size = 2,
    alpha = 0.8,
    color = "#8A8A8A"
  ) +
  ggplot2::labs(
    x = "Odhadnutá délka (cm)",
    y = "Residuum (cm)",
    title = "Odhadnuté délky vs. residua"
```

```
) +  
ggplot2::theme_bw(base_size = 18)
```



Jak tento graf číst:

- **každý bod** představuje jeden květ
- **vodorovná poloha** ukazuje délku odhadnutou modelem
- **svislá poloha** ukazuje rozdíl mezi naměřenou a odhadnutou délkou
- **bod na nulové čáře** má naměřenou délku přesně rovnou odhadu
- **bod nad nulou** model podhodnotil, **bod pod nulou** model nadhodnotil

Pro první kontrolu stačí jednoduchá otázka: *tvoří body kolem nuly neuspořádaný mrak, nebo v nich zůstává viditelný vzor?* **Viditelný vzor** znamená, že model v datech něco systematicky nezachytil.

14 Co musí být rozumné, aby lineární model odpovídal na naši otázku?


Lineární model je zjednodušený popis dat. Nemusí být dokonale pravdivý, ale jeho zjednodušení nesmí být v přímém rozporu s otázkou a daty. U jednoduchého modelu sledujeme čtyři odlišné oblasti:

1. **Tvar vztahu:** průměrná délka by se v pozorovaném rozsahu šířek měla měnit přibližně po přímce. Zřetelný oblouk v residuích by upozornil, že lineární tvar nestačí.

2. **Rozptýlení kolem přímky:** svislý rozptyl residuí by se neměl systematicky zvětšovat nebo zmenšovat. Trychtýřovitý tvar by znamenal, že model zachází se všemi částmi vztahu jako se stejně proměnlivými, přestože data tak nevypadají.
3. **Tvar residuí:** aby pozdější standardní chyby, intervaly a testy přiměřeně zachycovaly nejistotu, nesmí tvar residuí ukazovat silný rozpor s použitým modelem. Několik drobných odchylek od ideálního tvaru je v reálných datech běžných.
4. **Nezávislá informace:** zda jsou pozorování nezávislá, vyplývá především ze způsobu získání dat. Graf residuí sám nepozná, že několik měření pochází ze stejného jedince, lokality nebo časové řady.

14.1 Čtyři otázky, čtyři různé stopy v grafu

Následující schémata nejsou další čtyři datasety ani automatický test. Jsou to čtyři záměrně zjednodušené obrazy, které pomáhají pojmenovat, na jaký druh problému se díváme.




Obrázek 1: Schématické stopy v grafech residuí. Vodorovná čárkovaná čára označuje nulové residuum; spodní pravý panel jako jediný používá na vodorovné ose pořadí měření.

Vlevo nahoře nevidíme nápadný rozpor, ale ani tento obraz správnost modelu nedokazuje. Oblouk upozorňuje na tvar vztahu, trychtýř na měnící se rozptýlení. Dlouhé běhy nad a pod nulou se

ukážou teprve tehdy, když zachováme pořadí měření; nezávislost proto posuzujeme společně s informací o tom, jak data vznikla.

14.2 Odezva a residua mohou mít jiný tvar

U kosatců můžeme porovnat dvě skutečná rozdělení. Levý histogram popisuje naměřené délky korunních lístků. Pravý histogram popisuje odchylky těchto délek od hodnot odhadnutých přímkou.



Obrázek 2: Naměřená odezva a residua stejného modelu odpovídají na jiné otázky, a proto jejich rozdělení nemusí mít stejný tvar. Vodorovné osy panelů mají odlišný rozsah.

Histogram odezvy se ptá, jaké délky jsme naměřili. Histogram residuí se ptá, jak se skutečné délky liší od přímky při dané šířce. Ani jeden histogram sám neposoudí linearitu, měnící se rozptýlení nebo nezávislost; k tomu potřebujeme předchozí grafy a znalost uspořádání studie.

Diagnostika proto není zkouška, kterou model jednou provždy „udělá“ nebo „neudělá“. Spojuje grafy, znalost uspořádání studie a otázku, zda případný problém může změnit biologický závěr. V této lekci problémy pouze rozpoznáváme; jejich řešení přijdou postupně v dalších lekcích.

Doplňující: předpoklady se týkají residuí kolem modelu

Lineární model nevyžaduje, aby samotná šířka nebo délka korunních lístků měla dokonale normální rozdělení. Důležité je, jak se chovají odchylky délky od hodnot očekávaných při dané šířce. Proto diagnostikujeme residua kolem přímky, nikoli pouze histogram původní odezvy.


Ani residua nemusí vytvořit dokonalou zvonovitou křivku. U malého souboru lze tvar posoudit jen hrubě; u velkého souboru zase i nepatrná odchylka může vypadat „statisticky zjistitelně“. Smyslem kontroly je hledat odchylku natolik výraznou, že zpochybňuje použitý model nebo jeho nejistotu, nikoli získat mechanické razítko správnosti.

Doplňující: Q-Q graf residuí

Tvar histogramu residuí závisí také na tom, kolik sloupců zvolíme. Podrobnější pohled na tvar residuí nabízí **Q-Q graf** (z anglického *quantile-quantile*). Využívá kvantily – obecný název pro percentily a kvantily z první lekce, tedy hodnoty, pod nimiž leží určitý podíl seřazených dat. Residua seřadíme od nejmenšího po největší a každé porovnáme s hodnotou, kterou bychom na stejném místě pořadí čekali u souměrného zvonovitého (normálního) rozdělení.

14.2.a Základní graf v R


```
qqnorm(  
  # Seřazená residua porovnáme s kvantily normálního rozdělení  
  y = vec_rezidua,  
  main = "Q-Q graf residuí",  
  xlab = "Teoretické kvantily normálního rozdělení",  
  ylab = "Residuum (cm)",  
  pch = 16,  
  col = "#8A8A8A",  
  cex = 1.3,  
  cex.axis = 1.4,  
  cex.lab = 1.4,  
  cex.main = 1.4  
)  
  
qqline(  
  # Referenční přímka prochází prvním a třetím kvantilem residuí  
  y = vec_rezidua,  
  lty = 2,  
  lwd = 2,  
  col = "#5D2890"  
)
```



14.2.b Graf pomocí {ggplot2}

```
ggplot2::ggplot(
  # Stejná residua jako v předchozím grafu v základním R
  data = data_rezidua,
  mapping = ggplot2::aes(sample = residuum)
) +
  ggplot2::stat_qq_line(
    # Referenční přímka prochází prvním a třetím kvantilem residuí
    linetype = 2,
    color = "#5D2890"
  ) +
  ggplot2::stat_qq(
    size = 2,
    alpha = 0.8,
    color = "#8A8A8A"
  ) +
  ggplot2::labs(
    x = "Teoretické kvantily normálního rozdělení",
    y = "Residuuum (cm)",
    title = "Q-Q graf residuí"
```

```
) +  
ggplot2::theme_bw(base_size = 18)
```



Jak tento graf číst:

- **každý bod** je residuum jednoho květu; **svislá osa** ukazuje jeho skutečnou hodnotu v cm
- **vodorovná osa** ukazuje, kde by residuum se stejným pořadím leželo u normálního rozdělení, měřeno ve směrodatných odchylkách od středu
- **přerušovaná přímka** ukazuje, kde by body ležely při dokonale zvonovitém tvaru
- **body blízko přímky**: tvar residuí se od zvonovitého rozdělení výrazně neliší
- **oba konce se odklánějí opačnými směry** (vlevo dolů, vpravo nahoru): velkých kladných i záporných residuí je víc, než by odpovídalo zvonovité křivce
- **body tvoří oblouk**: residua jsou nesouměrná, na jedné straně nuly sahají dál než na druhé

U kosatců leží prostřední residua téměř přesně na přímce. Na obou koncích se body mírně odklánějí opačnými směry: několik květů má o něco větší kladná i záporná residua, než by odpovídalo zvonovité křivce. Odchylka se týká hlavně nejkrajnějších bodů a je mírná; sama o sobě proto použití lineárního modelu nezpochybňuje.

Q-Q graf není test, který model „schválí“. I residua vzniklá přesně ze zvonovitého rozdělení se na koncích grafu trochu vlní, zvlášť u malého počtu pozorování. Hledáme proto výraznou a souvislou odchylku, ne každý bod mimo přímku.

Doplňující: odlehlý, krajní a vlivný bod nejsou totéž

Odehlé pozorování má neobvykle velkou odchylku od toho, co jsme čekali. **Krajní bod** má neobvyklou hodnotu prediktoru, například mimo většinu pozorovaných šířek. **Vlivný bod** je takový, jehož přítomnost výrazně mění odhadnutý intercept nebo sklon.

Jeden květ může splňovat jednu, dvě nebo všechny tři vlastnosti. Žádná z nich sama neznamená chybu ani povolení řádek smazat. Nejdříve ověříme měření a biologický kontext, potom zkoumáme citlivost závěru. Jak „krajnost“ a vliv jednotlivých květů změřit, ukazují dva následující doplňující rámečky.

Doplňující: jak „krajní“ je květ – pákový efekt

Pákový efekt (anglicky *leverage*) měří, jak neobvyklou hodnotu prediktoru má jedno pozorování. Přímkou si můžeme představit jako páku: květ, jehož šířka leží daleko od průměrné šířky, ji může naklonit snáz než květ uprostřed rozsahu. V R pákový efekt získáme funkcí `hatvalues()`:


```
vec_pakovy_efekt <-  
  # hatvalues() vrátí pákový efekt pro každý květ  
  hatvalues(model = mod_listky)  
  
# Spojíme měření, residua a pákový efekt jednotlivých květů  
data_vliv_kvetu <-  
  data.frame(  
    sirka_listku = data_kosatce$sirka_listku,  
    delka_listku = data_kosatce$delka_listku,  
    reziduum = vec_rezidua,  
    pakovy_efekt = vec_pakovy_efekt  
  )  
  
# Zkontrolujeme nejmenší a největší pákový efekt  
range(vec_pakovy_efekt)
```

```
[1] 0.006666672 0.026208483
```

Pákový efekt nemá jednotky. S jediným prediktorem závisí pouze na šířce lístku: čím dál je šířka od průměrné šířky, tím je hodnota větší, a to na obě strany. Nejmenší hodnotu proto mají květy se šířkou blízko průměru. Naměřená délka ani residuum na pákový efekt vliv nemají. V následujícím grafu proto vyneseme obě vlastnosti z předchozího rámečku proti sobě: krajnost na vodorovnou osu a odlehlost na svislou.

14.2.c Základní graf v R


```
plot(  
  # Vodorovně krajnost šířky, svisle odchylka od přímky  
  x = data_vliv_kvetu$pakovy_efekt,  
  y = data_vliv_kvetu$reziduum,  
  xlab = "Pákový efekt",  
  ylab = "Residuum (cm)",  
  main = "Pákový efekt vs. residua",  
  pch = 16,  
  col = "#8A8A8A",  
  cex = 1.3,  
  cex.axis = 1.4,  
  cex.lab = 1.4,  
  cex.main = 1.4  
)  
  
abline(  
  # Nulové residuum: naměřená délka je rovna odhadu  
  h = 0,  
  lty = 2,  
  lwd = 2,  
  col = "#5D2890"  
)
```



14.2.d Graf pomocí {ggplot2}

```
ggplot2::ggplot(
  # Stejná data jako v předchozím grafu v základním R
  data = data_vliv_kvetu,
  mapping = ggplot2::aes(x = pakovy_efekt, y = reziduum)
) +
  ggplot2::geom_hline(
    # Nulové residuum: naměřená délka je rovna odhadu
    yintercept = 0,
    linetype = 2,
    color = "#5D2890"
  ) +
  ggplot2::geom_point(
    size = 2,
    alpha = 0.8,
    color = "#8A8A8A"
  ) +
  ggplot2::labs(
    x = "Pákový efekt",
    y = "Residuum (cm)",
    title = "Pákový efekt vs. residua"
```

```
) +  
ggplot2::theme_bw(base_size = 18)
```



Jak tento graf číst:

- **vpravo** leží květy s nejvíce neobvyklou šířkou lístku
- **daleko od nulové čáry** leží květy, jejichž délka se nejvíce liší od odhadu
- body tvoří **svislé sloupce**: mnoho květů má stejnou šířku a stejný pákový efekt mají i květy stejně daleko od průměrné šířky na opačných stranách – velmi úzké i velmi široké lístky

Úplně vpravo leží květy s nejširšími lístky (2.5 cm). Všechny leží pod nulovou čarou: model jejich délku nadhodnocuje. Květ, který je zároveň vpravo a daleko od nuly, může přímku naklonit nejvíce. Právě tuto kombinaci shrnuje Cookova vzdálenost.

Doplňující: Cookova vzdálenost – které květy hýbou přímkou?

Cookova vzdálenost (anglicky *Cook's distance*) spojuje obě vlastnosti z předchozího rámečku do jednoho čísla. Pro každý květ vyjadřuje, jak moc by se změnila odhadnuté délky všech květů, kdybychom právě tento květ vynechali a přímku odhadli znovu. Velkou hodnotu mívá hlavně květ, který má velké residuum a zároveň velký pákový efekt.

```

vec_cookova_vzdalenost <-
  # cooks.distance() vrátí Cookovu vzdálenost pro každý květ
  cooks.distance(model = mod_listky)

# Doplníme Cookovu vzdálenost a pořadí květu v datech
data_vliv_kvetu$cookova_vzdalenost <- vec_cookova_vzdalenost
data_vliv_kvetu$poradi_kvetu <- seq_len(length.out = nrow(x =
data_vliv_kvetu))

# Orientační hodnota 4/n, kde n je počet květů v modelu
hranice_cook <- 4 / nrow(x = data_vliv_kvetu)
hranice_cook

```

```
[1] 0.02666667
```


14.2.e Základní graf v R

```

plot(
  # Každá svislá čárka představuje jeden květ
  x = data_vliv_kvetu$poradi_kvetu,
  y = data_vliv_kvetu$cookova_vzdalenost,
  type = "h",
  lwd = 2,
  col = "#8A8A8A",
  xlab = "Pořadí květu v datech",
  ylab = "Cookova vzdálenost",
  main = "Cookova vzdálenost květů",
  cex.axis = 1.4,
  cex.lab = 1.4,
  cex.main = 1.4
)

abline(
  # Orientační čára, nikoli hranice pro mazání dat
  h = hranice_cook,
  lty = 2,
  lwd = 2,
  col = "#5D2890"
)

```




14.2.f Graf pomocí {ggplot2}

```
ggplot2::ggplot(
  # Stejná data jako v předchozím grafu v základním R
  data = data_vliv_kvetu,
  mapping = ggplot2::aes(x = poradi_kvetu, y = cookova_vzdalenost)
) +
  ggplot2::geom_segment(
    # Každá svislá čárka vede od nuly k hodnotě jednoho květu
    mapping = ggplot2::aes(xend = poradi_kvetu, yend = 0),
    linewidth = 0.8,
    color = "#8A8A8A"
  ) +
  ggplot2::geom_hline(
    # Orientační čára, nikoli hranice pro mazání dat
    yintercept = hranice_cook,
    linetype = 2,
    color = "#5D2890"
  ) +
  ggplot2::labs(
    x = "Pořadí květu v datech",
    y = "Cookova vzdálenost",
```

```

    title = "Cookova vzdálenost květů"
  ) +
  ggplot2::theme_bw(base_size = 18)

```



Nad orientační čarou leží 11 z 150 květů. Hodnota $4/n$ není test ani pravidlo pro mazání dat; pouze upozorňuje, které květy si zaslouží bližší pohled. Seřadíme je od největší Cookovy vzdálenosti:

```

data_vliv_serazene <-
  data_vliv_kvetu[
    # Seřadíme květy od největší Cookovy vzdálenosti
    order(data_vliv_kvetu$cookova_vzdalenost, decreasing = TRUE),
  ]

# Vybereme sloupce, které chceme u květů porovnat
vec_sloupce_tabulky <-
  c(
    "sirka_listku",
    "delka_listku",
    "reziduum",
    "pakovy_efekt",
    "cookova_vzdalenost"
  )

```

```
)

# Zobrazíme pět nejvlivnějších květů se zaokrouhlenými hodnotami;
# čísla vlevo jsou pořadí květů v datech
round(
  x = head(x = data_vliv_serazene[, vec_sloupce_tabulky], n = 5),
  digits = 3
)
```

	sirka_listku	delka_listku	reziduum	pakovy_efekt	cookova_vzdalenost
115	2.4	5.1	-1.335	0.023	0.095
142	2.3	5.1	-1.112	0.021	0.058
145	2.5	5.7	-0.958	0.026	0.056
146	2.3	5.2	-1.012	0.021	0.048
123	2.0	6.7	1.157	0.014	0.042

Nejvlivnější květ má široký lístek (2.4 cm) a jeho naměřená délka leží 1.34 cm pod odhadem přímky. Ke kterým druhům patří květy nad orientační čarou?

```
# Spočítáme druhy květů s Cookovou vzdáleností nad orientační čarou
table(data_kosatce$druh[vec_cookova_vzdalenost > hranice_cook])
```

```
setosa versicolor virginica
      0         0        11
```

Všechny tyto květy patří druhu *virginica*, který má nejširší lístky, a tedy i velký pákový efekt. Model 8 z nich nadhodnocuje a 3 naopak výrazně podhodnocuje. Proč jedna společná přímka pro tři druhy nestačí, ukazuje kapitola *Co model nevidí: druhy kosatců*.

Jak moc nejvlivnější květ přímku skutečně hýbe, zjistíme přímo: odhadneme stejný model bez něj a porovnáme koeficienty.

```
# Najdeme řádek květu s největší Cookovou vzdáleností
radek_nejvlivnejsi <- which.max(x = vec_cookova_vzdalenost)

mod_bez_kvetu <-
  lm(
    # Stejný model odhadneme bez jediného květu
    formula = delka_listku ~ sirka_listku,
    data = data_kosatce[-radek_nejvlivnejsi, ]
  )
```

```

)

# Porovnáme intercept a sklon obou modelů
rbind(
  vsechny_kvety = coef(object = mod_listky),
  bez_nejvlivnejsiho = coef(object = mod_bez_kvetu)
)

```

	(Intercept)	sirka_listku
vsechny_kvety	1.083558	2.229940
bez_nejvlivnejsiho	1.069930	2.248904


Sklon se změnil z 2.23 na 2.25 cm délky na 1 cm šířky. Ani nejvlivnější květ tedy přímku podstatně neposune a závěr o vztahu šířky a délky se nemění. Ani vysoká Cookova vzdálenost ale sama o sobě není důvod řádek smazat. Je to důvod ověřit měření, zvážit biologický kontext a porovnat závěr s květem a bez něj – tak jako zde.

15 Co model nevidí: druhy kosatců

Dosud jsme všechny květy zobrazovali stejně a druh kosatce jsme do modelu nezahrnuli. Nyní použijeme barvu pouze jako pomůcku, abychom zjistili, zda se jednotlivé druhy v datech chovají podobně.

15.1 Nejprve obarvíme původní data


Stejně barvy použijeme pro každý druh v obou následujících grafech:



Barvy ukazují, že **tři druhy netvoří jeden společný bodový mrak**. Jedna přímka vedená přes všechny květy proto shrnuje nejen vztah šířky a délky, ale také **rozdíly mezi druhy**.

15.2 Potom obarvíme graf odhadnutých délek a residuí

Ke každému residuu nyní doplníme druh stejného květu:



Po obarvení vidíme, že residua jednotlivých druhů **neleží kolem nuly úplně stejně**. Model některé druhy častěji **nadhodnocuje** a jiné častěji **podhodnocuje**. Informace o druhu tedy zůstala v části dat, kterou jednoduchý model nevysvětlil.

V této lekci stačí toto omezení rozpoznat a popsat. Druh jako další prediktor přidáme do modelu až v některé z navazujících lekcí.

16 Co budeme řešit v dalších lekcích

Jednoduchý lineární model je výborný začátek, ale ne univerzální řešení. V této lekci jsme odhalili jeden důvod k opatrnosti: v residuích zůstaly rozdíly mezi druhy kosatců.

V dalších lekcích se naučíme rozlišovat také jiné viditelné vzory:

- zakřivený průběh může ukazovat na nelinearitu
- postupné rozšiřování nebo zužování bodového mraku souvisí s pojmem heteroskedasticita
- jednotlivé body daleko od ostatních mohou být odlehlá pozorování
- barevně oddělené skupiny mohou upozornit na důležitý prediktor, který v modelu chybí

Tyto pojmy teď nemusíte umět diagnostikovat ani řešit. Později podle biologické otázky zvážíme další prediktor, transformaci, jiný tvar vztahu nebo jiný model.

Hlavní princip zůstává stejný: nejprve omezení modelu transparentně pojmenujeme a teprve potom volíme vhodné rozšíření.

V následující lekci ponecháme stejný modelový rámec a přidáme první inferenční vrstvu: výběrovou variabilitu a intervaly spolehlivosti jako vyjádření nejistoty odhadu. Testování hypotéz a p-hodnota přijdou až v pozdější lekci.

17 Shrnutí

- Lineární model zavádí hlavní rámec: biologická otázka → graf → model → interpretace → diagnostika.
- Koeficient sklonu popisuje, o kolik se v průměru změní délka korunního lístku při zvýšení jeho šířky o 1 cm.
- Rezidua nejsou „odpad“, ale klíčová informace o tom, co model nevysvětluje.
- Nejlepší přímka minimalizuje součet čtverců residuí; funkce `lm()` ji najde a vrátí její intercept a sklon.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice. Úplný průběžně aktualizovaný slovníček je dostupný také [online](#).

Interaktivní slovníček je dostupný online: <https://cuni-natur-biostatistics.github.io/slovník/>