

Lineární model s jedním kvantitativním prediktorem

Podkladové čtenářské materiály k přednášce

15. července 2026

Obsah

1 Úvod	2
2 Výsledky učení	2
3 Data a modelová otázka	2
3.1 Nejdřív jen květy jako data	3
4 Šířka korunního lístku	5
5 Délka korunního lístku	5
6 Rychlý a jednoduchý bodový graf	6
7 Graf pomocí {ggplot2}	7
7.1 Přes stejná data květů můžeme vést mnoho přímek	8
8 Jak popíšeme libovolnou přímku?	9
9 Intercept (a): posun přímky nahoru/dolů	9
10 Sklon (b): změna strmosti přímky	10
11 Od přímky k odhadnuté délce a residuu	11
11.1 Vybereme 4 květy napříč prostorem dat	11
11.2 Výpočet rezidua pro jeden květ	12
11.3 Výpočet rezidua pro všechny 4 květy	13
11.4 Jak kvantifikujeme „kvalitu“ přímky: SSE	14
11.5 Od našich dat k obecnému zápisu modelu	15
11.6 Sklon jako změna odhadnuté délky	16
12 Jak nejlepší přímku najdeme v R	16
12.1 Odhadnuté délky a graf modelu	17
13 Residua v R a jejich první grafická kontrola	20
13.1 Nejdříve známý graf: histogram residuí	20
13.2 Odhadnuté délky vs. residua	21
13.3 Základní graf v R	22
13.4 Graf pomocí {ggplot2}	23
14 Co model nevidí: druhy kosatců	24
14.1 Nejprve obarvíme původní data	24
14.2 Potom obarvíme graf odhadnutých délek a residuí	25
15 Co budeme řešit v dalších lekcích	26

16 Shrnutí	27
Slovníček pojmů	27

1 Úvod

Představte si, že měříte korunní lístky kosatců. Dá se z jejich šířky odhadnout jejich délka?

! Hlavní otázka této lekce

Mají širší korunní lístky kosatců také větší délku, a pokud ano, jak velká je tato změna?

Na tuhle otázku dnes navážeme. V minulé části jsme se naučili dívat na body v grafu a číst z nich jednoduchý trend. Teď tento trend rozšíříme do lineárního modelu, aby z bodů vznikl model, který umí vztah mezi šířkou a délkou korunního lístku shrnout jedním zápisem a jednou interpretací.

Cíl není „umět kliknout na funkci“, ale **převést biologickou otázku na modelový zápis a smysluplně interpretovat odhadnutý efekt**.

Pracovní otázka: Jak se mění odezva (délka korunního lístku) s rostoucím prediktorem (šířka korunního lístku)?

2 Výsledky učení

Po prostudování této lekce budete schopni:

- převést biologickou otázku na modelovou otázku s odezvou a prediktorem
- fitovat model $\text{lm}(y \sim x)$ a interpretovat směr i velikost efektu
- vysvětlit, co je residuum, a proč je důležité pro kontrolu modelu
- popsat základní diagnostický graf a rozpoznat v něm možné problémy

3 Data a modelová otázka

Pro první modelovou lekci používáme dataset `iris`, který obsahuje reálná měření 150 květů kosatců. Budeme vysvětlovat vztah mezi šířkou (`Petal.Width`) a délkou (`Petal.Length`) korunního lístku. Data sesbíral botanik Edgar Anderson a později je publikoval Ronald Fisher. Podrobnosti a odkazy na původní publikace uvádí [dokumentace datasetu v R](#).

Dataset rozlišuje tři druhy kosatců. V prvním modelu použijeme záměrně **jen jeden numerický prediktor** a **druh zatím do modelu nepřidáme**. Na konci se k tomuto rozhodnutí vrátíme při diagnostice.

i Proč dataset `iris`?

- měří biologicky srozumitelné veličiny ve stejných jednotkách
- obsahuje přirozenou variabilitu mezi květy
- hodnoty šířky začínají blízko nuly, takže intercept můžeme ukázat bez stlačení dat do malé části grafu
- umožňuje plynulý přechod od bodového grafu k lineárnímu modelu

```
data(iris)

data_kosatce <-
  data.frame(
    sirka_listku = iris$Petal.Width,
    delka_listku = iris$Petal.Length,
    druh = iris$Species
  )

summary(data_kosatce)
```

sirka_listku	delka_listku	druh
Min. :0.100	Min. :1.000	setosa :50
1st Qu.:0.300	1st Qu.:1.600	versicolor:50
Median :1.300	Median :4.350	virginica :50
Mean :1.199	Mean :3.758	
3rd Qu.:1.800	3rd Qu.:5.100	
Max. :2.500	Max. :6.900	

Co konkrétně znamenají sloupce v `iris`:

- `Petal.Width`: šířka korunního lístku v centimetrech (prediktor)
- `Petal.Length`: délka korunního lístku v centimetrech (odezva)
- `Species`: druh kosatce, který zatím ponecháme mimo model

Na úrovni biologické otázky nás zajímá jednoduché tvrzení: mají širší korunní lístky také větší délku, a pokud ano, jak velká je tato změna.

3.1 Nejdřív jen květy jako data

Než budeme mluvit o modelu, podívejme se na jednotlivé květy a na strukturu dat.

Z předchozích lekcí už víme dvě základní věci:

- obě proměnné jsou numerické, tedy měřené na číselné škále
- každou proměnnou můžeme nejdřív shrnout samostatně, než se podíváme na jejich vztah


Základní shrnutí jednotlivých proměnných si můžete otevřít jako krátké zopakování. Pro dnešní otázku ale bude nejdůležitější jejich vzájemný vztah.

i Zopakování: každá proměnná samostatně

4 Šířka korunního lístku

```
summary(data_kosatce$sirka_listku)
```


Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.100	0.300	1.300	1.199	1.800	2.500



5 Délka korunního lístku

```
summary(data_kosatce$delka_listku)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1.000	1.600	4.350	3.758	5.100	6.900



Než vybereme graf, zkusme si malý mentální úkol: když máme dvě numerické proměnné, jaký typ grafu dává největší smysl?

i Odpověď

Dobrá volba je bodový graf, protože chceme vidět jednotlivé květy a vztah mezi dvěma měřeními.

V našem případě je prediktorem **šířka korunního lístku** a podle ní vysvětlujeme rozdíly v **délce korunního lístku**.


Co z grafu sledujte zejména:

- **směr vztahu:** zda se s rostoucí šířkou obvykle zvětšuje i délka
- **neobvyklé květy:** jestli jsou v datech květy, které se chovají výrazně jinak než ostatní
- **rozptýlení kolem trendu:** jak velký je rozptyl hodnot kolem hlavního trendu

6 Rychlý a jednoduchý bodový graf

```
plot(  
  x = data_kosatce$sirka_listku,  
  y = data_kosatce$delka_listku,  
  xlab = "Šířka korunního lístku (cm)",  
  ylab = "Délka korunního lístku (cm)",  
  main = "Bodový graf šířky a délky korunního lístku",  
  pch = 16,  
  col = "#8A8A8A",  
  cex = 1.4,  
  cex.axis = 1.5,  
  cex.lab = 1.5,  
  cex.main = 1.5  
)
```


Bodový graf šířky a délky korunního lístku



7 Graf pomocí {ggplot2}

```
ggplot2::ggplot(  
  data = data_kosatce,  
  mapping = ggplot2::aes(x = sirka_listku, y = delka_listku)  
) +  
  ggplot2::geom_point(size = 2, alpha = 0.8, color = "#8A8A8A") +  
  ggplot2::labs(  
    x = "Šířka korunního lístku (cm)",  
    y = "Délka korunního lístku (cm)",  
    title = "Bodový graf šířky a délky korunního lístku"  
  ) +  
  ggplot2::theme_bw(base_size = 18)
```

Bodový graf šířky a délky korunního lístku




7.1 Přes stejná data květů můžeme vést mnoho přímek

V celé lekci budeme držet tuto interpretační větu:

„Když porovnáme dva květy, model pro květ se širším korunním lístkem odhaduje v průměru delší korunní lístek. Velikost tohoto rozdílu popisuje sklon přímky.“

Pro stejná data existuje **více kandidátních přímek** a každá vede k **trochu jiné interpretaci**. Každá přímka má přitom jiné parametry (viz níže).



Než rozhodneme, která přímka vystihuje data nejlépe, potřebujeme umět libovolnou přímku jednoznačně popsat.

8 Jak popíšeme libovolnou přímku?

Každou přímku popíšeme dvěma parametry:


- **a** (intercept)
- **b** (sklon)

Intuitivně:


- **a posouvá přímku nahoru nebo dolů** (mění základní úroveň odhadnuté délky)
- **b mění strmost přímky**, tedy jak rychle roste odhadnutá délka s rostoucí šířkou

Nejčastější studentská chyba je zaměnit tyto role. Proto je v následujících grafech oddělujeme: nejprve měníme intercept při stejném sklonu, potom sklon při pevném interceptu.


9 Intercept (a): posun přímky nahoru/dolů



10 Sklon (b): změna strmosti přímky



Jak vypadají kombinace a a b dohromady, si ukážeme v obrázku.



Teď už umíme každou kandidátní přímku popsat. Jak ale poznáme, která z nich nejlépe vystihuje vztah mezi šířkou a délkou korunního lístku?

i Co potřebujeme

Potřebujeme kritérium, které využije vzdálenosti naměřených délek od přímky při dané šířce. Nejprve proto musíme pochopit odhadnuté délky a residua.

11 Od přímky k odhadnuté délce a residuu

11.1 Vybereme 4 květy napříč prostorem dat

Než porovnáme kandidátní přímky ve všech datech, ukážeme princip na čtyřech květech rozptřčených napříč grafem.

```
data4 <-  
  data_kosatce[  
    c(1, 58, 71, 101),  
    c("sirka_listku", "delka_listku")  
  ]
```

data4

	sirka_listku	delka_listku
1	0.2	1.4
58	1.0	3.3
71	1.8	4.8
101	2.5	6.0


i Poznámka

Jako konkrétní příklad použijeme přímku **(B)** s interceptem $a = 1.1$ a sklonem $b = 2.2$.

Reziduum je **svislá vzdálenost bodu od modelové přímky**. Pokud je **kladné**, model délku podhodnocuje; pokud **záporné**, délku nadhodnocuje.

Rezidua přitom **očekáváme i u užitečného modelu**. Jednotlivé organismy se v důsledku přirozené biologické variability liší, takže žádná jednoduchá přímka nepopíše každý květ přesně. **Samotná existence reziduí proto neznamená, že je model špatný.**

V grafu níže je to vidět přímo jako zlaté úsečky mezi šedými body a fialovou přímkou.



11.2 Výpočet rezidua pro jeden květ

Nejdřív pro jeden květ ručně (dosazení konkrétních hodnot):

Logický postup pro jeden konkrétní květ:

1. Vezmeme **šířku** vybraného korunního lístku.
2. Dosadíme ji do vztahu **odhadnutá délka = intercept + sklon × šířka**.
3. Vypočítáme odhadnutou délku tohoto korunního lístku podle zvolené přímky.

Nejprve použijeme názvy veličin z našich dat a dosadíme hodnoty prvního květu. Jeho šířka 0.2 cm určuje **vodorovnou polohu prvního šedého bodu** v grafu výše. Intercept 1.1 a sklon 2.2 popisují **fialovou přímku**:

$$\begin{aligned}
 \text{odhadnutá délka}_1 &= \text{intercept} + \text{sklon} \cdot \text{šířka}_1 \\
 &= 1.1 + 2.2 \cdot 0.2 \\
 &= 1.1 + 0.44 \\
 &= 1.54 \text{ cm}
 \end{aligned}$$

Výsledek 1.54 cm je v grafu výše **výška fialové přímky** při šířce 0.2 cm — tedy **horní konec první zlaté úsečky**. Naměřená délka 1.4 cm je naopak **výška prvního šedého bodu**. Residuum proto vypočítáme opět pomocí názvů a konkrétních hodnot:

$$\begin{aligned}
 \text{residuum}_1 &= \text{naměřená délka}_1 - \text{odhadnutá délka}_1 \\
 &= 1.4 - 1.54 \\
 &= -0.14 \text{ cm}
 \end{aligned}$$

Hodnota -0.14 cm odpovídá **první zlaté úsečce**. Samotná úsečka má délku 0.14 cm; **záporné znaménko residua** říká, že šedý bod leží pod fialovou přímkou.

```

a0 <- 1.1
b0 <- 2.2

```

```
odhadnuta_delka_1 <-
  a0 + b0 * data4$sirka_listku[1]

odhadnuta_delka_1
```

```
[1] 1.54
```

11.3 Výpočet rezidua pro všechny 4 květy

Jakmile máme princip pro jeden květ, aplikujeme stejný výpočet na všechny čtyři květy. Tím získáme:

- odhadnuté délky jednotlivých květů
- rozdíly mezi naměřenou a odhadnutou délkou (residua)

```
odhadnuta_delka <-
  a0 + b0 * data4$sirka_listku

residuum <-
  data4$delka_listku - odhadnuta_delka

tab_pred <-
  data.frame(
    bod = 1:4,
    sirka = data4$sirka_listku,
    namerena_delka = data4$delka_listku,
    odhadnuta_delka = round(odhadnuta_delka, 2),
    residuum = round(residuum, 2)
  )

tab_pred
```

	bod	sirka	namerena_delka	odhadnuta_delka	residuum
1	1	0.2	1.4	1.54	-0.14
2	2	1.0	3.3	3.30	0.00
3	3	1.8	4.8	5.06	-0.26
4	4	2.5	6.0	6.60	-0.60

Čtení tabulky krok za krokem:

- sloupec `sirka`: šířka korunního lístku konkrétního květu
- sloupec `namerena_delka`: skutečně naměřená délka korunního lístku
- sloupec `odhadnuta_delka`: délka odhadnutá pomocí přímky B

- sloupec **residuum**: rozdíl mezi naměřenou a odhadnutou délkou

Teprve teď, když jsme stejný výpočet viděli pro všechny čtyři květy, zavedeme obecné symboly: naměřenou hodnotu označíme y_i , šířku x_i , odhadnutou hodnotu $\hat{y}_i$, intercept a , sklon b a residuum e_i .

$$\hat{y}_i = a + b \cdot x_i$$

$$e_i = y_i - \hat{y}_i$$

11.4 Jak kvantifikujeme „kvalitu“ přímky: SSE

Součet čtverců reziduí (SSE) říká, jak moc jsou body daleko od modelové přímky. **Čím menší SSE, tím lépe přímka vystihuje data.**

Proč čtverce? Protože:

- **odstraní znaménko** (kladná a záporná rezidua se neodečtou)
- **více penalizují velké chyby**
- **dávají jedno srovnatelné číslo** pro každou kandidátní přímku

Tabulka výše obsahuje všechny hodnoty potřebné pro ruční výpočet. Pro přehled ji zobrazíme ještě jednou:

Květ	Šířka	Naměřená délka	Odhadnutá délka	Residuum
1	0.2	1.4	1.54	-0.14
2	1.0	3.3	3.30	0.00
3	1.8	4.8	5.06	-0.26
4	2.5	6.0	6.60	-0.60

Ruční kalkulační zápis pro tuto přímku:

$$SSE = (-0.14)^2 + (0)^2 + (-0.26)^2 + (-0.6)^2 = 0.02 + 0 + 0.07 + 0.36 = 0.45$$

Až potom obecně pro všechna pozorování:

$$SSE = \sum_{i=1}^n e_i^2$$

Stejný výpočet nyní provedeme pro každou kandidátní přímku a pro všech 150 květů. Výsledkem je jediné srovnatelné číslo pro každou přímku:

Přímka	Intercept	Sklon	SSE
A	0.5	1.8	231.08
B	1.1	2.2	33.98
C	1.7	2.6	214.32

Otázka: Který model nejlépe odpovídá výzkumné otázce o vztahu šířky a délky korunního lístku?

i Odpověď

Z nabízených přímek je nejlepší B, protože má nejmenší SSE. Lineární model ale není omezen na tyto tři možnosti: hledá takový intercept a sklon, které SSE minimalizují mezi všemi možnými přímkami.

11.5 Od našich dat k obecnému zápisu modelu

Pro první květ můžeme naměřenou délku rozdělit na délku odhadnutou přímkou a residuum:

$$\begin{aligned}\text{naměřená délka}_1 &= \text{odhadnutá délka}_1 + \text{residuum}_1 \\ &= 1.54 + (-0.14) \\ &= 1.4 \text{ cm}\end{aligned}$$

Stejný vztah nyní zapíšeme pomocí již zavedených obecných symbolů:

$$y_i = \hat{y}_i + e_i = a + b \cdot x_i + e_i$$

Interpretace v biologickém příběhu:

- **a** (intercept) je odhad délky korunního lístku při nulové šířce; nula leží těsně za rozsahem pozorovaných dat
- **b** (sklon) říká, o kolik se v průměru změní délka korunního lístku při zvýšení jeho šířky o 1 cm
- e_i je nevysvětlená část variability (residuum)

11.6 Sklon jako změna odhadnuté délky

Nejprve ukážeme sklon na zvolené přímce a až poté jeho obecný zápis. Pro výpočet musíme použít dva body ležící na stejné přímce, ne dvě libovolná pozorování z dat:

Bod na přímce	Šířka	Odhadnutá délka
1	0.2	1.54
2	2.5	6.60

Sklon zvolené přímky můžeme z těchto dvou bodů zapsat takto:

$$\text{sklon} = \frac{\text{odhadnutá délka}_2 - \text{odhadnutá délka}_1}{\text{šířka}_2 - \text{šířka}_1} = \frac{6.6 - 1.54}{2.5 - 0.2} = \frac{5.06}{2.3} = 2.2$$

Až potom obecně:

$$b = \frac{\Delta \hat{y}}{\Delta x}$$

12 Jak nejlepší přímku najdeme v R

Funkce `lm()` fituje lineární model. Nejprve si její zápis přečteme jako obecnou gramatiku:

```
lm(  
  formula = odezva ~ prediktor,  
  data = data  
)
```

V tomto zápisu jsou `odezva`, `prediktor` a `data` zástupné názvy. Znak `~` můžeme číst jako „odezvu vysvětlujeme pomocí prediktoru“.

Pro naši biologickou otázku dosadíme:

- odezva: `delka_listku`
- prediktor: `sirka_listku`
- data: `data_kosatce`

Teprve potom sestavíme konkrétní volání. Tady model jen fitujeme; grafy uděláme až v dalším kroku.

V této části oddělíme dvě operace:

- `lm()` odhadne parametry modelu z dat
- `coef(mod_listky)` vrátí dva parametry, které už znáte z kandidátních přímek

```
mod_listky <-  
  lm(  
    
```

```

    formula = delka_listku ~ sirka_listku,
    data = data_kosatce
  )

coef(mod_listky)

```

```

(Intercept) sirka_listku
  1.083558      2.229940

```

Co vidíme za parametry (koeficienty) modelu:

- Intercept odpovídá parametru a
- odhad u `sirka_listku` odpovídá sklonu b

! Odpověď na biologickou otázku

Odhadnutý sklon je 2.23. Při zvýšení šířky korunního lístku o 1 cm proto očekáváme v průměru zvýšení jeho délky o 2.23 cm.

Odhadnutý intercept je 1.08 cm. Popisuje odhadnutou délku při nulové šířce, která leží těsně mimo rozsah pozorovaných dat. V tomto biologickém příběhu je proto důležitější sklon.

Model tak odpovídá na **směr a velikost vztahu**. Ani dobře vypadající lineární vztah ale automaticky neznamená **kauzální vztah**: z modelu zatím čteme pouze **asociaci mezi proměnnými**.

12.1 Odhadnuté délky a graf modelu

Odhadnuté délky pro všechny květy vypočítáme pomocí `predict()`:

```

odhadnuta_delka <-
  predict(
    object = mod_listky,
    newdata = data_kosatce
  )

head(odhadnuta_delka)

```

```

      1      2      3      4      5      6
1.529546 1.529546 1.529546 1.529546 1.529546 1.975534

```

Pak zobrazíme naměřené hodnoty a přímku odhadnutou modelem:


Tímto krokem uzavíráme logický kruh výzkumné otázky:

- ruční výpočet na 4 konkrétních květech

- stejný princip aplikovaný na celý dataset přes `predict()`
- vizuální kontrola, že přímka opravdu odpovídá číslům z modelu

```
data_model <-
  data.frame(
    sirka_listku = data_kosatce$sirka_listku,
    delka_listku = data_kosatce$delka_listku,
    odhadnuta_delka = predict(
      object = mod_listky,
      newdata = data_kosatce
    )
  )


ggplot2::ggplot(
  data = data_model,
  ggplot2::aes(x = sirka_listku, y = delka_listku)) +
  ggplot2::geom_point(size = 2, alpha = 0.75, color = "#8A8A8A") +
  ggplot2::geom_line(
    ggplot2::aes(y = odhadnuta_delka),
    color = "#5D2890",
    linewidth = 1
  ) +
  ggplot2::labs(
    x = "Šířka korunního lístku (cm)",
    y = "Délka korunního lístku (cm)"
  ) +
  theme_biostat()
```



i Kratší alternativa pomocí `geom_smooth()`

Balíček `{ggplot2}` umí lineární model odhadnout a nakreslit přímo pomocí `geom_smooth(method = "lm")`. Argument `se = FALSE` zde vypíná zobrazení pásu nejistoty, ke kterému se vrátíme v další lekci.

```
ggplot2::ggplot(  
  data = data_kosatce,  
  mapping = ggplot2::aes(x = sirka_listku, y = delka_listku)  
) +  
  ggplot2::geom_point(  
    size = 2,  
    alpha = 0.75,  
    color = "#8A8A8A"  
  ) +  
  ggplot2::geom_smooth(  
    method = "lm",  
    se = FALSE,  
    color = "#5D2890"  
  ) +  
  ggplot2::labs(  
    x = "Šířka korunního lístku (cm)",  
    y = "Délka korunního lístku (cm)"  
  ) +  
  ggplot2::theme_bw(base_size = 18)
```



13 Residua v R a jejich první grafická kontrola

Residua jsou uložena přímo v objektu modelu. Získáme je funkcí `resid()` a uložíme do vektoru, se kterým můžeme dále pracovat:

```
vec_rezidua <-  
  resid(mod_listky)  
  
head(vec_rezidua)
```


```
      1      2      3      4      5      6  
-0.12954613 -0.12954613 -0.22954613 -0.02954613 -0.12954613 -0.27553423
```

Kladné residuum znamená, že naměřená délka leží nad odhadem modelu. **Záporné residuum** znamená, že naměřená délka leží pod odhadem modelu.

13.1 Nejdříve známý graf: histogram residuí

Histogram už znáte z předchozích lekcí. Tentokrát na vodorovné ose nejsou původní délky lístků, ale rozdíly mezi naměřenou a odhadnutou délkou:

```
hist(  
  x = vec_rezidua,  
  breaks = 12,  
  main = "Histogram residuí",  
  xlab = "Residuum (cm)",  
  ylab = "Četnost",  
  col = "#D9D9D9",  
  border = "white",  
  cex.axis = 1.4,  
  cex.lab = 1.4,  
  cex.main = 1.4  
)  
  
abline(  
  v = 0,  
  lty = 2,  
  col = "#5D2890"  
)
```



Přerušovaná čára označuje **nulové residuum**, tedy přesnou shodu naměřené a odhadnuté délky. Histogram ukazuje, **která residua jsou častá** a zda některé květy leží od odhadu neobvykle daleko. Neříká ale, **u kterých odhadnutých délek** tato residua vznikají.

13.2 Odhadnuté délky vs. residua

Proto ke každému květu spojíme odhadnutou délku z `fitted()` s jeho residuem z `resid()`:

```
vec_odhadnuta_delka <-  
  fitted(mod_listky)  
  
data_rezidua <-  
  data.frame(  
    odhadnuta_delka = vec_odhadnuta_delka,  
    reziduum = vec_rezidua  
  )  
  
head(data_rezidua)
```


	odhadnuta_delka	reziduum
1	1.529546	-0.12954613
2	1.529546	-0.12954613
3	1.529546	-0.22954613

4	1.529546	-0.02954613
5	1.529546	-0.12954613
6	1.975534	-0.27553423

Stejný graf si ukážeme nejprve pomocí základních funkcí R a potom pomocí balíčku `{ggplot2}`.


13.3 Základní graf v R

```
plot(  
  x = data_rezidua$odhadnuta_delka,  
  y = data_rezidua$reziduum,  
  xlab = "Odhadnutá délka (cm)",  
  ylab = "Residuum (cm)",  
  main = "Odhadnuté délky vs. rezidua",  
  pch = 16,  
  col = "#8A8A8A",  
  cex = 1.3,  
  cex.axis = 1.4,  
  cex.lab = 1.4,  
  cex.main = 1.4  
)  
  
abline(  
  h = 0,  
  lty = 2,  
  col = "#5D2890"  
)
```



13.4 Graf pomocí {ggplot2}

```
ggplot2::ggplot(
  data = data_rezidua,
  mapping = ggplot2::aes(x = odhadnuta_delka, y = reziduum)
) +
  ggplot2::geom_hline(
    yintercept = 0,
    linetype = 2,
    color = "#5D2890"
  ) +
  ggplot2::geom_point(
    size = 2,
    alpha = 0.8,
    color = "#8A8A8A"
  ) +
  ggplot2::labs(
    x = "Odhadnutá délka (cm)",
    y = "Residuum (cm)",
    title = "Odhadnuté délky vs. residua"
  ) +
  ggplot2::theme_bw(base_size = 18)
```



Jak tento graf číst:

- **každý bod** představuje jeden květ
- **vodorovná poloha** ukazuje délku odhadnutou modelem
- **svislá poloha** ukazuje rozdíl mezi naměřenou a odhadnutou délkou
- **bod na nulové čáře** má naměřenou délku přesně rovnou odhadu
- **bod nad nulou** model podhodnotil, **bod pod nulou** model nadhodnotil


Pro první kontrolu stačí jednoduchá otázka: *tvoří body kolem nuly neuspořádaný mrak, nebo v nich zůstává viditelný vzor?* **Viditelný vzor** znamená, že model v datech něco systematicky nezachytil.

14 Co model nevidí: druhy kosatců

Dosud jsme všechny květy zobrazovali stejně a druh kosatce jsme do modelu nezahrnuli. Nyní použijeme barvu pouze jako pomůcku, abychom zjistili, zda se jednotlivé druhy v datech chovají podobně.

14.1 Nejprve obarvíme původní data


Stejně barvy použijeme pro každý druh v obou následujících grafech:



Barvy ukazují, že **tři druhy netvoří jeden společný bodový mrak**. Jedna přímka vedená přes všechny květy proto shrnuje nejen vztah šířky a délky, ale také **rozdíly mezi druhy**.

14.2 Potom obarvíme graf odhadnutých délek a residuí

Ke každému residuu nyní doplníme druh stejného květu:



Po obarvení vidíme, že residua jednotlivých druhů **neleží kolem nuly úplně stejně**. Model některé druhy častěji **nadhodnocuje** a jiné častěji **podhodnocuje**. Informace o druhu tedy zůstala v části dat, kterou jednoduchý model nevysvětlil.

V této lekci stačí toto omezení rozpoznat a popsat. Druh jako další prediktor přidáme do modelu až v některé z navazujících lekcí.

15 Co budeme řešit v dalších lekcích

Jednoduchý lineární model je výborný začátek, ale ne univerzální řešení. V této lekci jsme odhalili jeden důvod k opatrnosti: v residuích zůstaly rozdíly mezi druhy kosatců.

V dalších lekcích se naučíme rozlišovat také jiné viditelné vzory:

- zakřivený průběh může ukazovat na nelinearitu
- postupné rozšiřování nebo zužování bodového mraku souvisí s pojmem heteroskedasticita
- jednotlivé body daleko od ostatních mohou být odlehlá pozorování
- barevně oddělené skupiny mohou upozornit na důležitý prediktor, který v modelu chybí

Tyto pojmy teď nemusíte umět diagnostikovat ani řešit. Později podle biologické otázky zvážíme další prediktor, transformaci, jiný tvar vztahu nebo jiný model.

Hlavní princip zůstává stejný: nejprve omezení modelu transparentně pojmenujeme a teprve potom volíme vhodné rozšíření.

V následující lekci ponecháme stejný modelový rámec a přidáme první inferenční vrstvu: výběrovou variabilitu a intervaly spolehlivosti jako vyjádření nejistoty odhadu. Testování hypotéz a p-hodnota přijdou až v L05.

16 Shrnutí

- Lineární model zavádí hlavní rámec: biologická otázka $\rightarrow$ graf $\rightarrow$ model $\rightarrow$ interpretace $\rightarrow$ diagnostika.
- Koeficient sklonu popisuje, o kolik se v průměru změní délka korunního lístku při zvýšení jeho šířky o 1 cm.
- Rezidua nejsou „odpad“, ale klíčová informace o tom, co model nevysvětluje.
- Nejlepší přímka minimalizuje součet čtverců residuí; funkce `lm()` ji najde a vrátí její intercept a sklon.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice:

Interaktivní slovníček je dostupný v HTML verzi materiálů.