BIOSTATISTIKA

L03

Mají širší korunní lístky kosatců také větší délku — a pokud ano, o kolik?



Lineární model s jedním numerickým prediktorem

cuni-natur-biostatistics.github.io/materialy.html

Ilustrace vytvořená pomocí AI.

Jakou délku odhadneme z naměřené šířky?



BIOLOGICKÁ OTÁZKA

Mají širší korunní lístky kosatců také větší délku — a pokud ano, o kolik?

CO BUDEME SLEDOVAT

150 květů

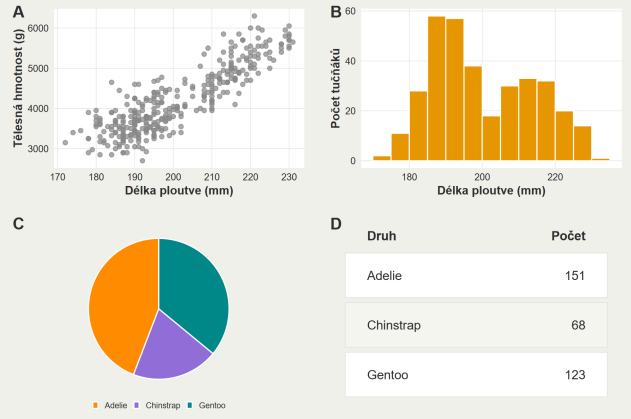
šířka a délka korunního lístku v centimetrech

Foto: Danielle Langlois / Wikimedia Commons, CC BY-SA 3.0

Co si pamatujete z minulé lekce?

Odpovězte samostatně na tři krátké otázky. Společné odpovědi projdeme po hlasování.

Máme délku ploutve a tělesnou hmotnost každého tučňáka. Který graf je vhodný jako první pohled na jejich vztah?



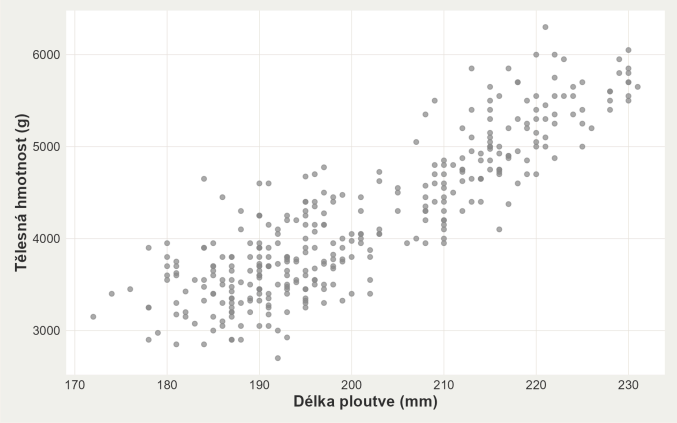
- Bodový graf
- Jeden histogram
- Koláčový graf
- Tabulka četností kategorií

SPRÁVNÁ ODPOVĚĎ

: Bodový graf

Obě proměnné jsou číselné a každá dvojice měření patří jednomu tučňákovi. Bodový graf zachová obě hodnoty i jejich párování.

Jaký směr vztahu vidíme v bodovém grafu délky ploutve a tělesné hmotnosti?



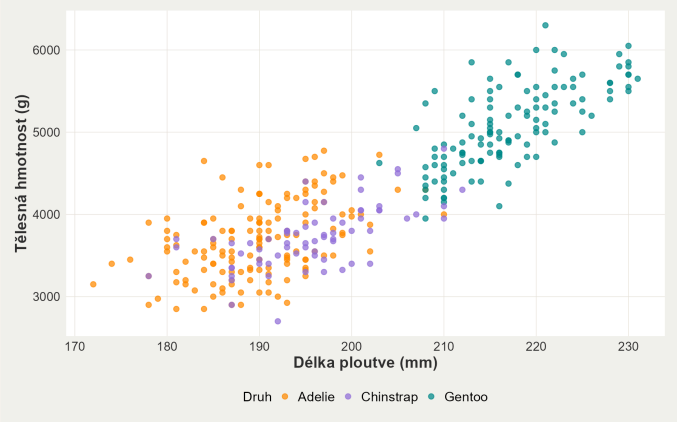
- Převážně klesající
- Bez viditelného směru
- Graf ukazuje pouze jednu proměnnou
- Převážně rostoucí

SPRÁVNÁ ODPOVĚĎ

: Převážně rostoucí

Tučňáci s delší ploutví bývají v tomto souboru těžší. Body proto tvoří převážně rostoucí oblak.

Které tvrzení odpovídá tomu, co z tohoto pozorovacího grafu smíme vyvodit?



- Delší ploutev způsobuje vyšší tělesnou hmotnost.
- Tělesná hmotnost způsobuje růst ploutve.
- Délka ploutve a tělesná hmotnost spolu v těchto datech souvisejí.
- Druh tučňáka nemůže vztah ovlivnit.

SPRÁVNÁ ODPOVĚĎ

: Délka ploutve a tělesná hmotnost spolu v těchto datech souvisejí.

Graf podporuje tvrzení o asociaci v pozorovaných datech. Sám neurčuje příčinu ani nevylučuje další proměnné.

Výsledky učení

Po absolvování této přednášky budete schopni:

- převést otázku „když změříme jednu veličinu, jakou hodnotu druhé můžeme čekat?“ na lineární model s odezvou a prediktorem
- fitovat `lm(odezva ~ prediktor)` a interpretovat směr i velikost efektu
- vysvětlit residuum jako rozdíl mezi naměřenou a odhadnutou hodnotou
- číst graf reziduí a rozpoznat v něm zbývající vzor

Změříme šířku — jakou délku čekáme?

Příští sezónu stihneme změřit jen šířku

Letos botanička změřila u každého květu šířku i délku korunního lístku. Ukázka čtyř květů: jeden řádek = jeden květ.

Květ	Šířka (cm)	Délka (cm)	Druh
1	0,2	1,3	setosa
2	1,0	3,7	versicolor
3	1,8	5,5	virginica
4	2,5	6,0	virginica
nový	**2,0**	**?**	**–**

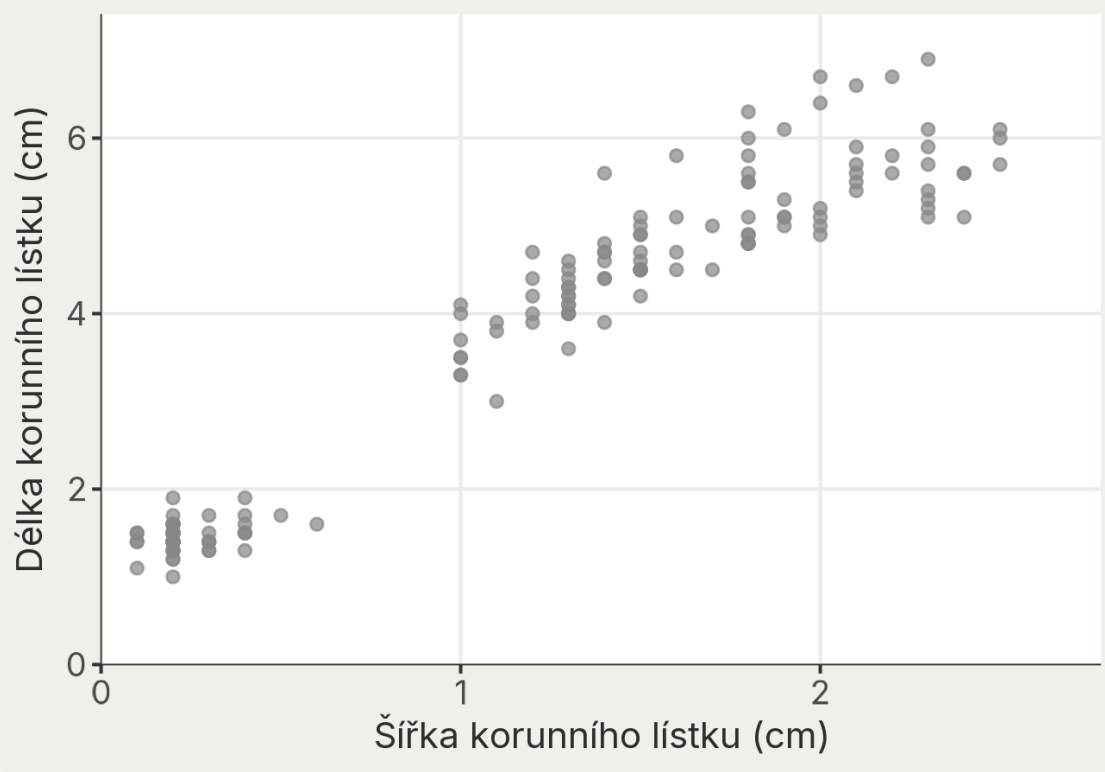
LETOŠNÍ MĚŘENÍ

150 květů · 0 chybějících hodnot
Šířky 0,1–2,5 cm · délky 1–6,9 cm

PŘÍŠTÍ SEZÓNA

U nových květů stihneme změřit jen šířku. Jakou délku můžeme čekat?

Jaký vztah vidíte?

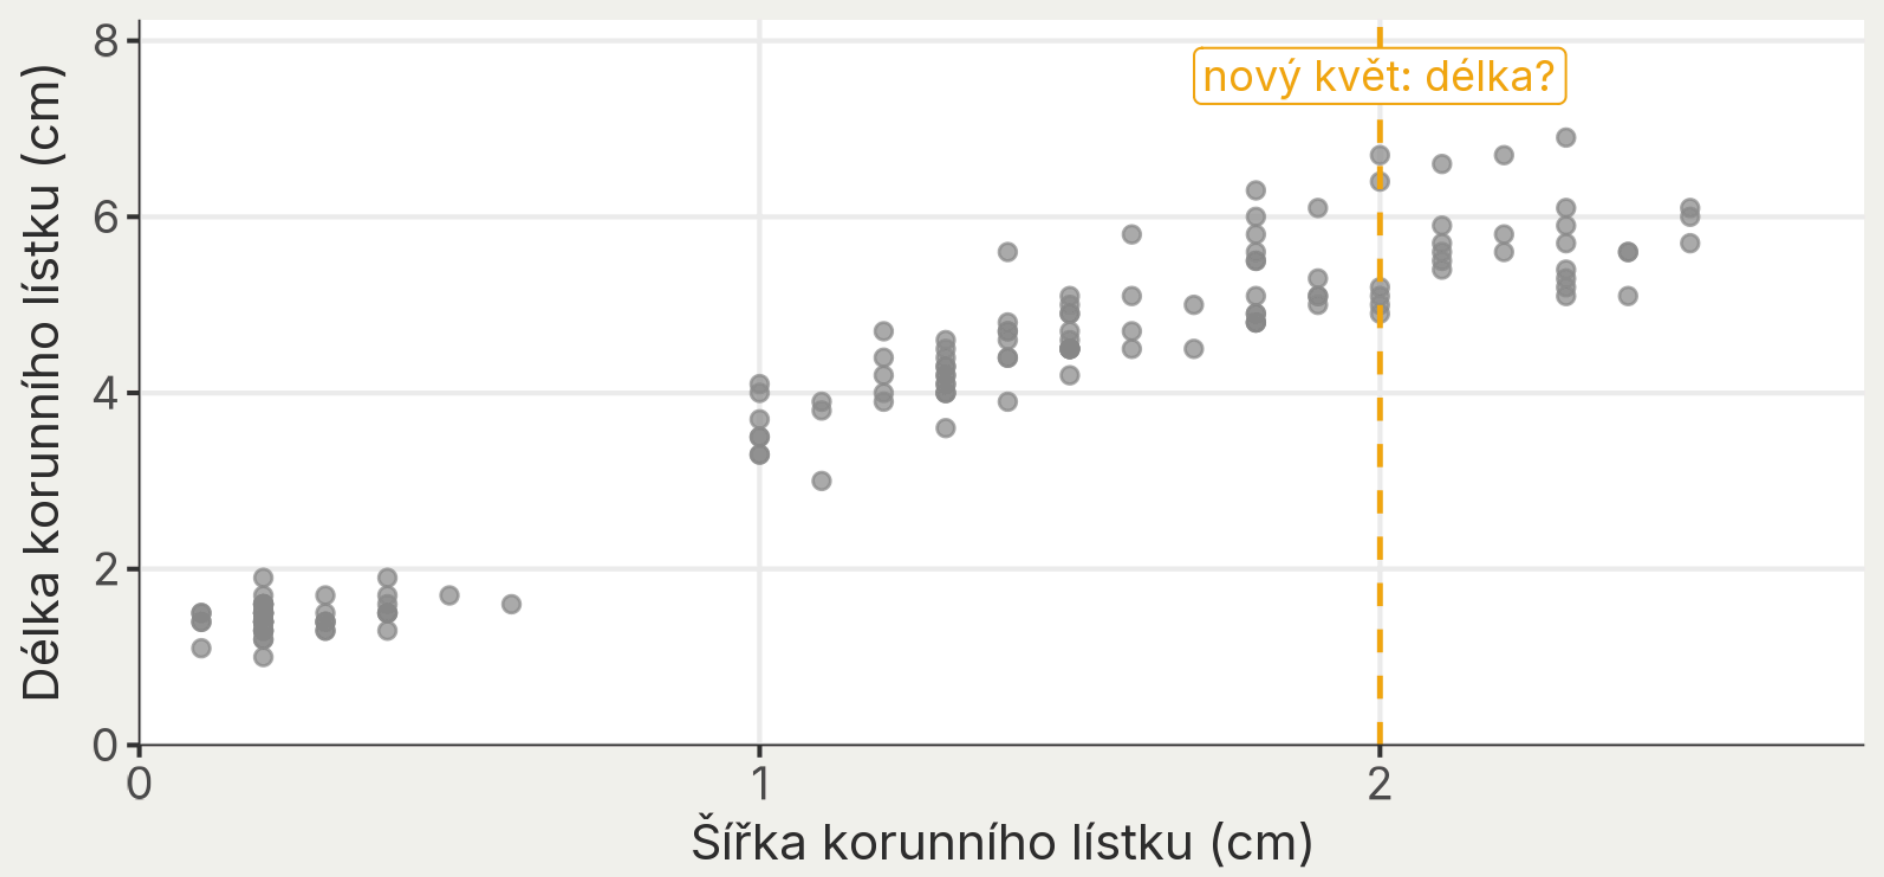


VYBERTE NEJLEPŠÍ POPIS

A) bez zřetelného vztahu
B) přibližně lineární růst
C) výrazně zakřivený růst

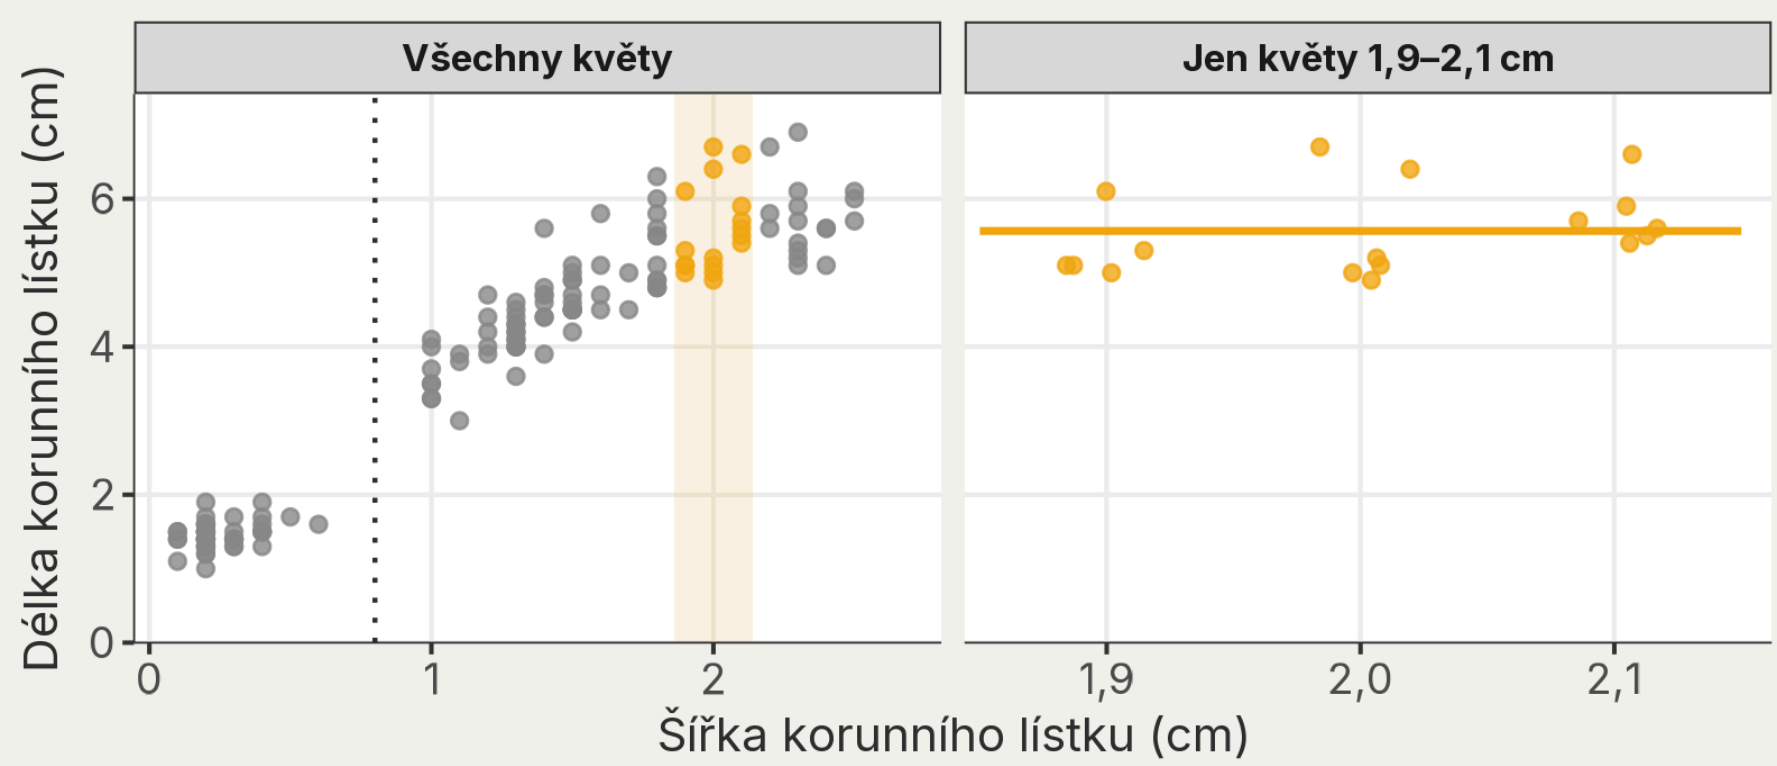
Zvolte A/B/C a zdůvodněte odpověď podle bodů v grafu.

Jakou délku čekáte u květu širokého 2 cm?



Odhadněte délku nového květu v cm a porovnejte ji se sousedem.

Jakou délku čekáte u květu širokého 2 cm?



Čekáme délku kolem 5,6 cm; jednotlivé podobně široké květy měří 4,9–6,7 cm.

A u květu širokého 0,8 cm (tečkovaná čára)? Podobně široké květy v datech nejsou, potřebujeme pravidlo pro každou šířku.

Co změříme a co čekáme?

OTÁZKA

V terénu jedno měření korunního lístku změříme a druhé podle něj chceme odhadnout. Které měření budeme odhadovat?

A) šířka korunního lístku

B) délka korunního lístku

Zvolte A/B a zdůvodněte svou volbu sousedovi.

prediktor: šířka — změříme → odezva: délka — odhadujeme
Opačná otázka, odhad šířky ze známé délky, by byla jiný model.

Jedna přímka shrnuje mnoho květů



Ilustrační obraz vytvořen AI.

> Přímka, která každé šířce (**prediktor**) přiřadí odhadnutou délku (**odezva**), je nejjednodušší **lineární model**.

Co přidá lineární model?

GRAF A KORELACE (MINULÁ LEKCE)

- vztah zobrazit
- popsat jeho směr
- shrnout jeho těsnost

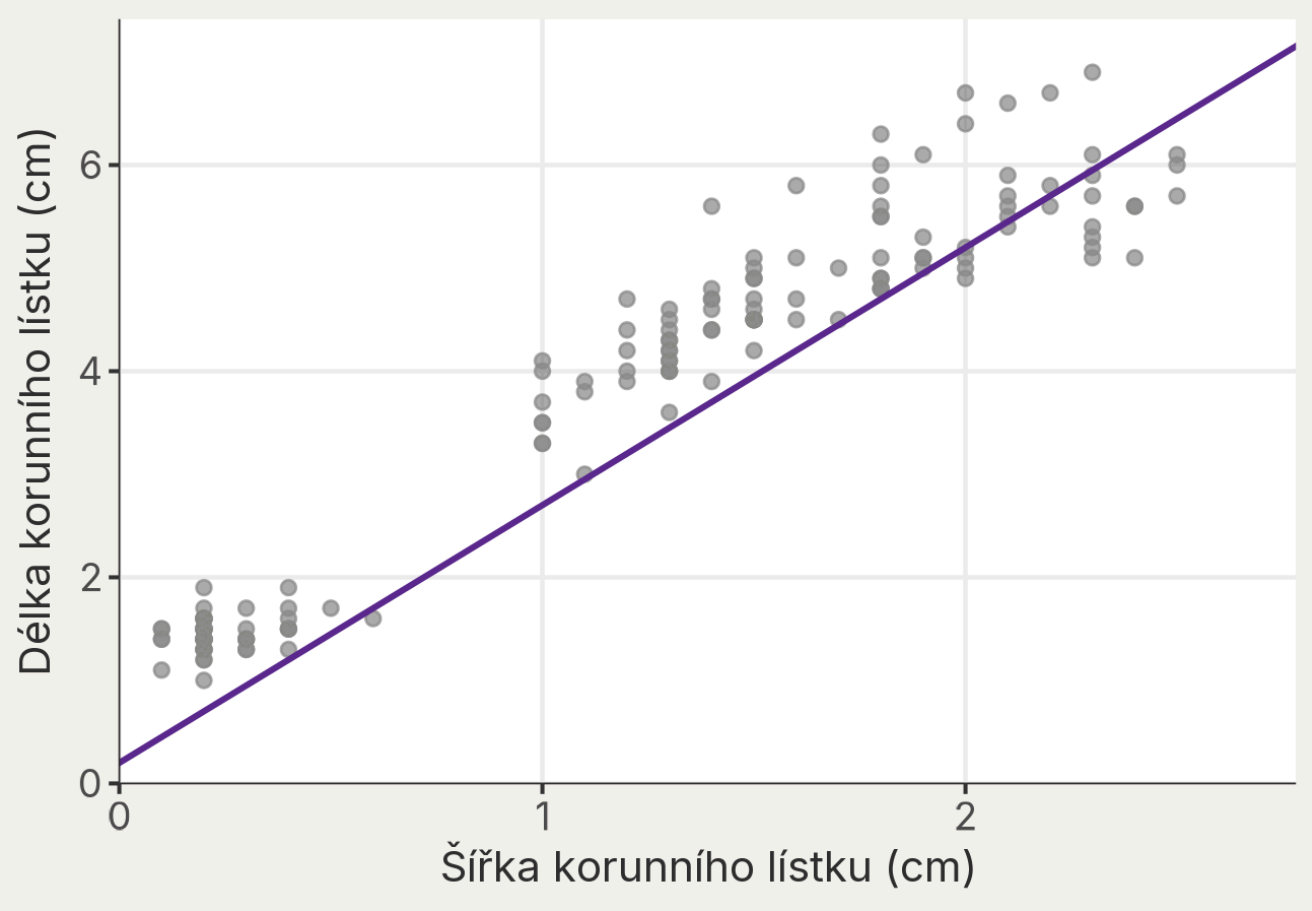
LINEÁRNÍ MODEL

- o kolik se v průměru liší délka dvou květů, jejichž šířky se liší o 1 cm
- jakou délku čekat u květu dané šířky, třeba u nového květu

Obě odpovědi dostaneme v centimetrech. Jak přesné jsou, zůstává otevřené do příští lekce.

Co rozhoduje mezi přímkami?

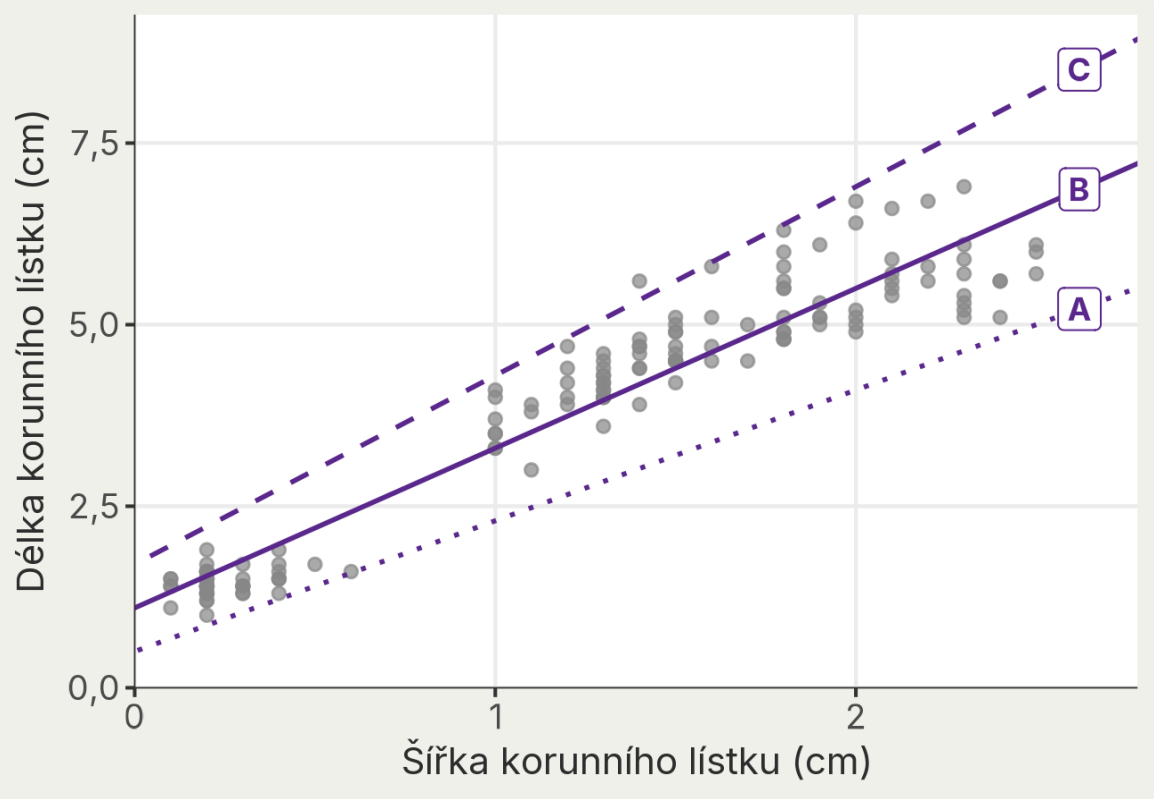
Která z mnoha přímek vystihuje měření?



DISKUZE SE SOUSEDEM — 30 S

Sledujte jeden cyklus. Podle čeho byste mezi přímkami rozhodli?

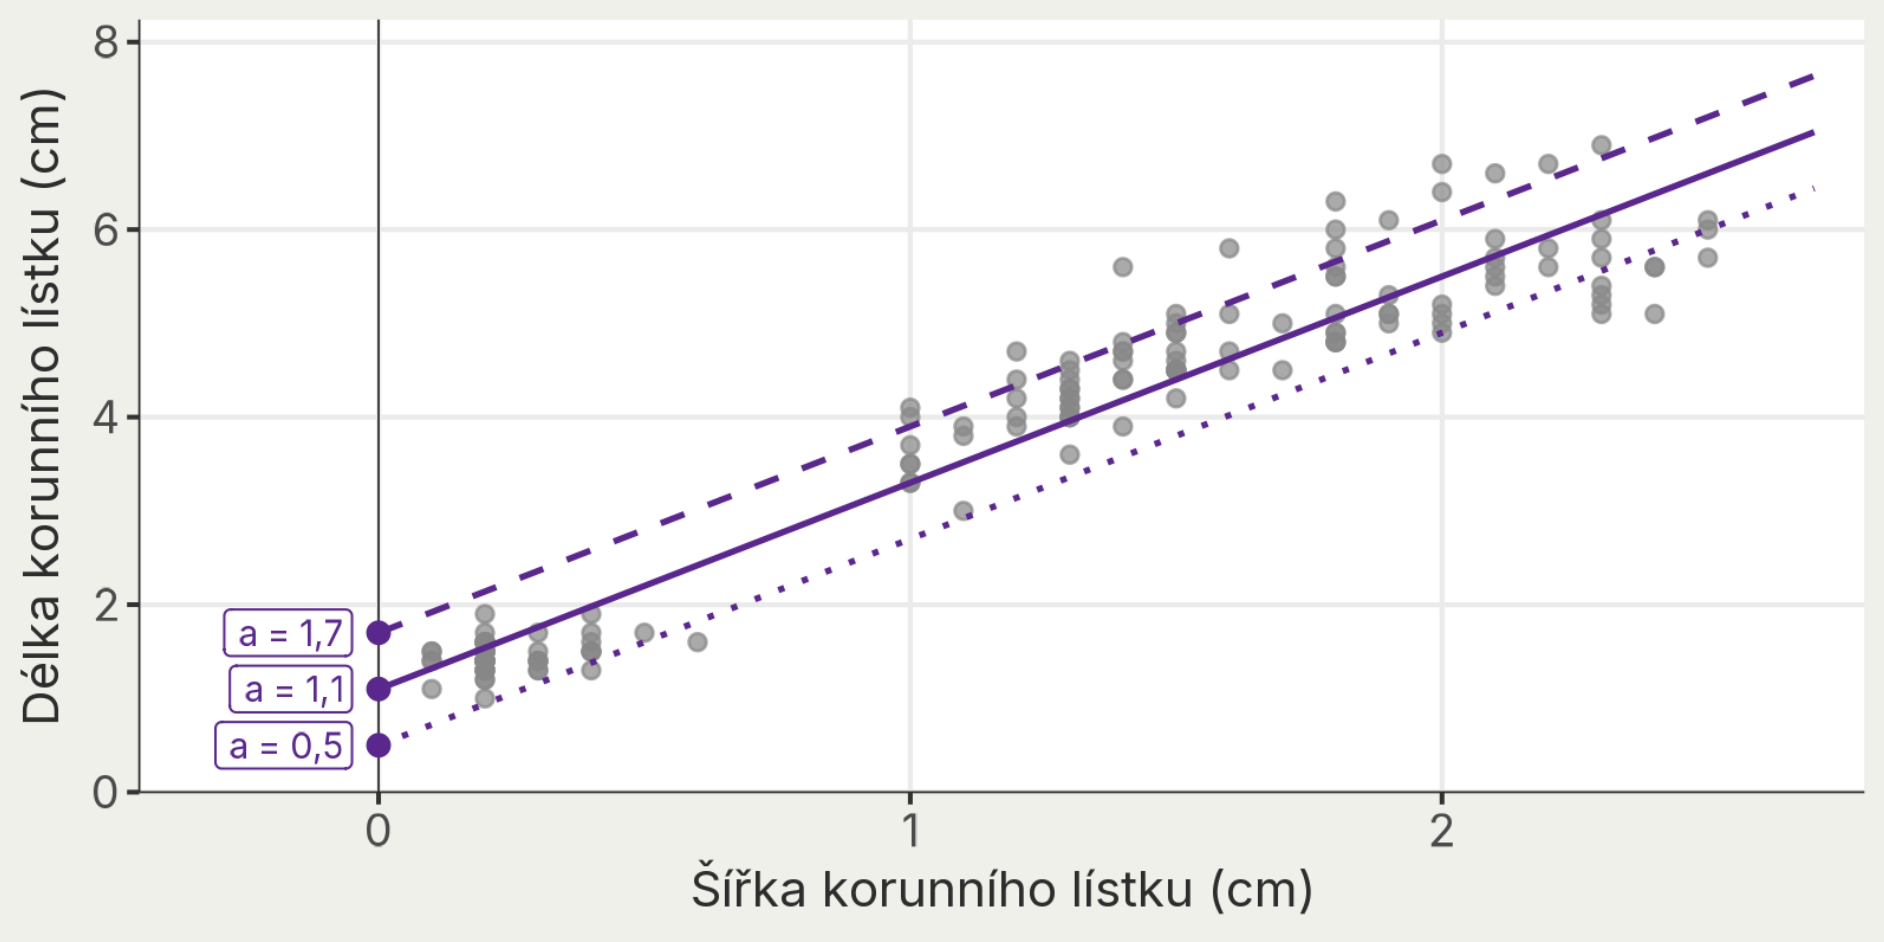
Kterou ze tří přímek byste vybrali?



HLASOVÁNÍ

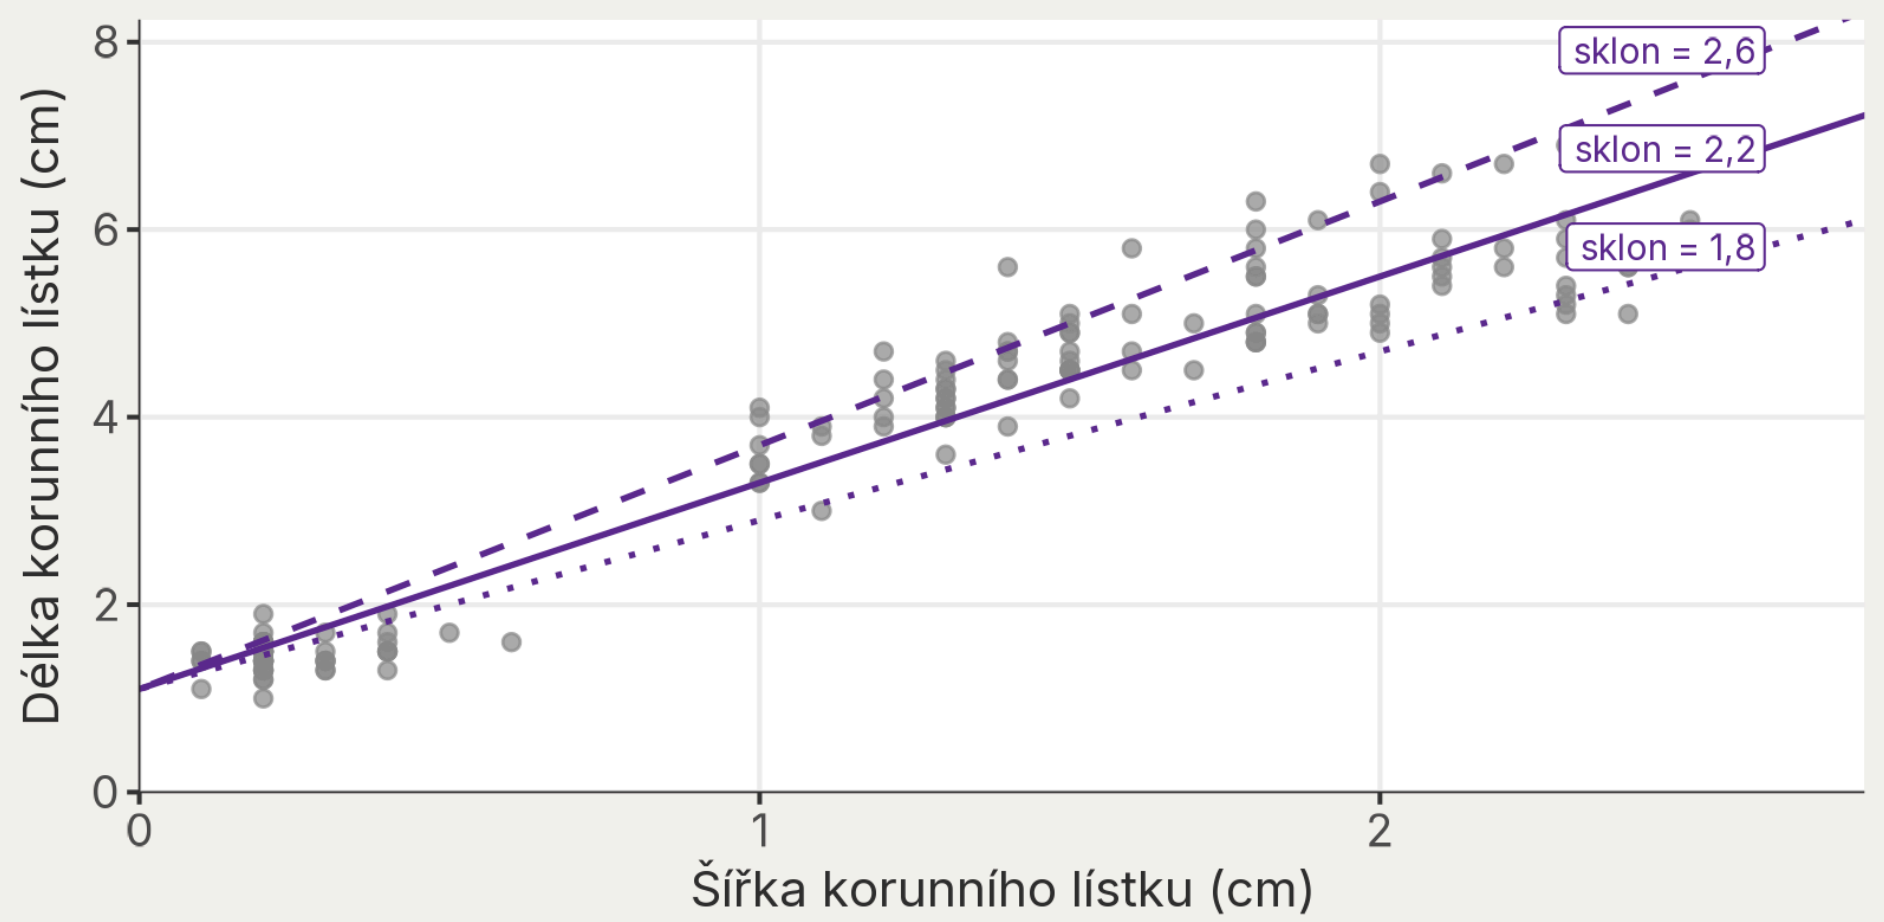
Zvolte A, B, nebo C a napište, podle čeho posuzujete nejlepší přímku.

Co se změní, když přímku posuneme?



Intercept (a) posouvá přímku nahoru nebo dolů.

Co se změní, když přímku nakloníme?



Sklon (b) říká, jak rychle se mění odhadnutá délka s rostoucí šířkou.

Dvě čísla popíší každou přímku

$$\text{odhadnutá délka} = \text{intercept } (a) + \text{sklon } (b) \cdot \text{šířka}$$

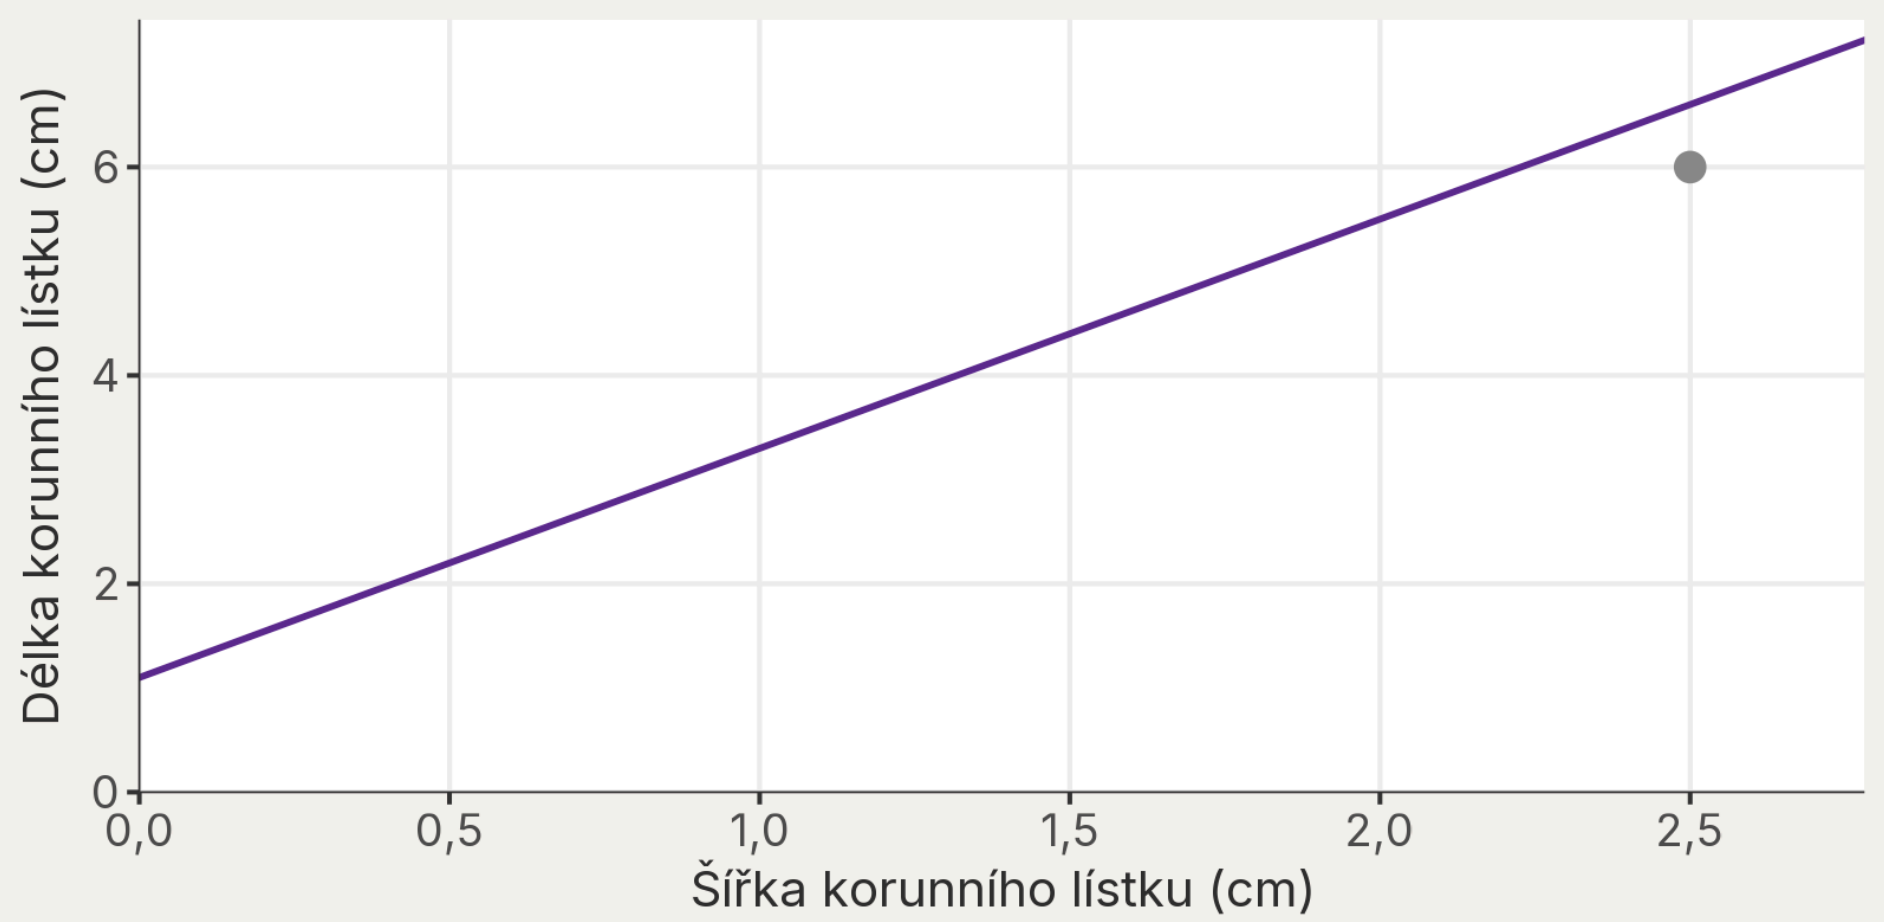
intercept (a)
Výška přímky při šířce 0 cm.

sklon (b)
Rozdíl odhadnutých délek dvou šířek, které se liší o 1 cm.

Intercept a sklon jsou dvě čísla, která popíší lineární model.

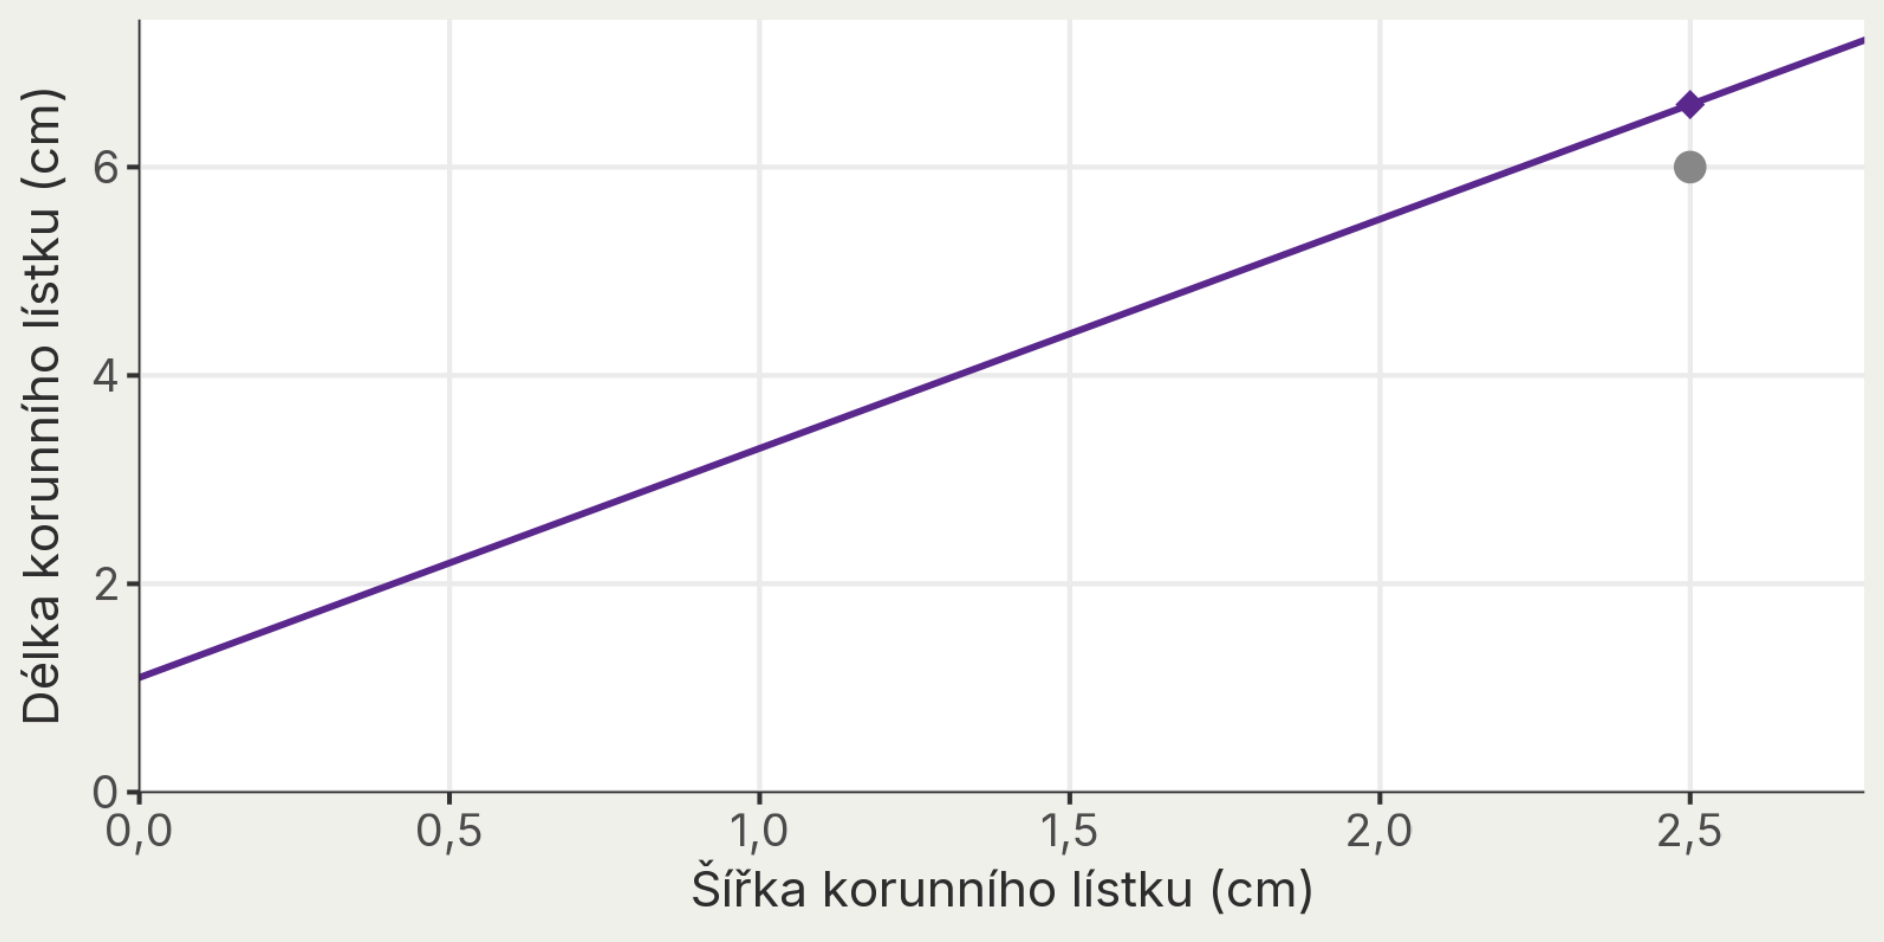
Jak daleko je měření od přímky?

Jeden květ a přímka B



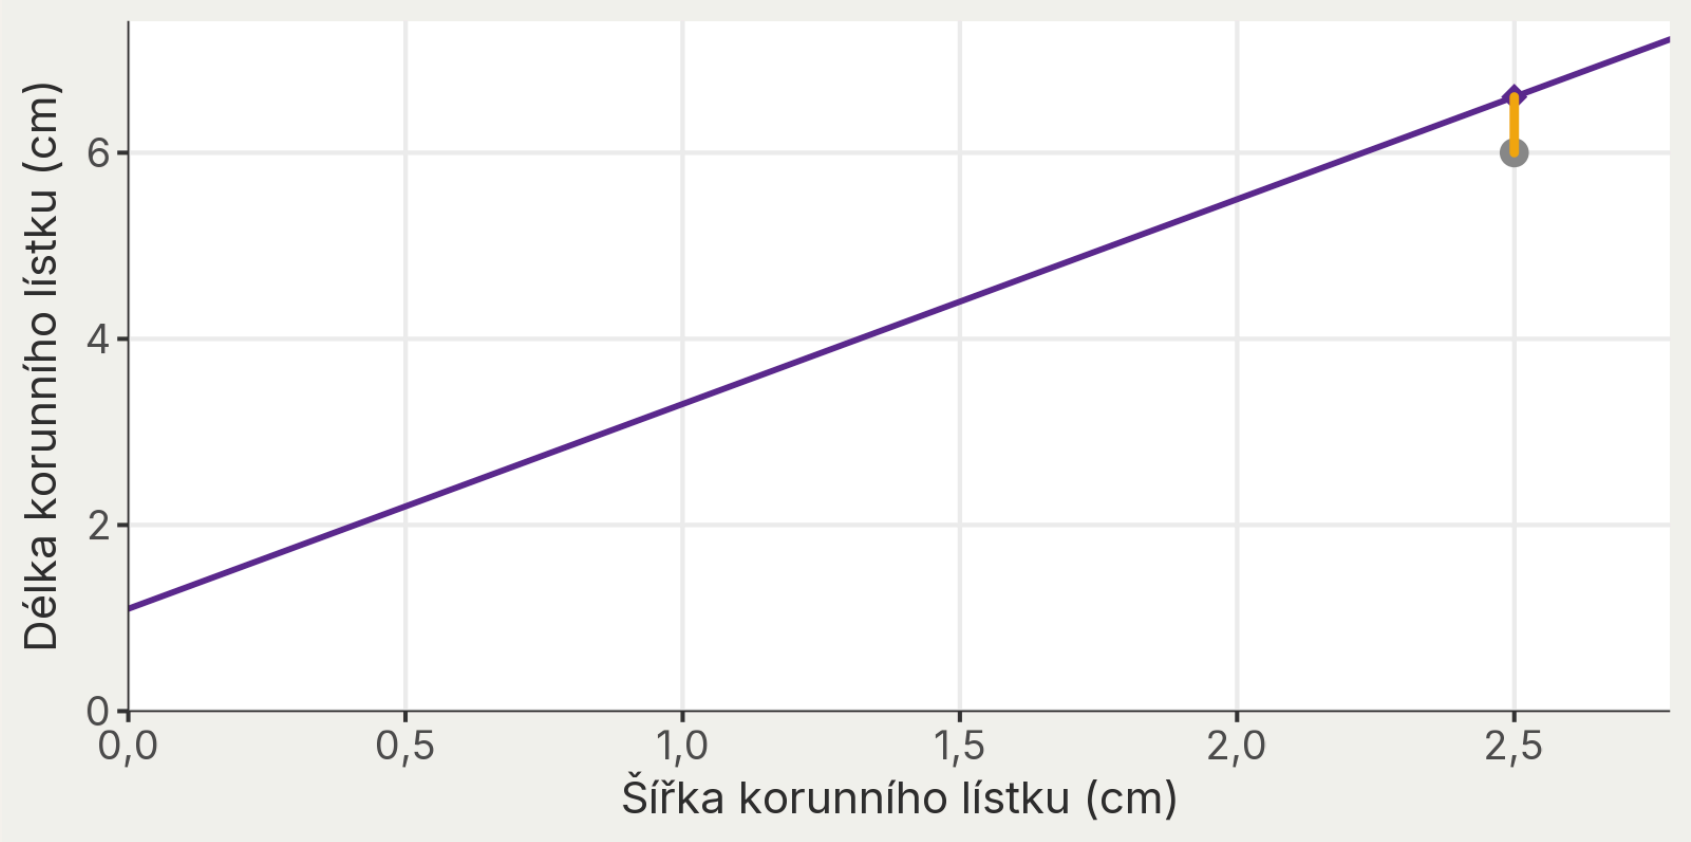
Přímka B · šedý bod = květ 4 z tabulky: šířka **2,5 cm**, naměřená délka **6 cm**

Odhad přímky pro stejnou šířku



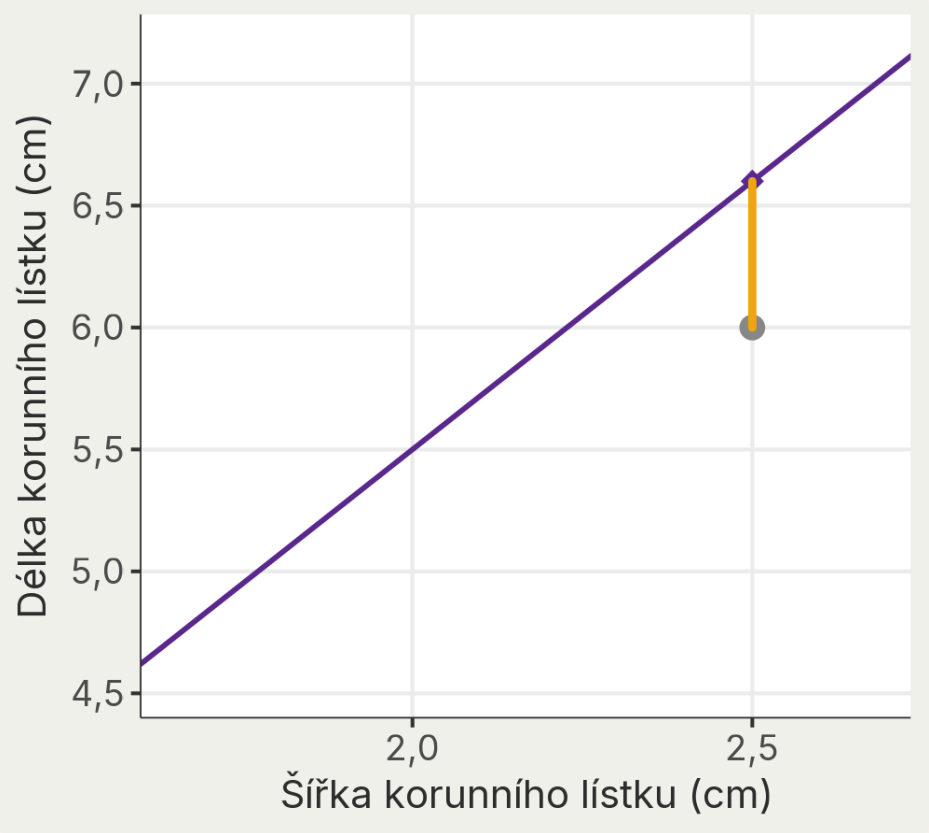
Fialový bod: odhadnutá délka na přímce při stejné šířce.

Mezi měřením a odhadem zůstává rozdíl



Oranžová úsečka ukazuje residuum: rozdíl mezi naměřenou a odhadnutou délkou.

Jaké znaménko má residuum?



$$\text{residuum} = \text{naměřená délka} - \text{odhadnutá délka}$$

A) kladné

B) záporné

C) nulové

Zvolte znaménko a zdůvodněte je polohou bodu vůči přímce.

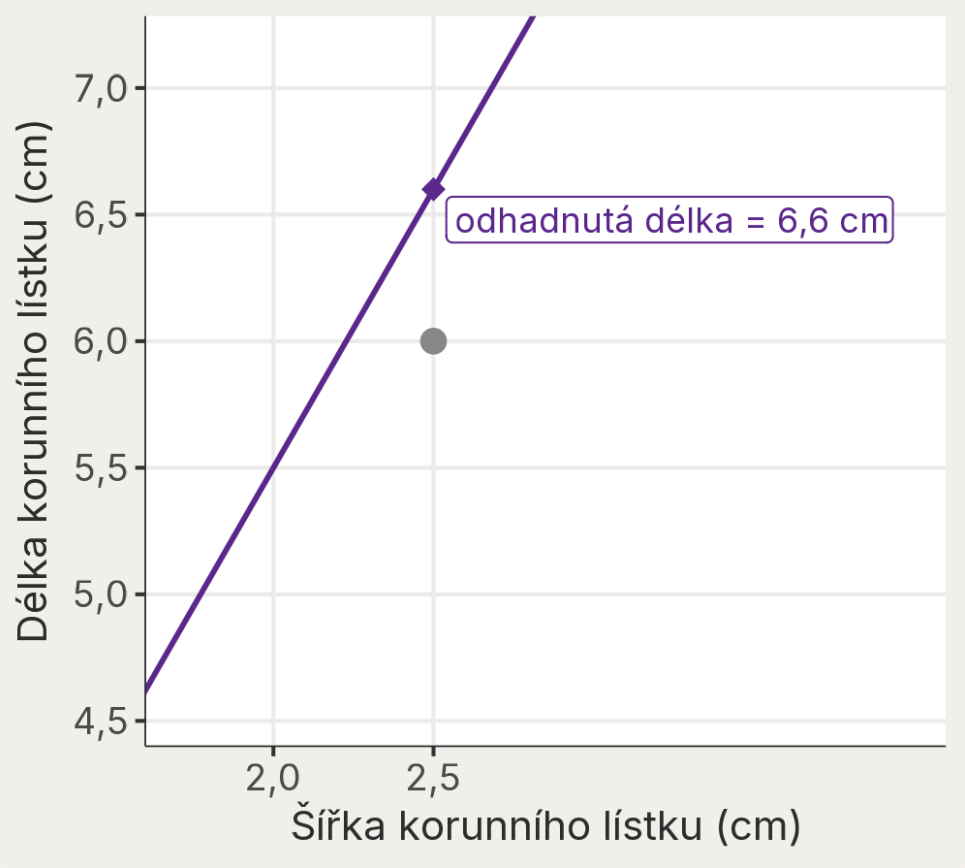
Odhadnutá délka vybraného květu

Přímka B: **intercept (a) = 1,1 cm · sklon (b) = 2,2 cm/cm**

$$\begin{aligned}\text{odhadnutá délka} &= \text{intercept} \\ &\quad + \text{sklon} \cdot \text{šířka} \\ &= 1{,}1 + 2{,}2 \cdot 2{,}5 \\ &= 1{,}1 + 5{,}5 \\ &= 6{,}6 \text{ cm}\end{aligned}$$

$$\hat{y}_i = a + b \cdot x_i$$

x_i = naměřená šířka · $\hat{y}_i$ = odhadnutá délka · i = pořadí květu



Residuum vybraného květu

$$\begin{aligned}\text{residuum} &= \text{naměřená délka} \\ &\quad - \text{odhadnutá délka} \\ &= 6 - 6{,}6 \\ &= -0{,}6 \text{ cm}\end{aligned}$$

$$e_i = y_i - \hat{y}_i$$

y_i = naměřená délka (cm)

$\hat{y}_i$ = odhadnutá délka (cm)

e_i = residuum (cm)



Residua očekáváme i u užitečného modelu

DŮLEŽITÁ MYŠLENKA

Biologická variabilita nezmizí jen proto, že jsme nakreslili modelovou přímku

Model nemusí trefit každý květ přesně. Potřebujeme ale zjistit, zda odchylky působí náhodně, nebo zda v nich zůstává vzor.

Čtyři květy, stejná přímka

Květ	Šířka (cm)	Délka (cm)	Odhad (cm)	Residuum (cm)
1	0,2	1,3	1,54	-0,24
2	1,0	3,7	3,30	0,40
3	1,8	5,5	5,06	0,44
4	2,5	6,0	6,60	-0,60

Součet residuí: **0 cm**. Kladná a záporná residua se vyruší, přestože přímka žádným bodem neprochází.



Jak porovnat celé přímky?

1 · ZMĚŘIT ROZDÍL

Pro každý květ určíme residuum.

2 · ODSTRANIT ZNAMÉNKO

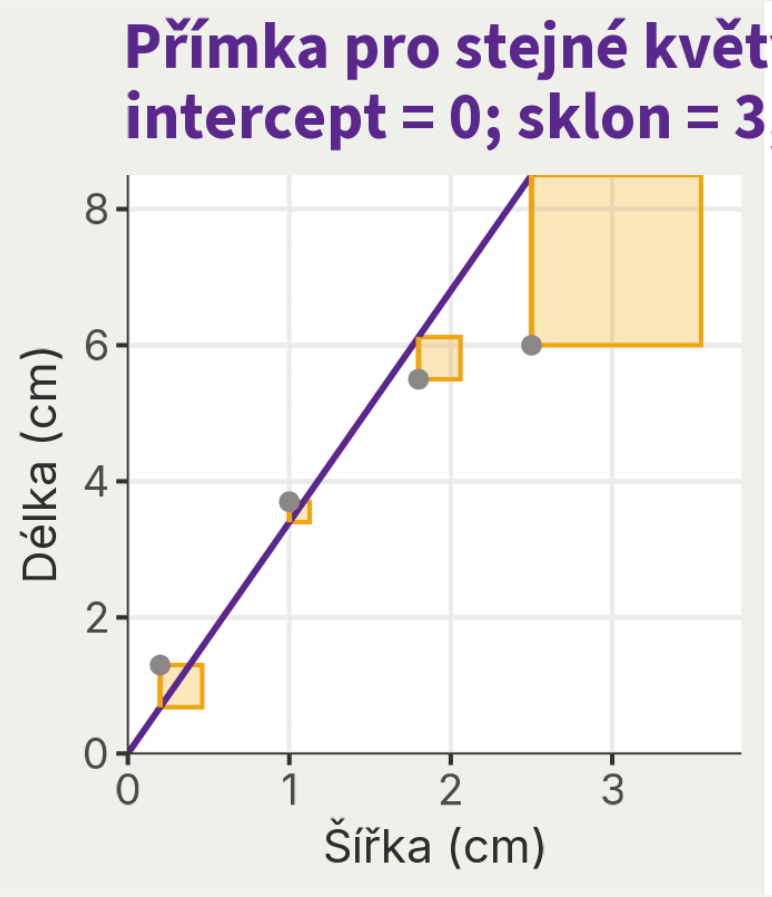
Každé residuum umocníme.

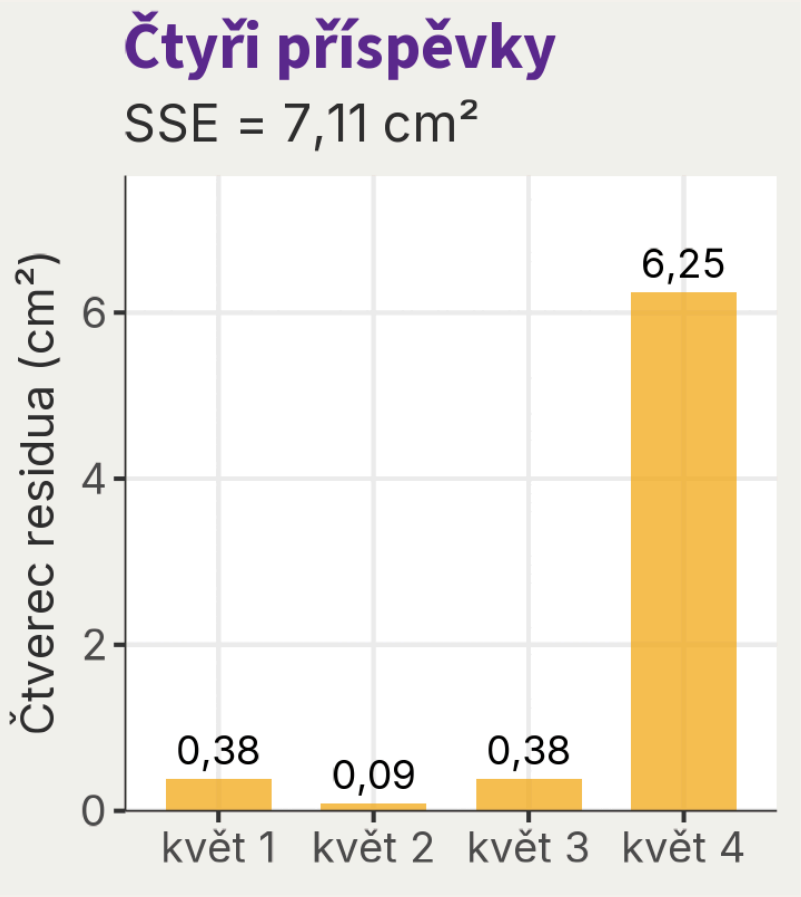
3 · SHRNOUT PŘÍMKU

Čtverce sečteme do jednoho čísla: SSE.

Menší SSE znamená, že body leží celkově blíže přímce.

Jiná přímka, jiné vzdálenosti

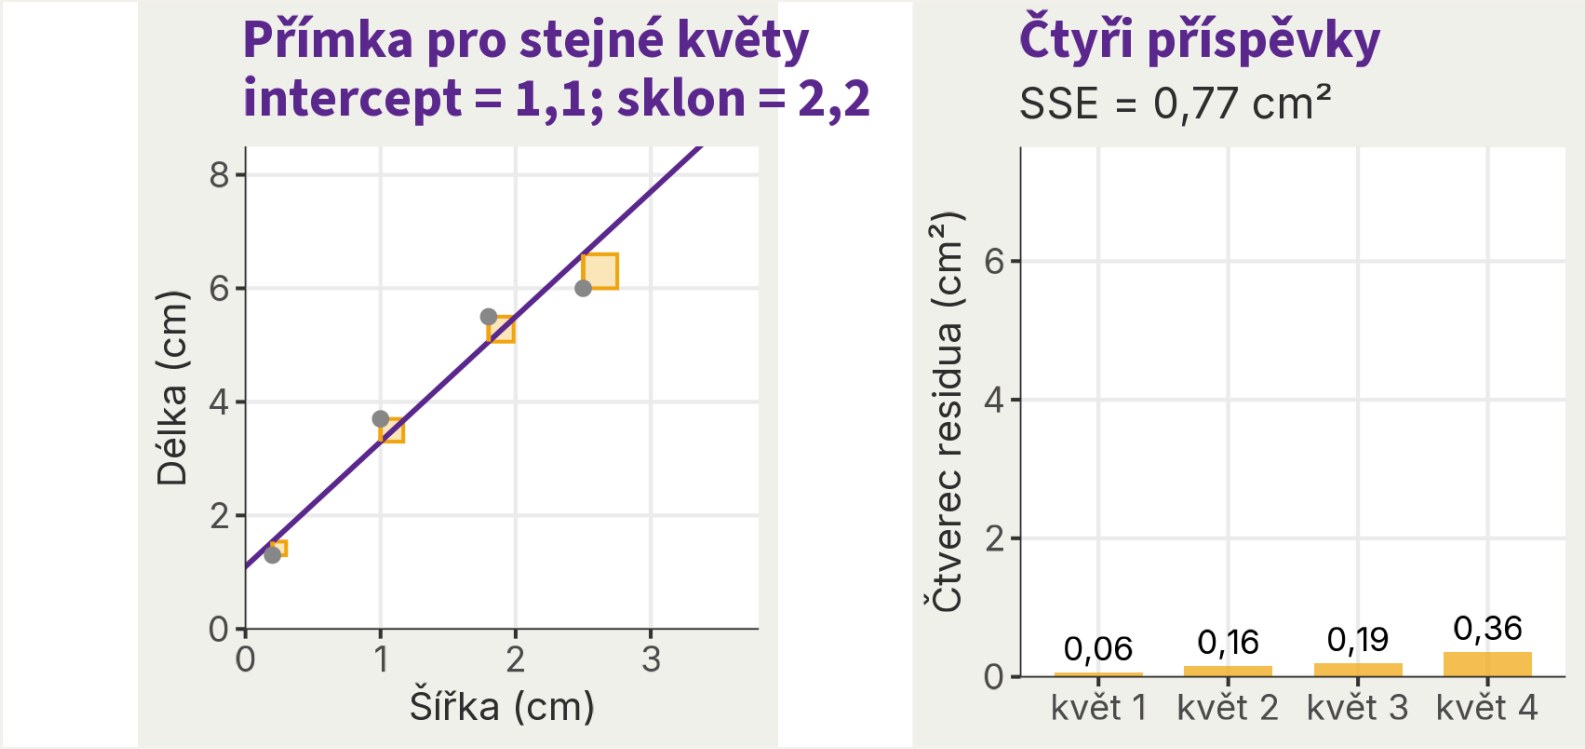




Sledujte jeden cyklus: Kdy je celková oranžová plocha nejmenší?

Stejné květy, jiné parametry přímky: strana = $|e_i|$ · plocha = e_i^2 · součet = **SSE**

Čtverce residuí čtyř květů



$$\begin{aligned}\text{SSE} &= (-0{,}24)^2 + (0{,}40)^2 \\ &\quad + (0{,}44)^2 + (-0{,}60)^2 \\ &\approx 0{,}77\ \text{cm}^2\end{aligned}$$

Stejná residua v R

```r
# Stejná čtyři měření jako v tabulce (cm)
vec_sirka <- c(0.2, 1.0, 1.8, 2.5)
vec_delka <- c(1.3, 3.7, 5.5, 6.0)

# Přímka B: intercept 1.1 cm, sklon 2.2 cm/cm
vec_odhad <- 1.1 + 2.2 * vec_sirka
vec_residua <- vec_delka - vec_odhad

# Prostý součet residuí, zaokrouhlený na setiny cm
round(
  x = sum(vec_residua),
  digits = 2
)
```

```
[1] 0
```

```r
# Součet čtverců residuí (cm²)
sum(vec_residua^2)
```

```
[1] 0.7712
```

> Prostý součet residuí je 0 cm, součet jejich čtverců ne. SSE má jednotku cm²; stejný princip použijeme pro všechny květy.

Která přímka je nejlepší podle těchto dat?

Přímka	Intercept (cm)	Sklon (cm/cm)	SSE pro 4 květy (cm^2)
A	0,5	1,8	6,25
B	1,1	2,2	0,77
C	1,7	2,6	6,82

Vyberte přímku s nejmenším SSE a vysvětlete, co toto číslo shrnuje.

Počítač hledá nejmenší součet čtverců

CO HLEDÁ `lm()`

Intercept a sklon, které dávají nejmenší SSE.

PROČ TUTO PŘÍMKU

Přímka leží podle zvoleného pravidla celkově nejblíže naměřeným bodům.

`lm()` použije statistické pravidlo: nejmenší součet čtverců residuí.

Přímka odhadnutá ze všech květů

Stejná měření v R

```r
# Načteme tabulku kosatců
data_kosatce <-
  read.csv(file = "data/kosatce.csv")
```

SLOUPCE SOUBORU

- `sirka_listku`: prediktor (cm)
- `delka_listku`: odezva (cm)
- `druh`, `delka_kalisniho_listku`: zatím mimo model

kosatce.csv: uložte do složky `data` ve svém projektu v R.

Co obsahuje `data_kosatce`?

```r
# Názvy, typy a první hodnoty sloupců
str(object = data_kosatce)
```

```
'data.frame':   150 obs. of  4 variables:
 $ sirka_listku          : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ delka_listku          : num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ druh                  : chr  "setosa" "setosa" "setosa" "setosa" ...
 $ delka_kalisniho_listku: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
```

```r
# Počet chybějících hodnot v každém sloupci
colSums(x = is.na(x = data_kosatce))
```

```
         sirka_listku           delka_listku                   druh
                    0                      0                      0
delka_kalisniho_listku
                    0
```

> Před modelováním zkontrolujte názvy, typy a chybějící hodnoty. Rozsahy obou měření jsme viděli v úvodní tabulce.

Jak funkce `lm()` spojuje odezvu a prediktor?

```
lm(
  formula = odezva ~ prediktor,
  data = data
)
```

`lm` = **l**inear **m**odel = lineární model

Znak `~` čteme: **odezvu vysvětlujeme pomocí prediktoru**.

VZOREC MODELU (`formula`)

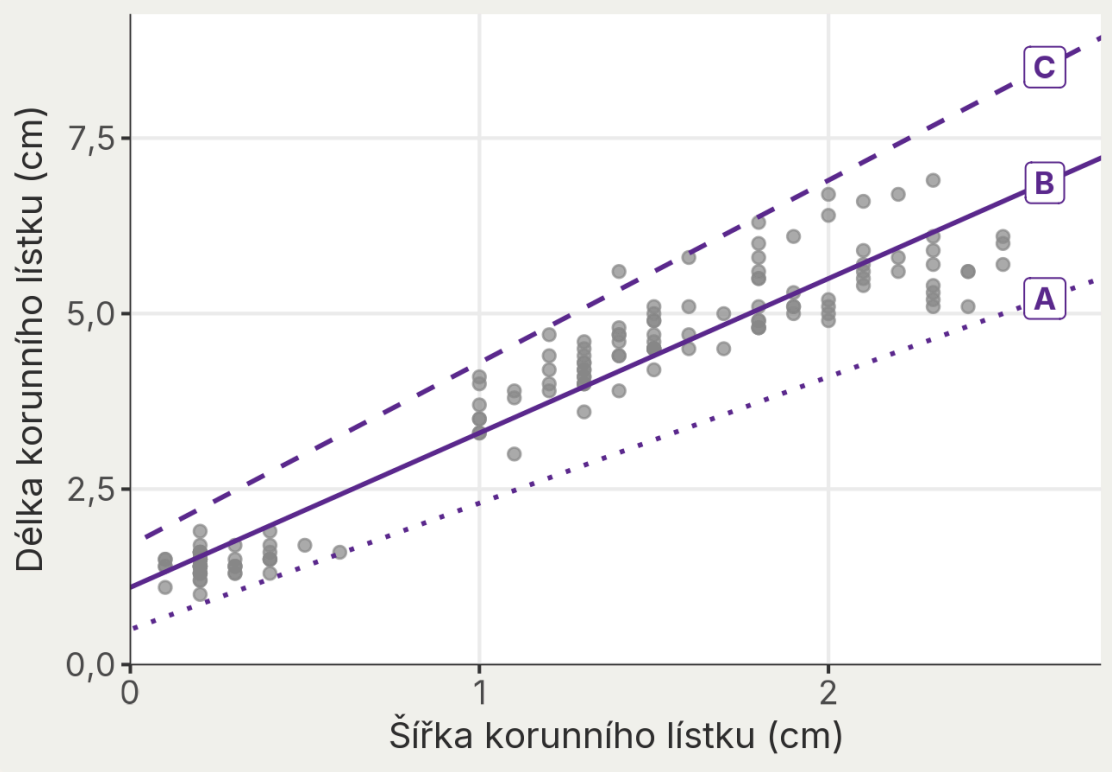
`delka_listku ~ sirka_listku`

odezva ~ prediktor

DATA (`data`)

`data_kosatce`: tabulka se všemi 150 květy

Jaké koeficienty model odhadne?



Přímka	Intercept (cm)	Sklon (cm/cm)
A	0,5	1,8
B	1,1	2,2
C	1,7	2,6

ODHADNĚTE PŘEDEM

`lm()` použije všech 150 květů. Bude **sklon** odhadnutého modelu nejblíž přímce A, B, nebo C?

Jaké koeficienty model odhadne?

```r
mod_listky <-
  lm(
    formula = delka_listku ~ sirka_listku,
    data = data_kosatce
  )
```

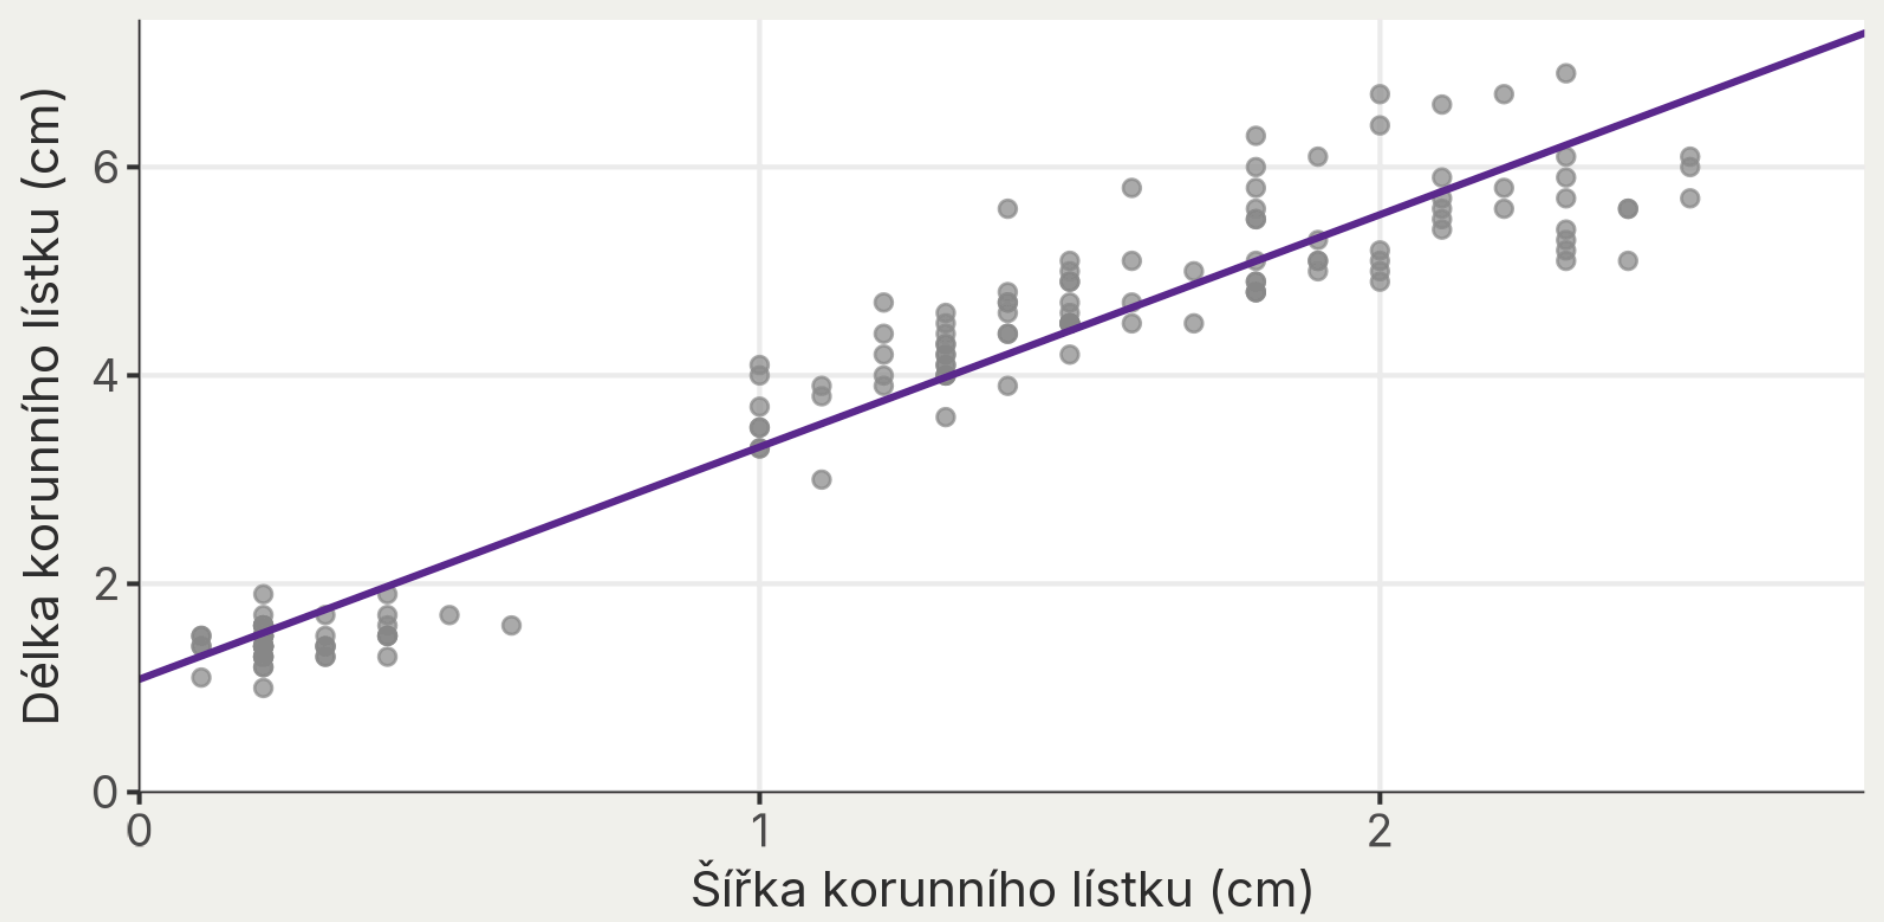
```r
coef(object = mod_listky)
```

```
(Intercept) sirka_listku
   1.083558     2.229940
```

Parametr	Odhad	Jednotka
Intercept	1,08	cm
Sklon	2,23	cm/cm

Odhadnutý **sklon 2,23 cm/cm** je nejblíž přímce B (2,2), ale není s ní totožný.

Přímka odhadnutá z těchto měření



Odhadnutá délka (cm) = 1,08 + 2,23 × šířka (cm)

Co znamená odhadnutý sklon?

Sklon je **2,23 cm/cm**. Která interpretace je správná?

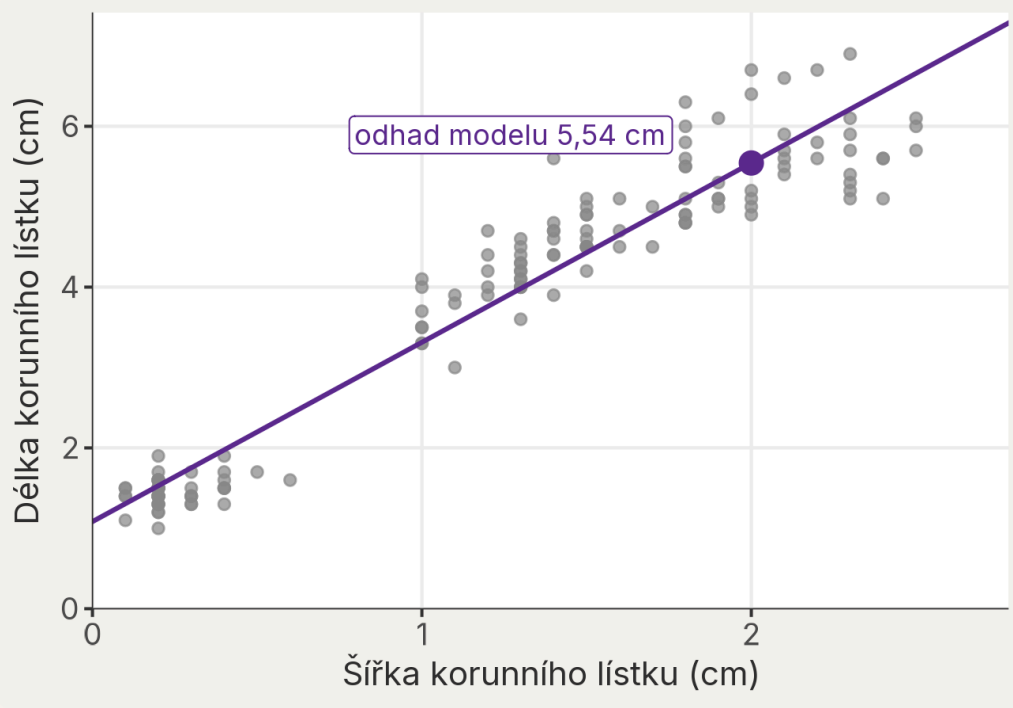
A) Přesný rozdíl délky u každé dvojice květů, jejichž šířky se liší o 1 cm.

B) Průměrný rozdíl délky dvou květů, jejichž šířky se liší o 1 cm.

C) Podíl variability délky, který vysvětluje šířka korunního lístku.

Zvolte A/B/C. Zdůvodněte, jaké dvě veličiny a jaké jednotky sklon spojuje.

Jakou délku čekáme u nového květu?



$$\begin{aligned}\text{odhadnutá délka} &= \text{intercept} \\ &\quad + \text{sklon} \cdot \text{šířka} \\ &= 1{,}08 + 2{,}23 \cdot 2 \\ &= 5{,}54 \text{ cm}\end{aligned}$$

VÁŠ ODHAD Z ÚVODU

Podobně široké květy měly v průměru 5,56 cm.

Lineární model vrací typickou délku pro danou šířku. Jednotlivé nové květy se od ní budou lišit; jak přesný je samotný odhad, ukáže příští lekce.

Co už víme o korunních lístcích?

Mají širší korunní lístky kosatců také větší délku — a pokud ano, o kolik?

CO MŮŽEME ŘÍCT

Ano. Dva květy, jejichž šířky se liší o 1 cm, se podle modelu liší v délce v průměru o **2,23 cm**.
U nového květu širokého 2 cm lineární model odhaduje délku **5,54 cm**.

CO ZATÍM NEVÍME

- Jak přesný je odhad **2,23 cm/cm**?
- Nepřehlíží jedna přímka systematický vzor?

Souvislost délky a šířky není důkaz příčiny

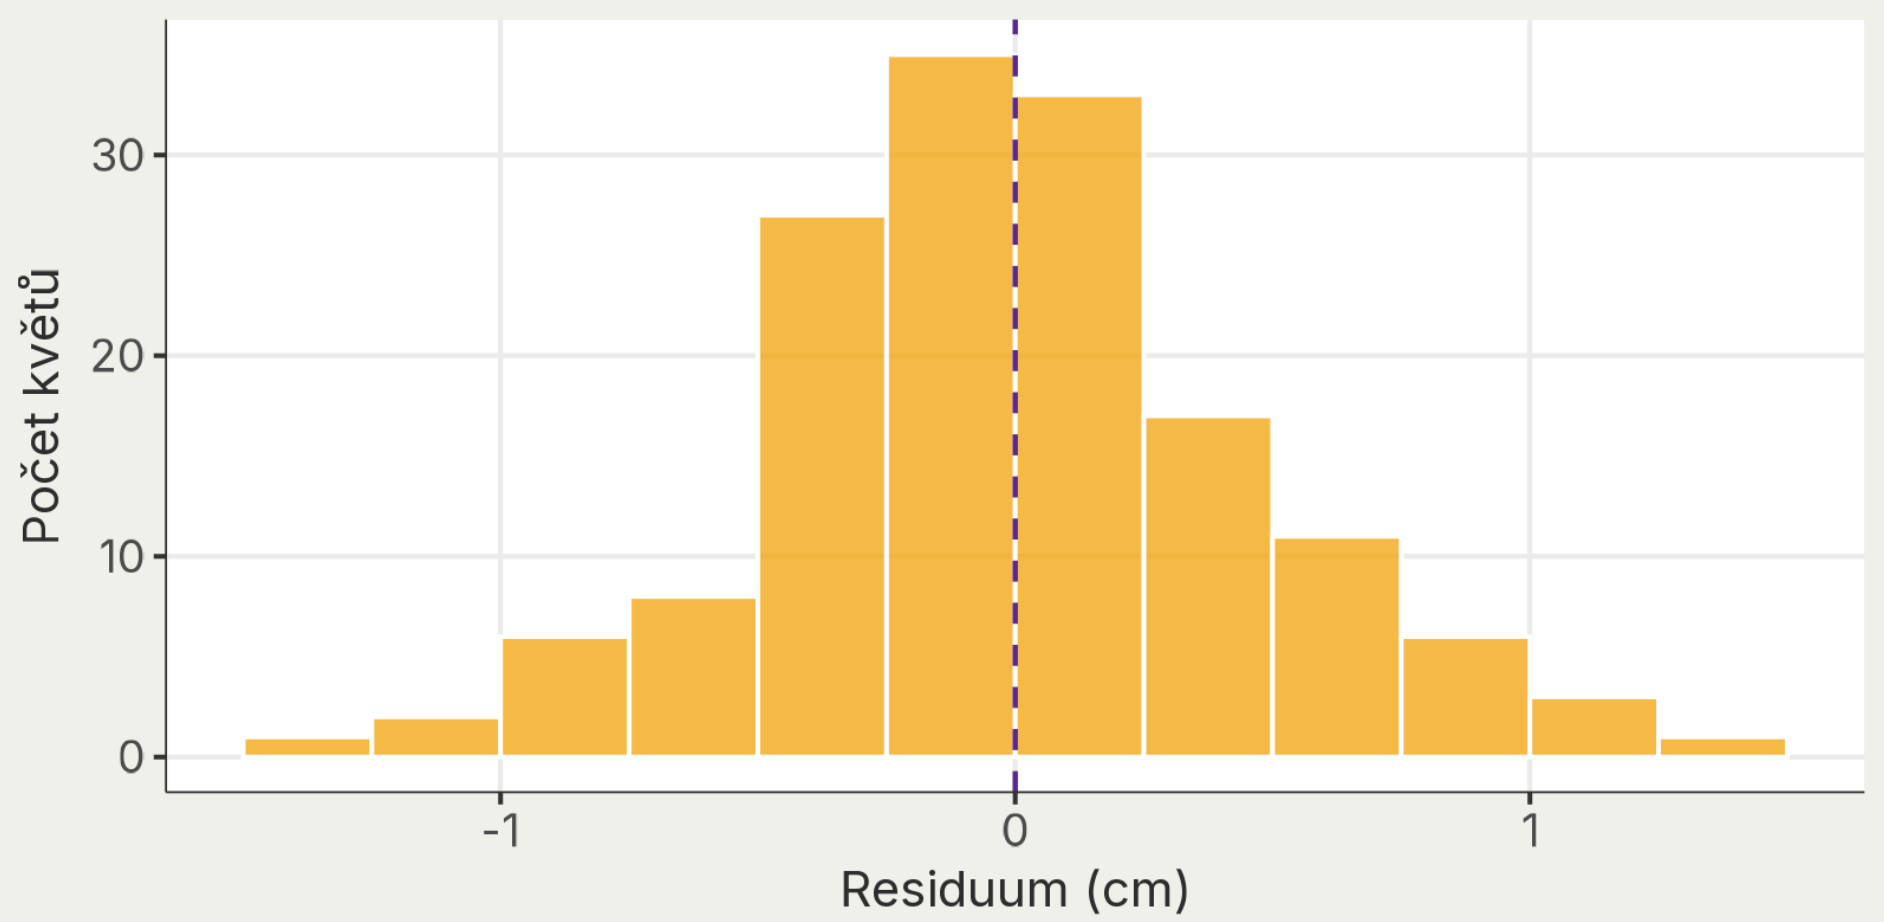
BIOLOGICKÝ ZÁVĚR

Asociace $\neq$ **příčina**

Model popisuje vztah v datech. Bez dalšího výzkumného designu neprokazuje, že větší šířka **způsobuje** větší délku.

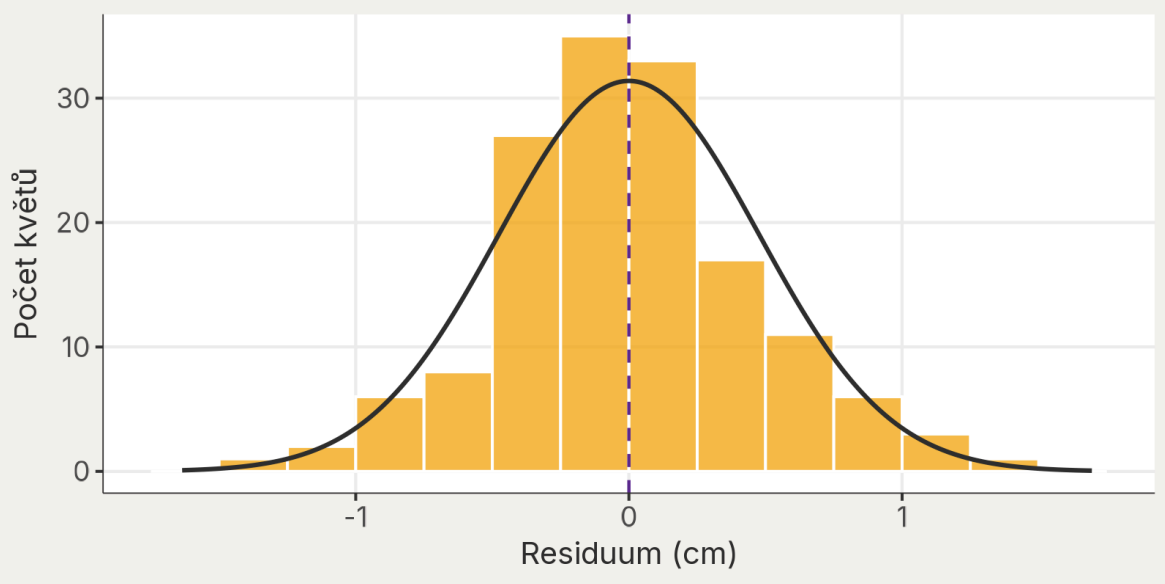
Co zůstává mimo přímku?

Jak jsou residua rozdělená?



Kde leží většina residuí a jak daleko sahají od nuly?

Stejná residua, ale s křivkou

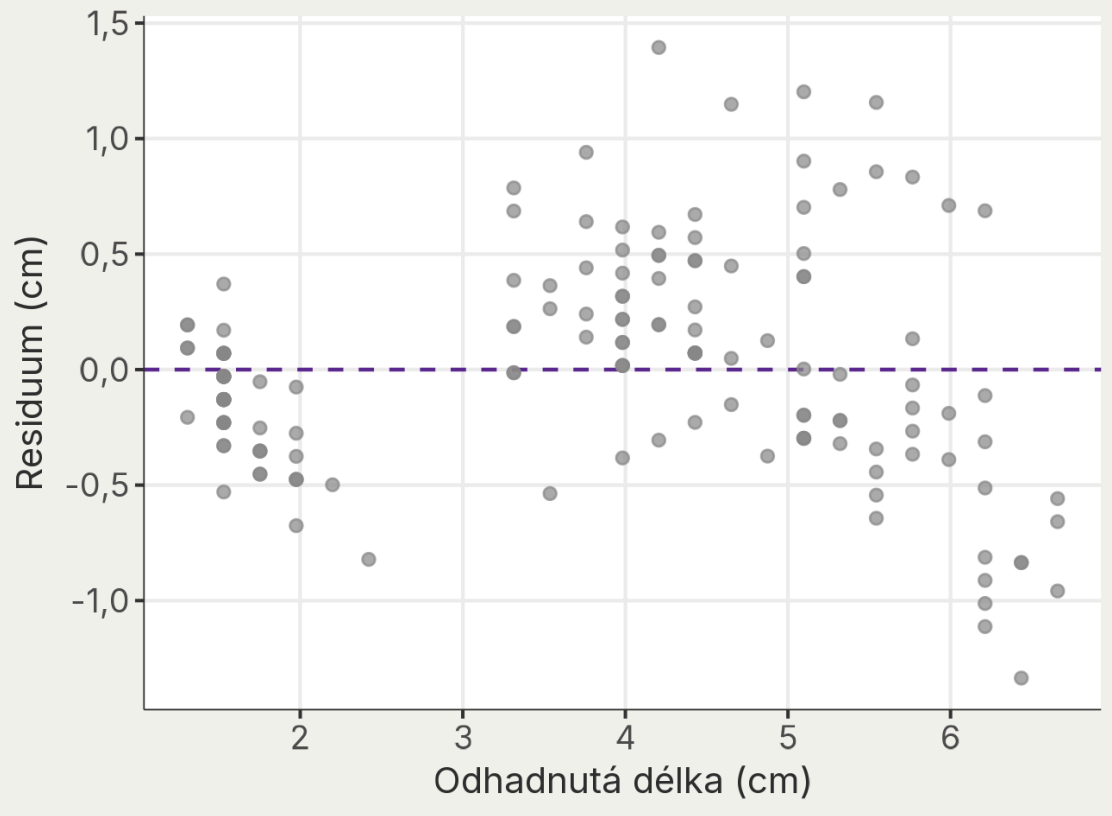


Většina residuí leží **blízko nuly**. Čím dál od nuly, tím jich je méně, na obě strany podobně.

Tmavá křivka ukazuje takový symetrický zvonovitý tvar. Říká se mu **normální rozdělení**.

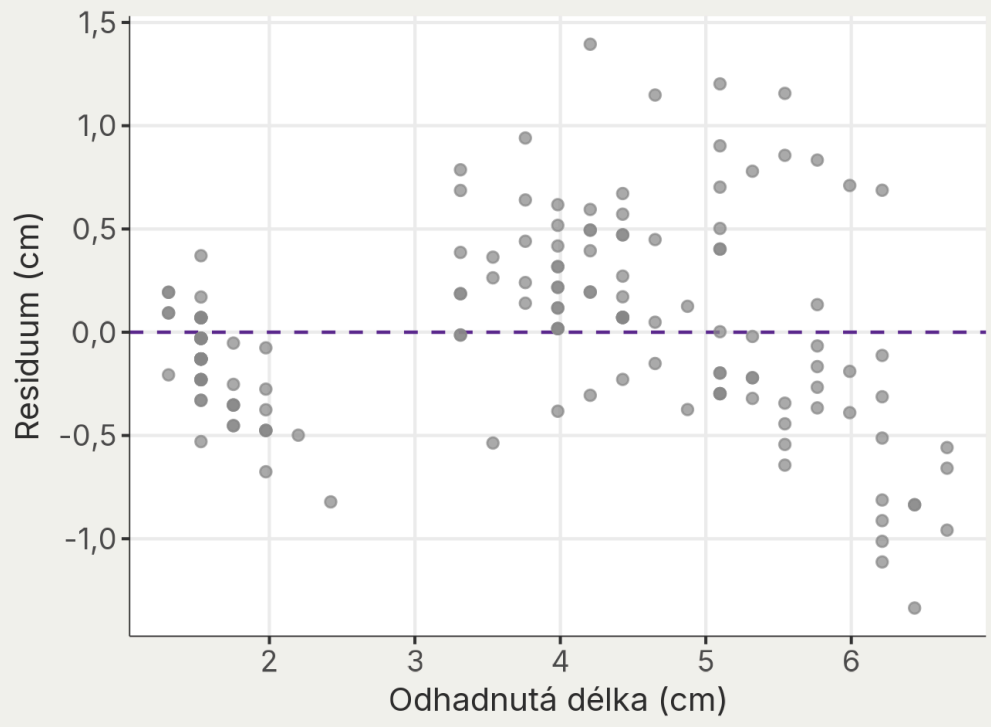
Lineární model předpokládá, že residua mají přibližně **normální rozdělení**. Proč na tom záleží, vysvětlíme v dalších lekcích.

Mění se residua podél odhadnuté délky?



- každý bod je jeden květ
- nad nulou model délku podhodnotil
- pod nulou model délku nadhodnotil
- hledáme neuspořádaný mrak kolem nuly

Vidíte neuspořádaný mrak, nebo zbývající vzor?

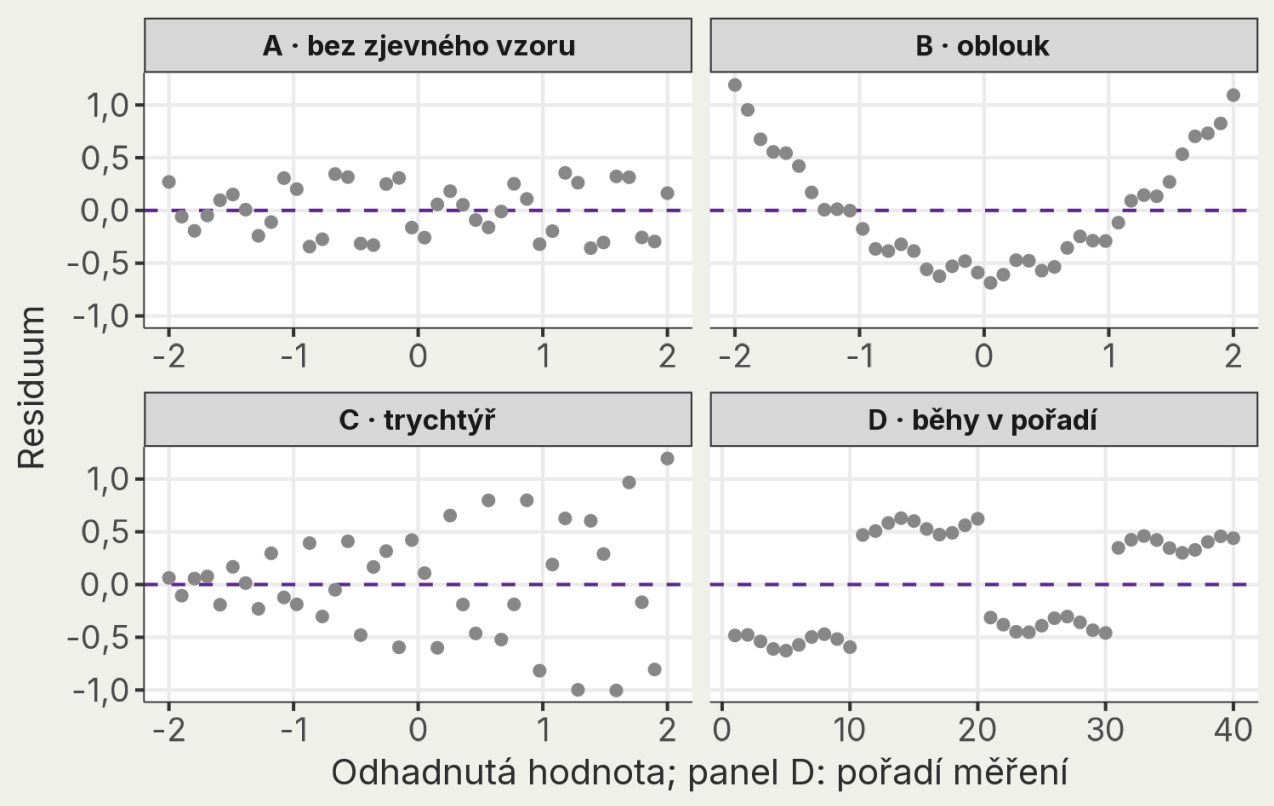


DISKUZE SE SOUSEDEM — 2 MIN

Najděte jednu oblast s převahou residuí nad nebo pod nulou. Co to říká o odhadované délce?

Které stopy by nás u přímky zneklidnily?

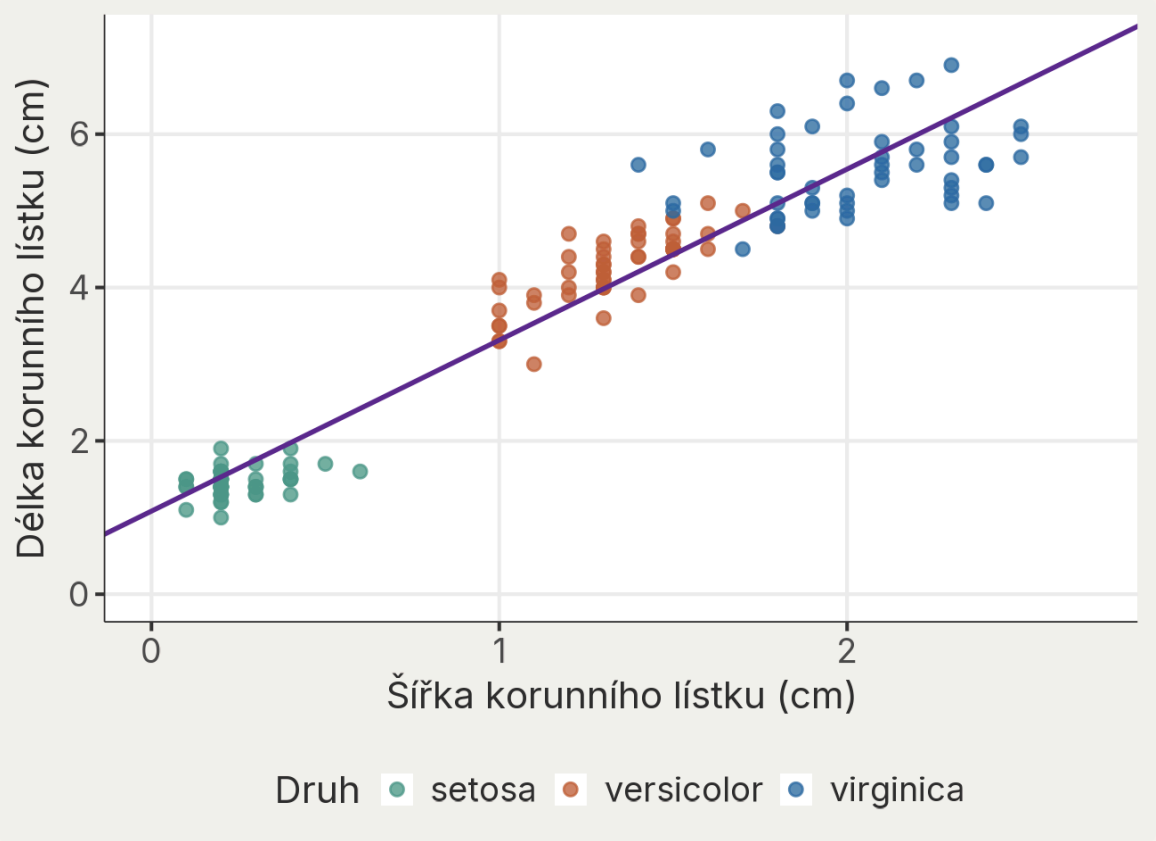
Schématické vzory; grafy nepředstavují další měření kosatců.



Přiřaďte: tvar vztahu · měnící se rozptýlení · pořadí měření.

B: tvar vztahu · C: měnící se rozptýlení · D: pořadí měření. A model neschvaluje.

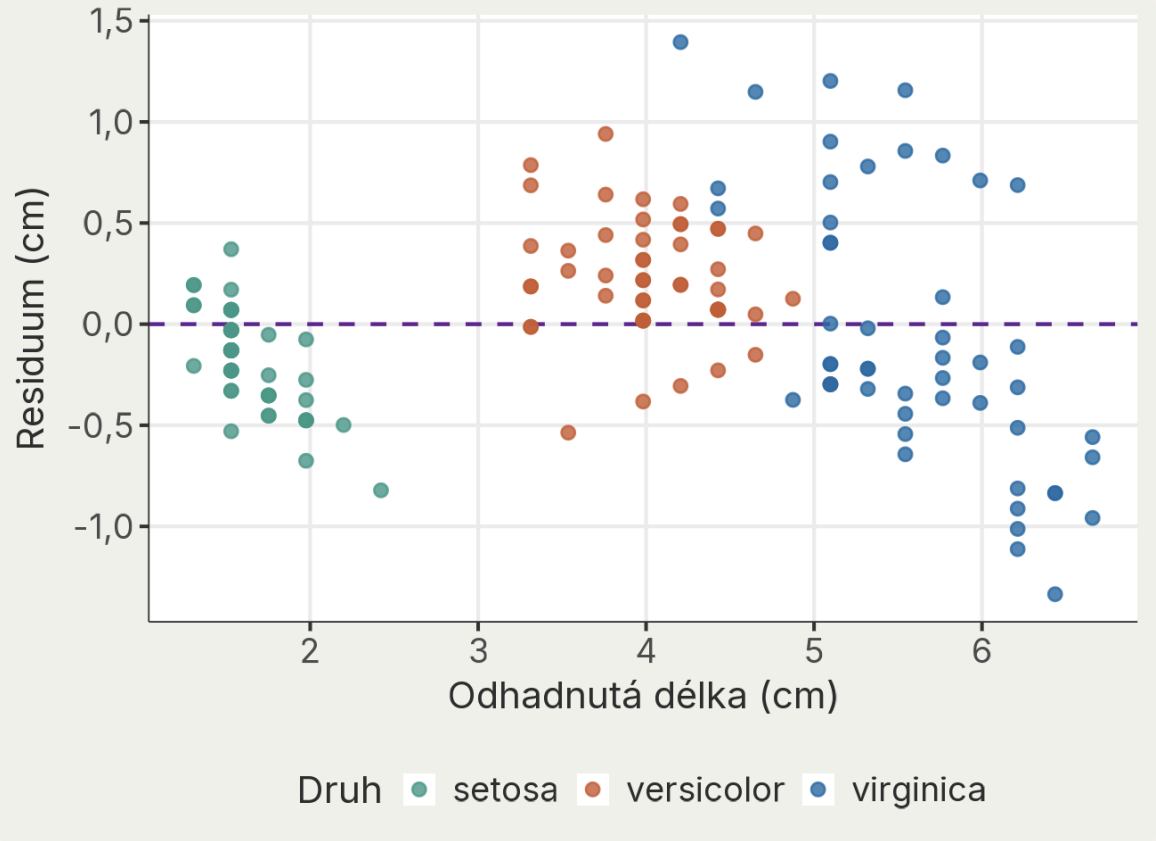
Stejná původní data, ale s druhem



CO VIDÍTE?

Tvoří tři druhy jeden společný mrak kolem přímky, nebo samostatné skupiny?

Stejná residua, ale s druhem



DISKUZE SE SOUSEDEM — 1 MIN

Který druh model spíše nadhodnocuje a který podhodnocuje? Podle čeho to poznáte?

Co model neviděl?

CHYBĚJÍCÍ PREDIKTOR

Druh kosatce

Jedna přímka zachytila celkový růst, ale druhy netvoří jeden společný mrak. Jejich struktura proto zůstává v residuích.

versicolor: 84 % residuí nad nulou → podhodnocuje · *setosa*: 78 % pod nulou → nadhodnocuje · *virginica*: 64 % pod nulou, hlavně nejširší květy

První model je začátek argumentu, ne jeho automatický konec.

Závěr

Shrnutí

- **Lineární model**: změříme **prediktor** a přímka vrátí odhadnutou **odezvu**.
- `lm()` hledá přímku s **nejmenším součtem čtverců residuí**; **sklon** je průměrný rozdíl odezvy mezi pozorováními, jejichž prediktor se liší o jednu jednotku.
- **Residuum** je rozdíl mezi naměřenou a odhadnutou hodnotou; ukazuje, co model u jednotlivých pozorování nevysvětlil.
- **Vzor v residuích** upozorňuje na chybějící strukturu nebo omezení modelu.

Co potřebujete vidět, než napíšete „o centimetr širší lístek, o 2,23 cm delší lístek“?

Jaké tři otázky položíte autorovi, který vám ukáže jen sklon 2,23 cm/cm bez grafu?

ŘEKNĚTE SOUSEDOVI JEDNOU VĚTOU

Kterou z otázek byste položili jako první, a proč?

Jak přesný je odhad sklonu? Následující lekce přidá nejistotu odhadu.