

Lineární model s jedním numerickým prediktorem

Biostatistika - L03

 Ondřej Mottl

Moodle

Naše biologická otázka



BIOLOGICKÁ OTÁZKA

Mají širší korunní lístky kosatců také větší délku — a pokud ano, o kolik?

CO BUDEME SLEDOVAT

150 květů


šířka a délka korunního lístku v centimetrech

Výsledky učení

Po absolvování této přednášky budete schopni:

- převést biologickou otázku na modelovou otázku s odezvou a prediktorem
- fitovat model $\text{lm}(y \sim x)$ a interpretovat směr i velikost efektu
- vysvětlit, co je residuum a co říká o konkrétním pozorování
- přečíst základní graf residuí a rozpoznat, že model něco systematicky nezachytil

Minule jsme skončili tady



PEARSONOVA KORELACE

$$r = 0.87$$

Rostoucí a poměrně
těsný vztah.

Co přidá model?

CO UŽ UMÍME

- vztah zobrazit
- popsat jeho směr
- shrnout jeho těsnost korelací

CO JEŠTĚ POTŘEBUJEME

O kolik se typicky změní odezva, když se prediktor zvýší o jednu jednotku?

Tato lekce přidá velikost efektu. Nejistotu odhadu přidáme v následující lekci.

Která proměnná má kterou roli?

OTÁZKA


Chceme odhadovat **délku** korunního lístku podle jeho **šířky**. Co je **odezva**?

A) šířka korunního lístku


B) délka korunního lístku

Když nehlasujeme: napište „odezva = ...“, prediktor = ...“ a doplňte názvy obou měření.

Všech 150 květů



Jaký vztah vidíte?




VYBERTE NEJLEPŠÍ POPIS

- A)** bez zřetelného vztahu
- B)** přibližně lineární růst
- C)** výrazně zakřivený růst

Když nehlasujeme: doplňte „S rostoucí šířkou délka v průměru ...“.

Co z grafu zatím můžeme říct?




CO VIDÍME

- vztah je rostoucí
- kolem trendu zůstává variabilita
- jednotlivé květy neleží na jedné přímce

CO JEŠTĚ NEVÍME

O kolik se odhadnutá délka změní při zvýšení šířky o 1 cm?


Která z mnoha přímek je správná?




DISKUZE SE SOUSEDEM — 30 S

Sledujte jeden cyklus. Podle čeho byste mezi přímkami rozhodli?

Tři kandidátní přímky




Kterou přímku byste vybrali?




Když nehlasujeme: zvolte A/B/C a napište, podle čeho posuzujete „nejlepší“ přímku.

Co se změní, když přímku posuneme?



Intercept (a) posouvá přímku nahoru nebo dolů.

Co se změní, když přímku nakloníme?



Sklon (b) říká, jak rychle se mění odhadnutá délka s rostoucí šířkou.

Dvě čísla popíše každou přímku

odhadnutá délka = intercept (a) + sklon (b) · šířka


intercept (a)

Kde přímka začíná při šířce 0 cm.


sklon (b)

Změna odhadnuté délky při zvýšení šířky o 1 cm.

Co přímka odhaduje pro jeden květ?




Přidáme jeden naměřený květ




Šedý bod: skutečně naměřená délka při šířce 2.5 cm.

Přímka vrátí odhad



Fialový bod: odhadnutá délka na přímce při stejné šířce.

Mezi měřením a odhadem zůstává rozdíl



Zaoblená oranžová úsečka ukazuje **residuum**.

Jaké znaménko má residuum?

Naměřená délka šedého bodu leží **pod** odhadem modelu. Residuum je:

A) kladné

B) záporné

C) nulové

Když nehlasujeme: doplňte „naměřená – odhadnutá = ...“, včetně znaménka.


Jak residuum počítáme?

NEJPRVE ODHAD MODELU

$$\text{odhadnutá délka} = \text{intercept} + \text{sklon} \cdot \text{šířka}$$

POTOM ROZDÍL

$$\text{residuum} = \text{naměřená délka} - \text{odhadnutá délka}$$




1. Odhadnutá délka

Naše přímka: **intercept (a) = 1.1 cm** · **sklon (b) = 2.2 cm/cm**

DOSADÍME HODNOTY


$$\begin{aligned}\text{odhadnutá délka} &= \text{intercept} + \text{sklon} \cdot \text{šířka} \\ &= 1.1 + 2.2 \cdot 2.5 \\ &= 6.6 \text{ cm}\end{aligned}$$



2. Residuum

NAMĚŘENÁ MINUS ODHADNUTÁ

$$\begin{aligned}\text{residuum} &= \text{naměřená délka} - \text{odhadnutá délka} \\ &= 6 - 6.6 \\ &= -0.6 \text{ cm}\end{aligned}$$



Zkráceně: $e_i = y_i - \hat{y}_i$

Residua očekáváme i u užitečného modelu

DŮLEŽITÁ MYŠLENKA

Biologická variabilita nezmizí jen proto, že jsme nakreslili přímku

Model nemusí trefit každý květ přesně. Potřebujeme ale zjistit, zda chyby působí náhodně, nebo zda v nich zůstává vzor.


Jak porovnat celé přímky?

1. Pro každý květ změříme residuum.
2. Residua umocníme, aby se kladné a záporné rozdíly nevyrušily.
3. Čtverce sečteme do jednoho čísla: **SSE**.

Menší SSE znamená, že body leží celkově blíže přímce.


Když se přímka mění, mění se i chyby

intercept = 0
sklon = 3.4



Čtverce residuí

SSE pro 4 květy = 8.52



Sledujte jeden cyklus: Kdy je celková oranžová plocha nejmenší?

Co se mění: strana = $|e_i|$ · plocha = e_i^2 · součet = **SSE**

Která přímka je nejlepší podle dat?

Přímka	Intercept	Sklon	SSE pro 4 květy
A	0.5	2.3	0.53
B	1.1	2.2	0.45
C	1.7	1.9	0.86

Když nehlasujeme: vyberte přímku s nejmenším SSE a jednou větou vysvětlete, co toto číslo shrnuje.

Počítač najde nejlepší přímku

`lm()` najde intercept a sklon, které minimalizují SSE.

My už ale víme, **co** hledá a **proč** právě tuto přímku preferuje.

Stejná data v R

```
1 data(iris)
2
3 data_kosatce <-
4   data.frame(
5     sirka_listku = iris$Petal.Width,
6     delka_listku = iris$Petal.Length,
7     druh = iris$Species
8   )
```

TŘI SLOUPCE

- sirka_listku: prediktor
- delka_listku: odezva
- druh: zatím mimo model

Co obsahuje data_kosatce?

```
1 summary(data_kosatce)
```

sirka_listku	delka_listku	druh
Min. :0.100	Min. :1.000	setosa :50
1st Qu.:0.300	1st Qu.:1.600	versicolor:50
Median :1.300	Median :4.350	virginica :50
Mean :1.199	Mean :3.758	
3rd Qu.:1.800	3rd Qu.:5.100	
Max. :2.500	Max. :6.900	

Před modelováním vždy nejprve zkontrolujeme názvy, rozsahy a případné chybějící hodnoty.

Gramatika funkce `lm()`

```
1 lm(  
2   formula = odezva ~ prediktor,  
3   data = data  
4 )
```

Znak `~` čteme: **odezvu vysvětlujeme pomocí prediktoru.**

Dosadíme názvy z naší otázky

FORMULA

```
delka_listku ~ sirka_listku  
odezva ~ prediktor
```

DATA

```
data = data_kosatce  
tabulka se všemi 150 květy
```

Fitujeme první model

```
1 mod_listky <-  
2   lm(  
3     formula = delka_listku ~ sirka_listku,  
4     data = data_kosatce  
5   )
```

Model ukládáme jako `mod_listky`, abychom se k němu mohli vracet.

Jaké koeficienty model odhadl?

```
1 coef(mod_listky)
```

```
(Intercept) sirka_listku  
1.083558      2.229940
```

ODHADNUTÉ KOEFICIENTY

- intercept: **1.08 cm**
- sklon: **2.23 cm/cm**

Co znamená odhadnutý sklon?

Sklon je **2.23 cm/cm**. Která interpretace je správná?

A) Přesná změna každého jednotlivého květu.

B) Průměrná změna délky při zvýšení šířky o 1 cm.

C) Procento variability vysvětlené šířkou.

Bez hlasování: přepište B vlastními slovy; zachovejte **1 cm** a **v průměru**.

Vracíme se k biologické otázce

Mají širší korunní lístky kosatců také větší délku, a pokud ano, jak velká je tato změna?

CO MŮŽEME ŘÍCT

Při zvýšení šířky o 1 cm model odhaduje v průměru zvýšení délky o **2.23 cm**.

Co ještě nevíme?

NEJISTOTA

Jak přesný je odhad **2,23 cm/cm**?

ZBÝVAJÍCÍ STRUKTURA

Přehlíží jedna přímka systematický vzor?


Směr a velikost nejsou příčina

BIOLOGICKÝ ZÁVĚR


Asociace $\neq$ příčina

Model popisuje vztah v datech. Bez dalšího výzkumného designu neprokazuje, že větší šířka **způsobuje** větší délku.

Co zůstalo po odhadu přímky?



Jak tento graf čteme?



- každý bod je jeden květ
- nad nulou model délku podhodnotil
- pod nulou model délku nadhodnotil
- hledáme neuspořádaný mrak kolem nuly


Vidíte náhodný mrak, nebo zbývající vzor?

Prohlédněte si graf 30 sekund a najděte jednu část, která vás zneklidňuje.


DISKUZE SE SOUSEDEM — 2 MIN

Popište pouze to, co v grafu vidíte. Zatím nenavrhujte řešení.

Stejná původní data, ale s druhem



Stejná residua, ale s druhem



Co model neviděl?

CHYBĚJÍCÍ PREDIKTOR

Druh kosatce

Jedna přímka zachytila celkový růst, ale druhy netvoří jeden společný mrak. Jejich struktura proto zůstává v residuích.

Co ještě z lineárního modelu neplyne?

- neznáme nejistotu odhadnutého sklonu
- neprokázali jsme příčinný mechanismus
- nezahrnuli jsme druh kosatce jako další prediktor
- nevyřešili jsme všechny možné diagnostické problémy

První model je začátek argumentu, ne jeho automatický konec.

Shrnutí

- Biologickou otázku převádíme na odezvu a prediktor.
- Sklon popisuje změnu odhadnuté odezvy při změně prediktoru o jednu jednotku.
- `lm()` hledá přímku s nejmenším součtem čtverců residuí.
- Residua ukazují, co model u jednotlivých pozorování nevysvětlil.
- Vzor v residuích upozorňuje na chybějící strukturu nebo omezení modelu.

Poslední kontrola

MODEL MÁ KLADNÝ SKLON

Co zkontrolujete před biologickou interpretací?

MINIMÁLNÍ ODPOVĚĎ

Residua a biologický kontext modelu.