

Lineární model s jedním kvantitativním prediktorem

Biostatistika - L03

 Ondřej Mottl

Moodle

Výsledky učení

Po absolvování této přednášky budete schopni:

- fitovat $\text{lm}(y \sim x)$ a interpretovat směr a velikost efektu
- vysvětlit, co jsou rezidua a proč je sledujeme
- popsat základní diagnostiku modelu pomocí jednoduchých grafů

Biologická otázka

Jak se mění objem kmene stromu s rostoucím obvodem kmene?

Nejdřív se podíváme na data, pak pojmenujeme model, a teprve potom budeme interpretovat koeficienty.

Data, se kterými začneme

Dataset `trees` obsahuje měření obvodu (`Girth`) a objemu (`Volume`) kmenů.

První krok: podívat se, jestli data naznačují přibližně lineární vztah.


Otázka k zamyšlení

Před zobrazením regresní přímky odhadněte:

- a. vztah je téměř nulový
- b. vztah je kladný a zřetelný
- c. vztah je silně nelineární

Když nehlasujeme: napište si vlastní volbu a jednou větou ji obhájte sousedovi.

První pohled na vztah v datech



Pojmenování modelu

Lineární model pro tuto otázku:

$$\text{Volume}_i = a + b \cdot \text{Girth}_i + e_i$$

Co nás zajímá nejvíc:

- směr koeficientu b
- velikost změny odezvy při zvýšení prediktoru
- co zůstává v reziduích

Ukázkový kód pro studenty

```
1 data(trees)
2
3 mod_objem <-
4   lm(
5     formula = Volume ~ Girth,
6     data = trees
7   )
8
9 ggplot2::ggplot(
10  data = trees,
11  mapping = ggplot2::aes(x = Girth, y = Volume)
12 ) +
13  ggplot2::geom_point(size = 2, alpha = 0.85, color = "#8A8A8A") +
14  ggplot2::geom_smooth(method = "lm", se = FALSE, color = "#5D2890", linewidth = 1) +
15  ggplot2::labs(
16    x = "Obvod kmene (Girth)",
17    y = "Objem kmene (Volume)"
18  ) +
19  ggplot2::theme_minimal()
```

```
1 summary(mod_objem)
```

Call:

```
lm(formula = Volume ~ Girth, data = trees)
```

Residuals:

Min	1Q	Median	3Q	Max
-----	----	--------	----	-----

Diskuze ve dvojicích (2 min)

Která část výstupu `summary(mod_objem)` je pro biologickou interpretaci důležitější než samotná p-hodnota?

- vysvětlíte sousedovi proč
- dohodněte se na jedné větě, kterou byste použili v biologické interpretaci

Interpretační úkol: rezidua

Představte si diagnostický graf reziduí:

- Co by vás varovalo, že lineární model není vhodný?
- Jaký vzor v reziduích by naznačoval nelinearitu?

Nejde o „správný obrázek naslepo“, ale o argument: proč by daný vzor byl problém pro interpretaci modelu.

Co už víme / Co ještě nevíme

CO UŽ VÍME

- Obvod kmene a objem jsou v datech zjevně propojené.
- Jednoduchý lineární model je rozumný první krok.

CO JEŠTĚ NEVÍME

- Jak velká je nejistota odhadu koeficientu?
- Kdy by stejný přístup naopak selhal?

Kontrola častého omylu

„Když body přibližně rostou, máme hotovo.“

To je nebezpečné zjednodušení. Po vizuálním trendu vždy potřebujeme ještě zkontrolovat rezidua a interpretaci efektu v biologickém kontextu.

Shrnutí

- Lineární model zavádí hlavní pracovní rámec.
- Začínáme biologickou otázkou a grafem, ne názvem metody.
- Koeficient modelu interpretujeme jako biologicky smysluplnou změnu odezvy.
- Rezidua používáme jako kontrolu toho, co model nevysvětluje.

Závěrečná otázka

Ve které situaci by pro vztah dvou proměnných byl jednoduchý $\text{lm}(y \sim x)$ nevhodný, i když bodový graf na první pohled vypadá lineárně?

Zapište si jednu podmínku, kterou byste před použitím tohoto modelu vždy zkontrolovali.