



L03

Mají širší korunní lístky kosatců také větší délku — a pokud ano, o kolik?



Lineární model s jedním numerickým prediktorem

cuni-natur-biostatistics.github.io/materialy.html

Ilustrace vytvořená pomocí AI.

Jakou délkou odhadneme z naměřené šířky?



BIOLOGICKÁ OTÁZKA

Mají širší korunní lístky kosatců také větší délku — a pokud ano, o kolik?

CO BUDEME SLEDOVAT


150 květů

šířka a délka korunního lístku v centimetrech

Co si pamatujete z minulé lekce?

Odpovězte samostatně na tři krátké otázky. Potom společně projdeme správné odpovědi.

Máme délku ploutve a tělesnou hmotnost každého tučňáka. Který graf je vhodný jako první pohled na jejich vztah?



Bodový graf

Jeden histogram

Koláčový graf


Tabulka četností kategorií

SPRÁVNÁ ODPOVĚĎ

: Bodový graf

Obě proměnné jsou číselné a každá dvojice měření patří jednomu tučňákovi. Bodový graf zachová obě hodnoty i jejich párování.

Jaký směr vztahu vidíme v bodovém grafu délky ploutve a tělesné hmotnosti?



Převážně klesající

Bez viditelného směru

Graf ukazuje pouze jednu proměnnou


Převážně rostoucí

SPRÁVNÁ ODPOVĚĎ

: Převážně rostoucí

Tučníci s delší ploutví bývají v tomto souboru těžší. Body proto tvoří převážně rostoucí oblak.

Které tvrzení odpovídá tomu, co z tohoto pozorovacího grafu smíme vyvodit?



Delší ploutev způsobuje vyšší tělesnou hmotnost.

Tělesná hmotnost způsobuje růst ploutve.

Délka ploutve a tělesná hmotnost spolu v těchto datech souvisejí.

Druh tučňáka nemůže vztah ovlivnit.

SPRÁVNÁ ODPOVĚĎ

: Délka ploutve a tělesná hmotnost spolu v těchto datech souvisejí.

Graf podporuje tvrzení o asociaci v pozorovaných datech. Sám neurčuje příčinu ani nevylučuje další proměnné.

Výsledky učení

Po absolvování této přednášky budete schopni:

- převést biologickou otázku na vztah mezi odezvou a prediktorem
- fitovat `lm(odezva ~ prediktor)` a interpretovat směr i velikost efektu
- vysvětlit residuum jako rozdíl mezi naměřenou a odhadnutou hodnotou
- číst graf residuí a rozpoznat v něm zbývající vzor

Dvě měření, dvě role

Co chceme zjistit ze známé šířky?

V minulé lekci jsme popsali vztah délky ploutve a hmotnosti tučňáků. U kosatců se ptáme: **o kolik delší korunní lístek očekáváme u květu, jehož lístek je o 1 cm širší?**

Co přidá **model**?

VZTAH DVOU MĚŘENÍ

- **vztah zobrazit**
- popsat jeho směr
- shrnout jeho těsnost korelací

DÉLKA PODLE ZNÁMÉ ŠÍŘKY

O kolik se typicky liší délka dvou květů, jejichž šířky se liší o 1 cm?

Model vyjádří **velikost efektu** v původních jednotkách. **Přesnost odhadu** zůstává otevřená.

Jedna přímka shrnuje mnoho květů



Ilustrační obraz vytvořen AI.

Modelová přímka data nenahrazuje. Stručně popisuje jejich systematický vztah.

Která proměnná má kterou roli?

OTÁZKA

Na jednom korunním lístku známe jedno měření a druhé podle něj odhadujeme. Které měření bude **neznámé, odhadované**?

A) šířka korunního lístku

B) délka korunního lístku

Zvolte A/B a zdůvodněte svou volbu sousedovi.

Odhadovanou délku nazýváme **odezva**, známou šířku **prediktor**.

Dvě měření každého květu


Květ	Šířka (cm)	Délka (cm)	Druh
1	0,2	1,3	setosa
2	1,0	3,7	versicolor
3	1,8	5,5	virginica
4	2,5	6,0	virginica

Jeden řádek = jeden květ · dvě
numerická měření · druh jako
kategorie

CELÁ DATA

150 květů · 0 chybějících hodnot
Šířky 0,1–2,5 cm · délky 1–6,9 cm

Jaký vztah vidíte?




VYBERTE NEJLEPŠÍ POPIS

- A)** bez zřetelného vztahu
- B)** přibližně lineární růst
- C)** výrazně zakřivený růst

Zvolte A/B/C a zdůvodněte odpověď podle bodů v grafu.

Co z tohoto grafu můžeme říct?



CO VIDÍME


- vztah je rostoucí
- kolem trendu zůstává variabilita
- jednotlivé květy neleží na jedné přímce

OTÁZKA NA VELIKOST ZMĚNY

O kolik se liší odhadnutá délka dvou květů, jejichž šířky se liší o 1 cm?

Co rozhoduje mezi přímkami?


Která z mnoha přímek vystihuje měření?



DISKUZE SE SOUSEDEM — 30 S

Sledujte jeden cyklus. Podle čeho byste mezi přímkami rozhodli?


Kterou ze tří přímek byste vybrali?



HLASOVÁNÍ


Zvolte A, B, nebo C a napište, podle čeho posuzujete nejlepší přímku.

Co se změní, když přímku posuneme?



Intercept (a) posouvá přímku nahoru nebo dolů.

Co se změní, když přímku nakloníme?



Sklon (b) říká, jak rychle se mění odhadnutá délka s rostoucí šířkou.

Dvě čísla popíší každou přímku

odhadnutá délka = intercept (a) + sklon (b) · šířka

intercept (a)


Výška přímky při šířce 0 cm.

sklon (b)

Rozdíl odhadnutých délek dvou šířek, které se liší o 1 cm.


Jak daleko je měření od přímky?

Jeden květ a přímka B




Přímka B · šedý bod = květ 4 z tabulky: šířka **2,5 cm**, naměřená délka **6 cm**

Odhad přímky pro stejnou šířku



Fialový bod: odhadnutá délka na přímce při stejné šířce.

Mezi měřením a odhadem zůstává rozdíl



Oranžová úsečka ukazuje **residuum**: rozdíl mezi naměřenou a odhadnutou délkou.

Jaké znaménko má residuum?



residuum = naměřená délka
– odhadnutá délka

A) kladné

B) záporné


C) nulové

Zvolte znaménko a zdůvodněte je polohou bodu vůči přímce.

Odhadnutá délka vybraného květu

Přímka B: **intercept (a) = 1,1 cm** · **sklon (b) = 2,2 cm/cm**

$$\begin{aligned}\text{odhadnutá délka} &= \text{intercept} \\ &+ \text{sklon} \cdot \text{šířka} \\ &= 1,1 + 2,2 \cdot 2,5 \\ &= 1,1 + 5,5 \\ &= 6,6 \text{ cm}\end{aligned}$$



Residuum vybraného květu

residuum = naměřená délka
– odhadnutá délka
= 6 – 6,6
= –0,6 cm



y_i = naměřená délka · $\hat{y}_i$ = odhadnutá délka · e_i = residuum · i = pořadí květu; vše v cm. $e_i = y_i - \hat{y}_i$

Residua očekáváme i u užitečného modelu

DŮLEŽITÁ MYŠLENKA

Biologická variabilita nezmizí jen proto, že jsme nakreslili modelovou přímku

Model nemusí trefit každý květ přesně. Potřebujeme ale zjistit, zda odchylky působí náhodně, nebo zda v nich zůstává vzor.

Čtyři květy, stejná přímka

Květ	Šířka (cm)	Délka (cm)	Odhad (cm)	Residuum (cm)
1	0,2	1,3	1,54	-0,24
2	1,0	3,7	3,30	0,40
3	1,8	5,5	5,06	0,44
4	2,5	6,0	6,60	-0,60

Součet residuí: **0 cm**. Kladná a záporná residua se vyruší, přestože přímka žádným bodem neprochází.



Jak porovnat celé přímky?

1 · ZMĚŘIT ROZDÍL

Pro každý květ určíme
residuum.

2 · ODSTRANIT ZNAMÉNKO

Každé residuum
umocníme.


3 · SHRNOU PŘÍMKU

Čtverce sečteme do
jednoho čísla: SSE.

Menší SSE znamená, že body leží celkově blíže přímce.


Jiná přímka, jiné vzdálenosti

Přímka pro stejné květy
intercept = 0; sklon = 3,4



Sledujte jeden cyklus: Kdy je celková oranžová plocha nejmenší?


Čtyři příspěvky
SSE = 7,11 cm²



Stejné květy, jiné parametry přímky: strana = $|e_i|$ · plocha = e_i^2 · součet = **SSE**


Čtverce residuí čtyř květů

Přímka pro stejné květy
intercept = 1,1; sklon = 2,2



Čtyři příspěvky

SSE = 0,77 cm²



$$\begin{aligned} \text{SSE} &= (-0,24)^2 + (0,40)^2 \\ &\quad + (0,44)^2 + (-0,60)^2 \\ &\approx 0,77 \text{ cm}^2 \end{aligned}$$

Stejná residua v R

```
1 # Stejná čtyři měření jako v tabulce (cm)
2 vec_sirka <- c(0.2, 1.0, 1.8, 2.5)
3 vec_delka <- c(1.3, 3.7, 5.5, 6.0)
4
5 # Přímka B: intercept 1.1 cm, sklon 2.2 cm/cm
6 vec_odhad <- 1.1 + 2.2 * vec_sirka
7 vec_residua <- vec_delka - vec_odhad
8
9 # Prostý součet residuí, zaokrouhlený na setiny cm
10 round(
11   x = sum(vec_residua),
12   digits = 2
13 )
```

```
[1] 0
```

```
1 # Součet čtverců residuí (cm²)
2 sum(vec_residua^2)
```

```
[1] 0.7712
```

Prostý součet residuí je 0 cm, součet jejich čtverců ne. SSE má jednotku cm^2 ; stejný princip použijeme pro všechny květy.

Která přímka je nejlepší podle těchto dat?

Přímka	Intercept (cm)	Sklon (cm/cm)	SSE pro 4 květy (cm ²)
A	0,5	1,8	6,25
B	1,1	2,2	0,77
C	1,7	2,6	6,82

Vyberte přímku s nejmenším SSE a vysvětlete, co toto číslo shrnuje.

Počítač hledá nejmenší součet čtverců

CO HLEDÁ `lm()`

Intercept a sklon, které dávají nejmenší SSE.

PROČ TUTO PŘÍMKU

Přímka leží podle zvoleného pravidla celkově nejbliže naměřeným bodům.

`lm()` použije statistické pravidlo: nejmenší součet čtverců residuí.

Přímka odhadnutá ze všech květů

Stejná měření v R

```
1 # Načteme tabulku kosatců
2 data_kosatce <-
3   read.csv(file = "data/kosatce.csv")
```

SLOUPCE SOUBORU

- sirka_listku: prediktor (cm)
- delka_listku: odezva (cm)
- druh,
delka_kalisniho_listku: zatím
mimo model

Co obsahuje data_kosatce?

```
1 # Názvy, typy a první hodnoty sloupců
2 str(object = data_kosatce)
```

```
'data.frame':  150 obs. of  4 variables:
 $ sirka_listku      : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ delka_listku      : num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ druh             : chr   "setosa" "setosa" "setosa" "setosa" ...
 $ delka_kalisniho_listku: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
```

```
1 # Počet chybějících hodnot v každém sloupci
2 colSums(x = is.na(x = data_kosatce))
```

	sirka_listku	delka_listku	druh
	0	0	0
delka_kalisniho_listku			
	0		

Před modelováním zkontrolujte názvy, typy a chybějící hodnoty. Rozsahy obou měření jsme viděli v úvodní tabulce.

Jak funkce `lm()` spojuje odezvu a prediktor?

```
1 lm(  
2   formula = odezva ~ prediktor,  
3   data = data  
4 )
```

Znak `~` čteme: **odezvu vysvětlujeme pomocí prediktoru.**

VZOREC MODELU (`formula`)

`delka_listku ~ sirka_listku`
`odezva ~ prediktor`

DATA (`data`)

`data_kosatce`: tabulka se všemi 150 květy

Jaké koeficienty model odhadne?

ODHADNĚTE PŘEDEM

Bude odhadnutý sklon blíž přímce A (1,8), B (2,2), nebo C (2,6)?


```
1 mod_listky <-  
2   lm(  
3     formula = delka_listku ~ sirka_listku,  
4     data = data_kosatce  
5   )
```

```
1 coef(object = mod_listky)
```

```
(Intercept) sirka_listku  
1.083558      2.229940
```

Parametr	Odhad	Jednotka
Intercept	1,08	cm
Sklon	2,23	cm/cm

Přímka odhadnutá z těchto měření



$$\text{Odhadnutá délka (cm)} = 1,08 + 2,23 \times \text{šířka (cm)}$$

Co znamená odhadnutý **sklon**?

Sklon je **2,23 cm/cm**. Která interpretace je správná?

A) Přesný rozdíl délky u každé dvojice květů, jejichž šířky se liší o 1 cm.

B) Průměrný rozdíl délky dvou květů, jejichž šířky se liší o 1 cm.

C) Podíl variability délky, který vysvětluje šířka korunního lístku.

Zvolte A/B/C. Zdůvodněte, jaké dvě veličiny a jaké jednotky sklon spojuje.

Co už víme o korunních lístcích?

Mají širší korunní lístky kosatců také větší délku — a pokud ano, o kolik?

CO MŮŽEME ŘÍCT

Ano. Dva květy, jejichž šířky se liší o 1 cm, se podle modelu liší v délce v průměru o **2,23 cm**.

CO ZATÍM NEVÍME

- Jak přesný je odhad **2,23 cm/cm**?
- Nepřehlíží jedna přímka systematický vzor?

Souvislost délky a šířky není důkaz příčiny


BIOLOGICKÝ ZÁVĚR

Asociace $\neq$ **příčina**

Model popisuje vztah v datech. Bez dalšího výzkumného designu neprokazuje, že větší šířka **způsobuje** větší délku.


Co zůstává mimo přímku?

Jak jsou residua rozdělená?




Kde leží většina residuí a jak daleko sahají od nuly?

Mění se residua podél odhadnuté délky?



- každý bod je jeden květ
- nad nulou model délku podhodnotil
- pod nulou model délku nadhodnotil
- hledáme neuspořádaný mrak kolem nuly

Vidíte neuspořádaný mrak, nebo zbývající vzor?




DISKUZE SE SOUSEDEM — 2 MIN

Najděte jednu oblast s převahou residuí nad nebo pod nulou. Co to říká o odhadované délce?

Které stopy by nás u přímky zneklidnily?


Schématické vzory; grafy nepředstavují další měření kosatců.




Přiřad'te: tvar vztahu · měnící se rozptýlení · pořadí měření.

B: tvar vztahu · C: měnící se rozptýlení · D: pořadí měření. A model neschvaluje.

Stejná původní data, ale s druhem



Stejná residua, ale s druhem



DISKUZE SE SOUSEDEM — 1 MIN
Který druh model spíše nadhodnocuje a který podhodnocuje? Podle čeho to poznáte?

Co model neviděl?

CHYBĚJÍCÍ PREDIKTOR

Druh kosatce

Jedna přímka zachytila celkový růst, ale druhy netvoří jeden společný mrak. Jejich struktura proto zůstává v residuích.

versicolor: 84 % residuí nad nulou → podhodnocuje · *setosa*: 78 % pod nulou → nadhodnocuje · *virginica*: 64 % pod nulou, hlavně nejširší květy

První model je začátek argumentu, ne jeho automatický konec.

Závěr

Shrnutí

- Biologickou otázku převádíme na **odezvu a prediktor**.
- `lm()` hledá přímku s **nejmenším součtem čtverců residuů**; **sklon** je průměrný rozdíl odezvy mezi pozorováními, jejichž prediktor se liší o jednu jednotku.
- **Residuum** je rozdíl mezi naměřenou a odhadnutou hodnotou; ukazuje, co model u jednotlivých pozorování nevysvětlil.
- **Vzor v residuích** upozorňuje na chybějící strukturu nebo omezení modelu.

Co potřebujete vidět, než napíšete „o centimetr širší lístek, o 2,23 cm delší lístek“?

Jaké tři otázky položíte autorovi, který vám ukáže jen sklon 2,23 cm/cm bez grafu?

ŘEKNĚTE SOUSEDovi JEDNOU VĚTOU

Kterou z otázek byste položili jako první, a proč?

Jak přesný je odhad sklonu? Následující lekce přidá nejistotu odhadu.