




L03

# Mají širší korunní lístky kosatců také větší délku — a pokud ano, o kolik?



Lineární model s jedním numerickým prediktorem

[cuni-natur-biostatistics.github.io/materialy.html](https://cuni-natur-biostatistics.github.io/materialy.html)

# Naše biologická otázka



## BIOLOGICKÁ OTÁZKA

**Mají širší korunní lístky kosatců také větší délku — a pokud ano, o kolik?**

## CO BUDEME SLEDOVAT

**150 květů**

šířka a délka korunního lístku v centimetrech

# Výsledky učení





Po dnešní přednášce budete schopni:

- převést biologickou otázku na vztah mezi **odezvou** a **prediktorem**
- fitovat  $\text{lm}(y \sim x)$  a interpretovat **směr** i **velikost efektu**
- vysvětlit **residuum** jako rozdíl mezi **měřením** a **odhadem**
- číst graf residuí a rozpoznat **zbývající vzor**

# Co si pamatujete z minulé lekce?

Odpovězte samostatně na tři krátké otázky. Potom společně projdeme správné odpovědi.

# Máme délku ploutve a tělesnou hmotnost každého tučňáka. Který graf je vhodný jako první pohled na jejich vztah?



Bodový graf

Jeden histogram

Koláčový graf


Tabulka četností kategorií

## SPRÁVNÁ ODPOVĚĎ

: Bodový graf

Obě proměnné jsou číselné a každá dvojice měření patří jednomu tučňákovi. Bodový graf zachová obě hodnoty i jejich párování.

# Jaký směr vztahu vidíme v bodovém grafu délky ploutve a tělesné hmotnosti?



Převážně rostoucí

Převážně klesající

Bez viditelného směru

Graf ukazuje pouze jednu proměnnou

## SPRÁVNÁ ODPOVĚĎ

: Převážně rostoucí

Tučňáci s delší ploutví bývají v tomto souboru těžší. Body proto tvoří převážně rostoucí oblak.

# Které tvrzení odpovídá tomu, co z tohoto pozorovacího grafu smíme vyvodit?



Delší ploutev způsobuje vyšší tělesnou hmotnost.

Tělesná hmotnost způsobuje růst ploutve.

Délka ploutve a tělesná hmotnost spolu v těchto datech souvisejí.

Druh tučňáka nemůže vztah ovlivnit.

## SPRÁVNÁ ODPOVĚĎ

: Délka ploutve a tělesná hmotnost spolu v těchto datech souvisejí.

Graf podporuje tvrzení o asociaci v pozorovaných datech. Sám neurčuje příčinu ani nevylučuje další proměnné.

# Od vztahu k modelu

Bodový graf ukazuje, že dvě proměnné souvisejí. Dnes se zeptáme: **o kolik se očekávaná délka korunního lístku změní, když se změní jeho šířka?**

# Co přidá model?

## CO UŽ UMÍME

- vztah zobrazit
- popsat jeho směr
- shrnout jeho těsnost korelací

## CO JEŠTĚ POTŘEBUJEME

O kolik se typicky změní odezva, když se prediktor zvýší o jednu jednotku?

Tato lekce přidá velikost efektu. Nejistotu odhadu přidáme v následující lekci.

# Jedna přímka shrnuje mnoho květů



Ilustrační obraz vytvořen AI.

Modelová přímka data nenahrazuje. Stručně popisuje jejich systematický vztah.

# Která proměnná má kterou roli?

## OTÁZKA


Chceme odhadovat **délku** korunního lístku podle jeho **šířky**. Co je **odezva**?

**A)** šířka korunního lístku


**B)** délka korunního lístku

Když nehlasujeme: napište „odezva = ...“, prediktor = ...“ a doplňte názvy obou měření.

# Všech 150 květů



# Jaký vztah vidíte?




**VYBERTE NEJLEPŠÍ POPIS**

- A)** bez zřetelného vztahu
- B)** přibližně lineární růst
- C)** výrazně zakřivený růst

Když nehlasujeme: doplňte „S rostoucí šířkou délka v průměru ...“.

# Co z grafu zatím můžeme říct?




## CO VIDÍME

- vztah je rostoucí
- kolem trendu zůstává variabilita
- jednotlivé květy neleží na jedné přímce

## CO JEŠTĚ NEVÍME

O kolik se odhadnutá délka změní při zvýšení šířky o 1 cm?


# Která z mnoha přímek je správná?




**DISKUZE SE SOUSEDEM — 30 S**

Sledujte jeden cyklus. Podle čeho byste mezi přímkami rozhodli?

# Tři kandidátní přímky




# Kterou přímku byste vybrali?




Když nehlasujeme: zvolte A/B/C a napište, podle čeho posuzujete „nejlepší“ přímku.

# Co se změní, když přímku posuneme?



Intercept (a) posouvá přímku nahoru nebo dolů.

# Co se změní, když přímku nakloníme?



Sklon (b) říká, jak rychle se mění odhadnutá délka s rostoucí šířkou.

# Dvě čísla popíší každou přímku

odhadnutá délka = intercept ( $a$ ) + sklon ( $b$ ) · šířka


## **intercept ( $a$ )**

Kde přímka začíná při šířce 0 cm.


## **sklon ( $b$ )**

Změna odhadnuté délky při zvýšení šířky o 1 cm.

# Co přímka odhaduje pro jeden květ?




# Přidáme jeden naměřený květ




**Šedý bod:** skutečně naměřená délka při šířce 2.5 cm.

# Přímka vrátí odhad



**Fialový bod**: odhadnutá délka na přímce při stejné šířce.

# Mezi měřením a odhadem zůstává rozdíl



Zaoblená oranžová úsečka ukazuje residuum.

# Jaké znaménko má residuum?

Naměřená délka šedého bodu leží **pod** odhadem modelu. Residuum je:

**A)** kladné

**B)** záporné

**C)** nulové

Když nehlasujeme: doplňte „naměřená – odhadnutá = ...“, včetně znaménka.


# Jak residuum počítáme?

## NEJPRVE ODHAD MODELU

odhadnutá délka = intercept + sklon · šířka

## POTOM ROZDÍL

residuum = naměřená délka – odhadnutá délka




# 1. Odhadnutá délka

Naše přímka: **intercept (a) = 1.1 cm** · **sklon (b) = 2.2 cm/cm**

## DOSADÍME HODNOTY


$$\begin{aligned}\text{odhadnutá délka} &= \text{intercept} + \text{sklon} \cdot \text{šířka} \\ &= 1.1 + 2.2 \cdot 2.5 \\ &= 6.6 \text{ cm}\end{aligned}$$



## 2. Residuum

### NAMĚŘENÁ MINUS ODHADNUTÁ

$$\begin{aligned}\text{residuum} &= \text{naměřená délka} - \text{odhadnutá délka} \\ &= 6 - 6.6 \\ &= -0.6 \text{ cm}\end{aligned}$$



Zkráceně:  $e_i = y_i - \hat{y}_i$

# Residua očekáváme i u užitečného modelu

## DŮLEŽITÁ MYŠLENKA

Biologická variabilita nezmizí jen proto, že jsme nakreslili modelovou přímku

Model nemusí trefit každý květ přesně. Potřebujeme ale zjistit, zda chyby působí náhodně, nebo zda v nich zůstává vzor.

# Jak porovnat celé přímky?

## 1 · ZMĚŘIT ROZDÍL

Pro každý květ určíme  
residuum.

## 2 · ODSTRANIT ZNAMÉNKO

Každé residuum  
umocníme.


## 3 · SHRNOU PŘÍMKU

Čtverce sečteme do  
jednoho čísla: SSE.

Menší SSE znamená, že body leží celkově blíže přímce.


# Když se přímka mění, mění se i chyby

intercept = 0  
sklon = 3.4



Čtverce residuí

SSE pro 4 květy = 8.52



**Sledujte jeden cyklus:** Kdy je celková oranžová plocha nejmenší?

**Co se mění:** strana =  $|e_i|$  · plocha =  $e_i^2$  · součet = **SSE**

# Která **přímka** je nejlepší podle **dat**?

| Přímka   | Intercept | Sklon | SSE pro 4 květy |
|----------|-----------|-------|-----------------|
| <b>A</b> | 0.5       | 2.3   | 0.53            |
| <b>B</b> | 1.1       | 2.2   | 0.45            |
| <b>C</b> | 1.7       | 1.9   | 0.86            |

Když nehlasujeme: vyberte přímku s nejmenším SSE a jednou větou vysvětlete, co toto číslo shrnuje.

# Počítač najde nejlepší přímku

CO HLEDÁ `lm()`

Intercept a sklon, které dávají nejmenší SSE.

PROČ TUTO PŘÍMKU

Její body leží podle zvoleného pravidla celkově nejbližše datům.

`lm()` výpočet automatizuje; statistické pravidlo jsme už sestavili sami.

# Stejná data v R

```
1 data(iris)
2
3 data_kosatce <-
4   data.frame(
5     sirka_listku = iris$Petal.Width,
6     delka_listku = iris$Petal.Length,
7     druh = iris$Species
8   )
```

## TŘI SLOUPCE

- sirka\_listku: prediktor
- delka\_listku: odezva
- druh: zatím mimo model

# Co obsahuje data\_kosatce?

```
1 summary(data_kosatce)
```

| sirka_listku  | delka_listku  | druh          |
|---------------|---------------|---------------|
| Min. :0.100   | Min. :1.000   | setosa :50    |
| 1st Qu.:0.300 | 1st Qu.:1.600 | versicolor:50 |
| Median :1.300 | Median :4.350 | virginica :50 |
| Mean :1.199   | Mean :3.758   |               |
| 3rd Qu.:1.800 | 3rd Qu.:5.100 |               |
| Max. :2.500   | Max. :6.900   |               |

Před modelováním vždy nejprve zkontrolujeme názvy, rozsahy a případné chybějící hodnoty.

# Gramatika funkce `lm()`

```
1 lm(  
2   formula = odezva ~ prediktor,  
3   data = data  
4 )
```

Znak `~` čteme: **odezvu vysvětlujeme pomocí prediktoru.**

# Dosadíme názvy z naší otázky

## FORMULA

```
delka_listku ~ sirka_listku  
odezva ~ prediktor
```

## DATA

```
data = data_kosatce  
tabulka se všemi 150 květy
```

# Fitujeme první model

```
1 mod_listky <-  
2   lm(  
3     formula = delka_listku ~ sirka_listku,  
4     data = data_kosatce  
5   )
```

Model ukládáme jako `mod_listky`, abychom se k němu mohli vracet.

# Jaké koeficienty model odhadl?

```
1 coef(mod_listky)
```

```
(Intercept) sirka_listku  
1.083558      2.229940
```

| Parametr  | Odhad | Jednotka |
|-----------|-------|----------|
| Intercept | 1,08  | cm       |
| Sklon     | 2,23  | cm/cm    |

# Co znamená odhadnutý **sklon**?

**Sklon** je **2.23 cm/cm**. Která interpretace je správná?

**A)** Přesná změna každého jednotlivého květu.

**B)** Průměrná změna délky při zvýšení šířky o 1 cm.

**C)** Procento variability vysvětlené šířkou.

Bez hlasování: přepište B vlastními slovy; zachovejte **1 cm** a **v průměru**.

# Vracíme se k biologické otázce

Mají širší korunní lístky kosatců také větší délku, a pokud ano, jak velká je tato změna?

CO MŮŽEME ŘÍCT

Při zvýšení šířky o 1 cm model odhaduje v průměru zvýšení délky o **2.23 cm**.

# Co ještě nevíme?

## NEJISTOTA

Jak přesný je odhad **2,23 cm/cm**?

## ZBÝVAJÍCÍ STRUKTURA

Přehlíží jedna přímka systematický vzor?


# Směr a velikost nejsou příčina

## BIOLOGICKÝ ZÁVĚR


**Asociace**  $\neq$  **příčina**

Model popisuje vztah v datech. Bez dalšího výzkumného designu neprokazuje, že větší šířka **způsobuje** větší délku.

# Co zůstalo po odhadu přímky?



# Jak tento graf čteme?



- každý bod je jeden květ
- nad nulou model délku podhodnotil
- pod nulou model délku nadhodnotil
- hledáme neuspořádaný mrak kolem nuly


# Vidíte náhodný mrak, nebo zbývající vzor?

**Prohlédněte si graf 30 sekund a najděte jednu část, která vás zneklidňuje.**


**DISKUZE SE SOUSEDEM — 2 MIN**

Popište pouze to, co v grafu vidíte. Zatím nenavrhujte řešení.

# Stejná původní data, ale s druhem



# Stejná residua, ale s druhem



# Co model neviděl?

## CHYBĚJÍCÍ PREDIKTOR

### Druh kosatce

Jedna přímka zachytila **celkový růst**, ale druhy netvoří jeden společný mrak. Jejich struktura proto zůstává v residuích.

# Co ještě z lineárního modelu neplyne?

- neznáme nejistotu odhadnutého sklonu
- neprokázali jsme příčinný mechanismus
- nezahrnuli jsme druh kosatce jako další prediktor
- nevyřešili jsme všechny možné diagnostické problémy

První model je začátek argumentu, ne jeho automatický konec.

# Shrnutí

- Biologickou otázku převádíme na **odezvu a prediktor**.
- **Sklon** popisuje změnu odhadnuté odezvy při změně prediktoru o jednu jednotku.
- `lm()` hledá přímku s **nejmenším součtem čtverců residuí**.
- **Residua** ukazují, co model u jednotlivých pozorování nevysvětlil.
- **Vzor v residuích** upozorňuje na chybějící strukturu nebo omezení modelu.

# Poslední kontrola

**MODEL MÁ KLADNÝ SKLON**

**Co zkontrolujete před biologickou interpretací?**

**MINIMÁLNÍ ODPOVĚĎ**

Residua a biologický kontext modelu.