

Lineární model s jedním numerickým prediktorem

Biostatistika - L03

 Ondřej Mottl


Moodle

Výsledky učení

Po absolvování této přednášky budete schopni:

- převést biologickou otázku na modelovou otázku s odezvou a prediktorem
- fitovat model $\mathcal{L}_m(y \sim x)$ a interpretovat směr i velikost efektu
- vysvětlit, co je residuum a co říká o konkrétním pozorování
- přečíst základní graf residuí a rozpoznat, že model něco systematicky nezachytil

Minule jsme skončili tady



Co přidá model?

CO UŽ UMÍME

- vztah zobrazit
- popsat jeho směr
- shrnout jeho těsnost korelací

CO JEŠTĚ POTŘEBUJEME

O kolik se typicky změní odezva, když se prediktor zvýší o jednu jednotku?

Tato lekce přidá velikost efektu. Nejistotu odhadu přidáme v následující lekci.

Dnes budeme měřit květy

Mají širší korunní lístky kosatců také větší délku?

150 květů · dvě měření v centimetrech · jeden první model

Která proměnná má kterou roli?

OTÁZKA

Chceme odhadovat **délku** korunního lístku podle jeho **šířky**. Co je odezva?

A) šířka korunního lístku

B) délka korunního lístku

Když nehlasujeme: napište „odezva = ...“, prediktor = ...“ a doplňte názvy obou měření.

Nejprve jeden květ



Přidáme další tři květy



Co čekáte ve všech datech?

PŘEDPOVĚĎ

Jak bude vypadat vztah mezi šířkou a délkou korunního lístku u všech 150 květů?

(A) téměř bez vztahu

(B) zřetelně rostoucí vztah

(C) zřetelně klesající vztah

Když nehlasujeme: zvolte A/B/C a napište jednu větu, podle čeho byste svoji předpověď v grafu poznali.

Všech 150 květů



Co z grafu zatím můžeme říct?




CO VIDÍME

- vztah je rostoucí
- kolem trendu zůstává variabilita
- jednotlivé květy neleží na jedné přímce


CO JEŠTĚ NEVÍME

O kolik se odhadnutá délka změní při zvýšení šířky o 1 cm?

Stejná data můžeme proložit různými přímkami




Kterou přímku byste vybrali?




Když nehlasujeme: zvolte A/B/C a napište, podle čeho posuzujete „nejlepší“ přímku.

Co se změní, když přímku posuneme?



Intercept a posouvá přímku nahoru nebo dolů.

Co se změní, když přímku nakloníme?



Sklon b říká, jak rychle se mění odhadnutá délka s rostoucí šířkou.

Dvě čísla popíší každou přímku

$$\text{odhadnutá délka} = a + b \cdot \text{šířka}$$


a — **intercept**

Kde přímka začíná při šířce 0 cm.


b — **sklon**

Změna odhadnuté délky při zvýšení šířky o 1 cm.

Co přímka odhaduje pro jeden květ?



Mezi měřením a odhadem zůstává rozdíl



Tento svislý rozdíl nazýváme **residuum**.

Jaké znaménko má residuum?

ROZHODNĚTE PODLE OBRÁZKU

Naměřená délka šedého bodu leží **pod** odhadem modelu. Residuum je:

(A) kladné

(B) záporné

(C) nulové

Když nehlasujeme: doplňte „naměřená – odhadnutá = ...“, včetně znaménka.

Residuum pro jeden konkrétní květ

Pro šířku **2.5 cm** odhaduje přímka délku:

$$1.1 + 2.2 \cdot 2.5 = 6.6 \text{ cm}$$

Naměřili jsme **6 cm**, takže:

$$6 - 6.6 = -0.6 \text{ cm}$$


Obecně: $e_i = y_i - \hat{y}_i$

Residua očekáváme i u užitečného modelu

Biologická variabilita nezmizí jen proto, že jsme nakreslili přímku.

Model nemusí trefit každý květ přesně. Potřebujeme ale zjistit, zda chyby působí náhodně, nebo zda v nich zůstává vzor.

Stejný rozdíl pro čtyři květy



Jak porovnat celé přímky?

1. Pro každý květ změříme residuum.
2. Residua umocníme, aby se kladné a záporné rozdíly nevyrušily.
3. Čtverce sečteme do jednoho čísla: **SSE**.

Menší SSE znamená, že body leží celkově blíže přímce.

Která přímka je nejlepší podle dat?

Přímka	Intercept	Sklon	SSE
A	0.5	1.8	231.1
B	1.1	2.2	34
C	1.7	2.6	214.3

Když nehlasujeme: vyberte přímku s nejmenším SSE a jednou větou vysvětlete, co toto číslo shrnuje.

Počítač najde nejlepší přímku

`lm()` najde intercept a sklon, které minimalizují SSE.

My už ale víme, **co** hledá a **proč** právě tuto přímku preferuje.

Stejná data v R

```
1 data(iris)
2
3 data_kosatce <-
4   data.frame(
5     sirka_listku = iris$Petal.Width,
6     delka_listku = iris$Petal.Length,
7     druh = iris$Species
8   )
```

TŘI SLOUPCE

- šířka: prediktor
- délka: odezva
- druh: zatím mimo model

Fitujeme první model

```
1 mod_listky <-  
2   lm(  
3     formula = delka_listku ~ sirka_listku,  
4     data = data_kosatce  
5   )  
6  
7   coef(mod_listky)
```

```
(Intercept) sirka_listku  
1.083558      2.229940
```

ODHADNUTÉ KOEFICIENTY

- intercept: **1.08 cm**
- sklon: **2.23 cm/cm**

Co znamená odhadnutý sklon?

VYBERTE BIOLOGICKOU INTERPRETACI

Odhadnutý sklon je 2.23 cm/cm.

- **A)** Každý korunní lístek je přesně o 2.23 cm delší než předchozí.
- **B)** Při zvýšení šířky o 1 cm očekáváme v průměru zvýšení délky o 2.23 cm.
- **C)** Šířka vysvětluje 2.23 % variability délky.

Když nehlasujeme: přepište správnou možnost vlastními slovy a zachovejte jednotky i výraz „v průměru“.

Vracíme se k biologické otázce

Mají širší korunní lístky kosatců také větší délku, a pokud ano, jak velká je tato změna?

CO MŮŽEME ŘÍCT

Při zvýšení šířky o 1 cm model odhaduje v průměru zvýšení délky o **2.23 cm**.

CO JEŠTĚ NEVÍME

- jak nejistý je tento odhad
- zda přímka něco systematicky přehlíží

Směr a velikost nejsou příčina

MODEL UKAZUJE


Asociaci mezi šířkou a délkou korunního lístku.

MODEL SÁM NEPROKAZUJE


Že větší šířka přímo způsobuje větší délku.

Koeficient popisuje vztah v datech; kauzální mechanismus vyžaduje další argumenty.

Co zůstalo po odhadu přímky?



Jak tento graf čteme?



- každý bod je jeden květ
- nad nulou model délku podhodnotil
- pod nulou model délku nadhodnotil
- hledáme neuspořádaný mrak kolem nuly


Vidíte náhodný mrak, nebo zbývající vzor?

Prohlédněte si graf 30 sekund a najděte jednu část, která vás zneklidňuje.


DISKUZE SE SOUSEDEM — 2 MIN

Popište pouze to, co v grafu vidíte. Zatím nenavrhujte řešení.

Stejná původní data, ale s druhem



Stejná residua, ale s druhem



Co model neviděl?

CO UŽ VÍME

Jedna přímka zachytila celkový rostoucí vztah šířky a délky.

CO V MODELU CHYBÍ

Druhy kosatců netvoří jeden společný mrak a v residuích zůstává jejich struktura.

Diagnostika neříká jen „dobrý/špatný model“. Ukazuje, co jednoduchý model ještě nevysvětlil.

Co ještě z lineárního modelu neplyne?

- neznáme nejistotu odhadnutého sklonu
- neprokázali jsme příčinný mechanismus
- nezahrnuli jsme druh kosatce jako další prediktor
- nevyřešili jsme všechny možné diagnostické problémy

První model je začátek argumentu, ne jeho automatický konec.

Shrnutí

- Biologickou otázku převádíme na odezvu a prediktor.
- Sklon popisuje změnu odhadnuté odezvy při změně prediktoru o jednu jednotku.
- `lm()` hledá přímku s nejmenším součtem čtverců residuí.
- Residua ukazují, co model u jednotlivých pozorování nevysvětlil.
- Vzor v residuích upozorňuje na chybějící strukturu nebo omezení modelu.

CO BYSTE ZKONTROLOVALI JAKO PRVNÍ?

Model má kladný sklon a body přibližně sledují přímku. Znamená to, že můžeme výsledek bez další kontroly biologicky interpretovat?

- A)** Ano, kladný sklon stačí.
- B)** Ne, nejprve zkontrolujeme residua a biologický kontext.
- C)** Ano, pokud je v datasetu dost pozorování.

Když nehlasujeme: napište jednu kontrolu, kterou byste před konečnou interpretací modelu vždy provedli.